Topological Data Analysis를 활용한 음악 구조 분석 및 위상 구조 보존 기반 AI 작곡 파이프라인

저자: 김민주
지도: 정재훈 (KIAS 초학제 독립연구단)
작성일: 2026

---

2. 수학적 배경

본 절에서는 본 연구의 파이프라인을 이해하기 위해 필요한 수학적 도구들을 정의하고, 각 도구가 음악 구조 분석에서 어떻게 사용되는지를 서술한다.

2.1 Vietoris-Rips Complex

정의 2.1. 거리 공간 (X, d)와 양의 실수 $\varepsilon > 0$이 주어졌을 때, Vietoris-Rips complex $\mathrm{VR}_\varepsilon(X)$는 다음과 같이 정의되는 복합체(simplicial complex)이다:

$$\mathrm{VR}_\varepsilon(X) = \left\{\sigma \subseteq X \mid \forall x_i, x_j \in \sigma,\ d(x_i, x_j) \leq \varepsilon\right\}$$

즉, 부분집합 σ에 속한 모든 점 쌍 사이의 거리가 ε 이하이면 σ를 심플렉스(simplex)로 포함시킨다.

구성 요소:

- 0-simplex (vertex): 각 점 $x_i \in X$
- 1-simplex (edge): $d(x_i, x_j) \leq \varepsilon$인 쌍 $\{x_i, x_j\}$
- 2-simplex (triangle): 세 점이 모두 ε 이내인 삼각형
- k-simplex: $k+1$개의 점이 모두 ε 이내인 부분집합

Filtration 구조: ε 값을 0부터 연속적으로 키우면, 어떤 임계값들을 지날 때마다 새로운 심플렉스가 추가되어 복합체의 위상이 변한다. 이 변화 임계값들을 $\varepsilon_0 < \varepsilon_1 < \varepsilon_2 < \cdots$로 두면, 다음의 nested sequence가 만들어진다:

$$\emptyset \subseteq \mathrm{VR}_{\varepsilon_0}(X) \subseteq \mathrm{VR}_{\varepsilon_1}(X) \subseteq \mathrm{VR}_{\varepsilon_2}(X) \subseteq \cdots \subseteq \mathrm{VR}_{\varepsilon_n}(X)$$

표기 편의를 위해 $K_{\varepsilon_i} := \mathrm{VR}_{\varepsilon_i}(X)$로 두면:

$$\emptyset \subseteq K_{\varepsilon_0} \subseteq K_{\varepsilon_1} \subseteq K_{\varepsilon_2} \subseteq \cdots \subseteq K_{\varepsilon_n}$$

이를 filtration이라 부르며, 변화가 일어나는 미지수 ε_i들이 곧 위상 구조의 birth/death 시점이 된다.

본 연구에서의 사용: $X = \{n_1, n_2, \ldots, n_{23}\}$은 hibari에 등장하는 23개의 고유 note이며, $d(n_i, n_j)$는 두 note 간 거리이다. ε를 점진적으로 증가시키며 simplex complex의 변화를 추적하여, 어떤 거리 척도에서 어떤 위상 구조가 출현·소멸하는지를 분석한다.

2.2 Simplicial Homology

정의 2.2. Simplex complex K에 대해 **n차 호몰로지 군**(homology group) $H_n(K)$는 K 안에 존재하는 n차원 "구멍"의 대수적 표현이다. 직관적으로:

- $H_0(K)$: 연결 성분(connected components)의 개수
- $H_1(K)$: cycle의 개수 (1차원 구멍)

- $H_2(K)$: 2차원 빈 공간(void)의 개수

Betti number $\beta_n = \mathrm{rank}(H_n(K))$는 n차원 위상 특징의 개수를 나타낸다. 예컨대 $\beta_1 = 3$이면 이 simplex complex 안에 서로 독립적인 cycle이 3개 있다는 뜻이다.

본 연구에서의 사용: 본 연구는 주로 H_1 (1차 호몰로지)을 다룬다. 이는 음악 네트워크에서 서로 가까운 note들이 만드는 닫힌 cycle, 즉 순환적으로 연결된 note 그룹을 포착한다. 발견된 각 cycle은 곡의 구조적 반복 단위로 해석된다.

2.3 Persistent Homology

Filtration $K_{\varepsilon_0} \subseteq K_{\varepsilon_1} \subseteq \cdots \subseteq K_{\varepsilon_n}$에서, 각 단계마다 H_1의 cycle 구조가 달라진다. Persistent homology는 이 과정에서 각 cycle이 어느 ε_i에서 처음 나타나고(birth) 어느 ε_j에서 사라지는지(death)를 추적하는 이론이다.

Birth와 death의 음악적 의미:

- Birth b: 거리 임계값 ε가 충분히 커져서 새로운 cycle이 형성되는 순간. 음악적으로는 "이 거리 척도에서 처음으로 닫힌 반복 구조가 발견되는 시점".
- Death d: 더 큰 ε에서 그 cycle 내부가 더 작은 simplex들로 채워져 cycle이 더 이상 독립적이지 않게 되는 순간. 음악적으로는 "거리 척도가 너무 느슨해져서 이 cycle이 다른 구조에 흡수되는 시점".

각 cycle은 (b, d) 쌍으로 기록되며, 본 연구에서는 이 쌍의 모음을 곡의 위상적 지문(topological signature)으로 사용한다.

Persistence: $\mathrm{pers}(\mathrm{cycle}) = d - b$. (death가 birth보다 항상 크므로 양수.) 큰 persistence를 갖는 cycle은 다양한 거리 척도에서 살아남으므로 위상적으로 안정한 구조이며, 작은 persistence는 일시적이거나 노이즈에 가까운 구조이다.

알고리즘적 측면: Persistent homology는 boundary matrix D를 구성하고 column reduction을 수행하여 계산한다. 본 연구에서는 두 가지 구현을 사용하였다:

1. pHcol algorithm (정재훈 외, 2024): 순수 Python 구현
2. Ripser (Bauer, 2021): C++ 기반 최적화 구현, 약 45배 빠름

본 연구에서의 사용: 거리 행렬 $D \in \mathbb{R}^{23 \times 23}$로부터 Vietoris-Rips filtration을 구성하고, 각 rate parameter r (가중치 비율, 후술)에서의 H_1 persistence를 계산한다. 발견된 모든 (b, d) 쌍이 cycle 집합을 정의하며, 이 cycle들이 다음 절의 중첩행렬 구축에 사용된다.

2.4 Tonnetz와 음악적 거리 함수

Pitch class 개념. Tonnetz를 정의하기에 앞서, pitch class는 옥타브 차이를 무시한 음의 동치류이다. 예컨대 C4 (가운데 도)와 C5 (한 옥타브 위 도), C3 등은 모두 같은 pitch class "C"에 속한다. 12음 평균율(12-TET)에서는 한 옥타브 안에 12개의 pitch class가 있으며, 이를 정수 $\{0, 1, 2, \ldots, 11\}$에 대응시켜 $\mathbb{Z}/12\mathbb{Z}$로 표기한다 (0=C, 1=C , 2=D, ..., 11=B).

정의 2.4. Tonnetz(또는 tone-network)는 pitch class 집합 $\mathbb{Z}/12\mathbb{Z}$를 평면 격자에 배치한 구조이다. 두 pitch class가 격자 위에서 가까운 것은 음악 이론적으로 어울리는 음(consonant)임을 의미한다.

Tonnetz의 격자 구조: pitch class $p \in \mathbb{Z}/12$를 좌표 (x, y)에 배치하되, 다음 관계를 만족시킨다:

- 가로 이동 (+1 in x): 완전5도 (perfect fifth, +7 semitones)
- 대각선 이동 (+1 in y): 장3도 (major third, +4 semitones)

이렇게 배치하면 자연스럽게 단3도(+3 semitones) 관계도 다른 대각선 방향으로 형성되어 삼각형 격자가 만들어진다. 그림 2.1은 hibari의 C장조 음역에 해당하는 일부분을 보여준다.

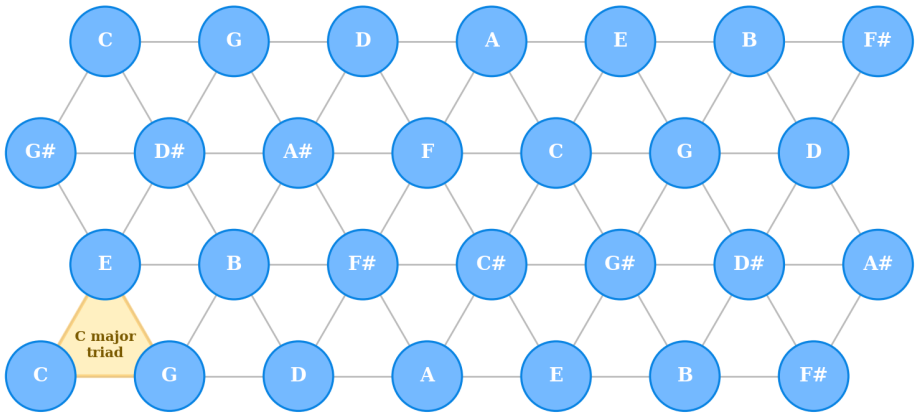

그림 2.1. Tonnetz 격자 구조. 가로 방향은 완전5도(C→G→D→A→E...), 대각선 방향은 장3도(C→E→G ...)와 단3도(C→A→F ...)로 이동한다. 삼각형 하나는 하나의 장3화음(major triad) 또는 단3화음(minor triad)에 대응된다.

Tonnetz 거리. 두 pitch class p_1, p_2 사이의 Tonnetz 거리 $d_T(p_1, p_2)$는 격자 위 최단 경로 길이로 정의된다:

$$d_T(p_1, p_2) = \min\{|x_1 - x_2| + |y_1 - y_2| \mid (x_i, y_i) \text{ represents } p_i\}$$

본 연구에서는 BFS(너비 우선 탐색)로 이 거리를 계산하며, 12개 pitch class 모두에 대해 사전 계산된 12×12 거리 테이블을 사용한다.

빈도 기반 거리 d_{freq}. 본 연구의 기준 거리는 두 note의 인접도(adjacency)의 역수로 정의된다. 인접도 $w(n_i, n_j)$는 곡 안에서 두 note가 시간적으로 연달아 등장한 횟수이다:

$$w(n_i, n_j) = \#\{t : (n_i \text{ attime } t) \wedge (n_j \text{ attime } t+1)\}$$

거리는 $d_{\text{freq}}(n_i, n_j) = 1/w(n_i, n_j)$로 정의되며 (인접도가 0인 경우는 도달 불가능한 큰 값으로 처리), 자주 연달아 등장하는 음일수록 가까워진다. 이는 곡의 통계적 흐름만 반영하며 화성 관계는 직접 포착하지 못한다는 한계가 있다.

그 외의 음악적 거리 함수.

1. Voice-leading distance (Tymoczko, 2008):

$$d_V(p_1, p_2) = |p_1 - p_2|$$

즉, 두 음의 반음 차이. 피아노 건반에서 가까운 음일수록 거리가 짧다.

2. DFT distance (Tymoczko, 2008): pitch class 집합을 12차원 indicator vector로 표현한 후 이산 푸리에 변환(Discrete Fourier Transform)을 적용하여 푸리에 공간(Fourier space)으로 옮긴 뒤, 그 공간에서의 L_2 거리를 측정한다:

$$d_F(p_1, p_2) = \|\hat{f}(p_1) - \hat{f}(p_2)\|_2$$

여기서 $\hat{f}(p)$는 pitch class p의 indicator vector $e_p \in \mathbb{R}^{12}$를 DFT 변환한 결과이다. 각 푸리에 계수는 음악적 속성에 대응되는데, 예컨대 $|\hat{f}(3)|$은 단3도 대칭성, $|\hat{f}(5)|$는 온음계성(diatonicity)과 연관된다 (Tymoczko, 2008).

복합 거리(Hybrid distance). 본 연구는 빈도 기반 거리 d_{freq}와 음악적 거리 d_{music} (Tonnetz, Voice-leading, DFT 중 하나)을 선형 결합한다:

$$d_{\text{hybrid}}(n_i, n_j) = \alpha \cdot d_{\text{freq}}(n_i, n_j) + (1-\alpha) \cdot d_{\text{music}}(n_i, n_j)$$

여기서 $\alpha \in [0,1]$은 두 거리의 비중을 조절하는 파라미터이다. Grid search 결과, hibari에 대해서는 $\alpha = 0.3$ (음악적 거리 70% + 빈도 거리 30%)이 최적임을 확인하였다 (실험 결과 표 X 참조).

본 연구에서의 사용: 거리 함수의 선택은 발견되는 cycle 구조에 직접적으로 영향을 미친다. 빈도 기반 거리만 사용하면 곡의 통계적 특성만 반영되어 화성적·선율적 의미가 있는 구조를 포착하지 못한다. Tonnetz 거리를 도입함으로써 hibari의 C장조/A단조 화성 구조와 정합적인 cycle을 발견할 수 있었다.

2.5 활성화 행렬과 중첩행렬

본 연구에서는 곡의 시간축 위에서 cycle 구조가 어떻게 전개되는지를 두 단계의 행렬로 표현한다. 첫 단계는 활성화 행렬(activation matrix), 두 번째 단계는 그것을 가공한 중첩행렬(overlap matrix)이다.

정의 2.5 (활성화 행렬). 음악의 시간축 길이를 T, 발견된 cycle의 수를 C라 하자. 활성화 행렬 $A \in \{0,1\}^{T \times C}$는 raw 활성 정보를 담는다:

시점 t에서 cycle c를 구성하는 note 중 적어도 하나가 원곡에서 연주되고 있으면 $A[t,c] = 1$, 아니면 $A[t,c] = 0$이다. 형식적으로:

$$A[t,c] = \mathbb{1}[\,\exists n \in V(c) \text{ s.t. } n \text{ isplayedattime } t\,]$$

여기서 $V(c)$는 cycle c의 vertex(=note) 집합이며, $\mathbb{1}[\cdot]$은 indicator function이다. 활성화 행렬은 산발적인 단일 시점 활성화까지 모두 포함하므로 노이즈가 많다.

정의 2.6 (중첩행렬). 중첩행렬 $O \in \{0,1\}^{T \times C}$는 활성화 행렬에서 연속적이고 충분히 긴 활성 구간만 남긴 것이다.

$$O[t,c] = \mathbb{1}[\,t \in R(c)\,], \qquad R(c) = \bigcup_i [s_i, s_i + L_i]$$

여기서 $R(c)$는 cycle c의 "지속 활성 구간(sustained intervals)"의 합집합이며, 각 구간 $[s_i, s_i + L_i]$는 활성화 행렬 $A[\cdot, c]$에서 길이가 임계값 $\text{scale}(c)$ 이상인 연속 1의 구간이다. 즉, 중첩행렬은 활성화 행렬을 시간 방향 morphological filtering한 결과이다.

활성화 행렬과 중첩행렬의 차이.

- $A[t,c]$: 시점 t에 cycle c의 note가 단 한 번이라도 울리면 1. 순간적 활성을 모두 잡음.
- $O[t,c]$: cycle c의 활성이 일정 시간 이상 지속되는 구간에서만 1. 산발적 노이즈 제거됨.

본 연구에서 중첩행렬을 음악 생성의 seed로 사용하는 이유는, 잠시 스쳐가는 활성보다 일정 시간 유지되는 cycle만이 곡의 구조적 단위로 의미 있다고 보기 때문이다.

구축 과정:

1. 활성화 행렬 계산: 위 정의 2.5에 따라 $A \in \{0,1\}^{T \times C}$를 구한다.
2. 연속 활성 구간 추출: 각 cycle c에 대해 길이 $\geq \text{scale}(c)$인 연속 1 구간을 모두 찾는다.
3. Scale 동적 조정: cycle마다 ON 비율 $\rho(c) = |R(c)|/T$가 목표치 $\rho^* = 0.35$에 근접하도록 $\text{scale}(c)$를 조정한다 (구간이 너무 많으면 scale을 키우고, 너무 적으면 줄인다).

목표 ON 비율 $\rho^* = 0.35$의 근거. 이 값은 본 연구에서 새로 결정한 것이 아니라 선행연구(정재훈 외, 2024)에서 사용된 휴리스틱 값을 계승한 것이다. 직관적으로 한 cycle이 곡 전체의 약 1/3 정도 활성화되면 "그 cycle이 곡의 구조적 모티프로서 충분히 자주 등장하면서도, 모든 시점을 점유하지 않아 다른 cycle과 구분된다"는 균형을 만든다. 이 값의 최적성은 본 연구에서 정량적으로 검증하지 않았으며, 향후 다른 곡으로 확장할 때 재검토되어야 할 파라미터이다.

연속값 확장. 본 연구에서는 이진 중첩행렬 외에, cycle의 활성 정도를 [0,1] 사이의 실수값으로 표현하는 연속값 버전도 도입하였다:

$$O_{\text{cont}}[t,c] = \frac{\sum_{n \in V(c)} w(n) \cdot \mathbb{1}[n \text{ isplayedattime } t]}{\sum_{n \in V(c)} w(n)}$$

여기서 $V(c)$는 cycle c의 vertex 집합, $w(n) = 1/N_{\text{cyc}}(n)$은 note n의 희귀도 가중치이며 $N_{\text{cyc}}(n)$은 note n이 등장하는 cycle의 개수이다. 적은 cycle에만 등장하는 희귀한 note가 활성화되면 더 큰 가중치를 받는다.

음악적 의미: 중첩행렬은 곡의 위상적 뼈대(topological skeleton)를 시각화한 것이다. 시간이 흐름에 따라 어떤 반복 구조가 켜지고 꺼지는지를 나타내며, 이것이 음악 생성의 seed 역할을 한다.

2.6 Kullback-Leibler Divergence와 Jensen-Shannon Divergence

정의 2.7 (KL Divergence). 두 이산 확률 분포 P와 Q에 대해, Kullback-Leibler divergence는 다음과 같이 정의된다:

$$D_{\text{KL}}(P \| Q) = \sum_i P(i) \log \frac{P(i)}{Q(i)}$$

직관적으로 $D_{\text{KL}}(P \| Q)$는 "참 분포가 P인데 우리가 Q로 잘못 알고 있을 때 발생하는 정보 손실(information loss)"의 평균으로 해석된다. 두 분포가 똑같으면 손실이 없으므로 $D_{\text{KL}} = 0$이고, 분포의 차이가 클수록 값이 커진다. 항상 $D_{\text{KL}}(P \| Q) \geq 0$이며, 등호는 $P = Q$일 때만 성립한다 (Gibbs' inequality).

비대칭성: $D_{\text{KL}}(P \| Q) \neq D_{\text{KL}}(Q \| P)$. 예를 들어, P에는 자주 나오는 사건이 Q에는 거의 없으면 $D_{\text{KL}}(P \| Q)$는 매우 크지만 그 반대는 작을 수 있다. 이 비대칭성 때문에 두 곡을 "공정하게" 비교하기 위해서는 대칭화된 지표가 필요하다.

정의 2.8 (Jensen-Shannon Divergence). KL을 대칭화한 지표로, JS divergence는 다음과 같이 정의된다:

$$D_{\text{JS}}(P \| Q) = \tfrac{1}{2} D_{\text{KL}}(P \| M) + \tfrac{1}{2} D_{\text{KL}}(Q \| M)$$

여기서 $M = \frac{1}{2}(P+Q)$는 두 분포의 평균이다.

핵심 성질:

- 대칭성: $D_{\text{JS}}(P \| Q) = D_{\text{JS}}(Q \| P)$
- 유계성: $0 \leq D_{\text{JS}}(P \| Q) \leq \log 2$ ($\log_2$ 사용 시 최대값 1)
- D_{JS} 자체는 metric은 아니지만, $\sqrt{D_{\text{JS}}}$는 삼각 부등식까지 만족하는 metric이다 (Endres & Schindelin, 2003)

본 연구에서의 사용: 생성된 음악과 원곡의 유사도를 평가하는 주요 지표로 사용한다. 두 가지 분포를 비교한다.

(1) Pitch 빈도 분포. 곡에 등장하는 모든 note에 대해, 그 pitch 값의 출현 횟수를 세어 정규화한 확률 분포이다. 곡의 모든 note 집합을 $\mathcal{N} = \{(s_k, p_k, e_k)\}_{k=1}^{K}$ (s_k=시작, p_k=pitch, e_k=종료)라 하면:

$$P_{\text{pitch}}(p) = \frac{|\{k : p_k = p\}|}{K}$$

원곡과 생성곡 각각에서 이 분포를 계산하고 둘 사이의 JS divergence를 측정한다. 값이 0에 가까울수록 두 곡의 pitch 사용 비율이 일치한다.

(2) Transition 빈도 분포. 시간 순서대로 인접한 두 note 쌍 (p_k, p_{k+1})의 출현 횟수를 세어 정규화한 분포이다. note들을 시작 시점 s_k 순으로 정렬하여 pitch 시퀀스 $(p_1, p_2, \ldots, p_K)$를 만들고:

$$P_{\text{trans}}(a,b) = \frac{|\{k : p_k = a,\ p_{k+1} = b\}|}{K-1}$$

이는 $|P| \times |P|$ 크기의 transition matrix를 정규화한 것과 동일하다. 원곡과 생성곡의 transition 분포 간 JS divergence는 "어떤 음 다음에 어떤 음이 오는가"의 패턴이 얼마나 유사한지를 측정한다.

두 지표의 차이.

- $D_{\mathrm{JS}}(P^{\mathrm{orig}}_{\mathrm{pitch}} \parallel P^{\mathrm{gen}}_{\mathrm{pitch}})$: 음의 사용 비율 (시간 순서 무시)
- $D_{\mathrm{JS}}(P^{\mathrm{orig}}_{\mathrm{trans}} \parallel P^{\mathrm{gen}}_{\mathrm{trans}})$: 음의 진행 패턴 (시간 순서 반영)

본 연구의 최우수 조합(Tonnetz hybrid + FC, $\alpha = 0.3$)에서 pitch JS divergence는 $D_{\mathrm{JS}} \approx 0.002$를 달성하였다. 이는 가능한 최댓값 $\log 2 \approx 0.693$ (자연로그 기준)의 약 0.3%에 해당하는 값이다.

2.7 Greedy Forward Selection과 Submodularity

정의 2.9. 유한 집합 V에 대한 함수 $f: 2^V \to \mathbb{R}$이 submodular라 함은, 모든 $A \subseteq B \subseteq V$와 $x \in V \setminus B$에 대해 다음이 성립한다는 것이다:

$$f(A \cup \{x\}) - f(A) \geq f(B \cup \{x\}) - f(B)$$

이는 "한계 효용 체감(diminishing returns)" 성질로, 큰 집합에 원소를 추가할 때의 이득이 작은 집합에 같은 원소를 추가할 때의 이득보다 작거나 같다는 것을 의미한다.

정리 (Nemhauser et al., 1978). f가 submodular이고 monotone이며 $f(\emptyset) = 0$일 때, $|S| \leq k$를 만족시키면서 $f(S)$를 최대화하는 문제에 대해 greedy forward selection 알고리즘은 $(1 - 1/e) \approx 0.632$ 근사 보장을 갖는다:

$$f(S_{\mathrm{greedy}}) \geq (1 - \tfrac{1}{e}) f(S^*)$$

여기서 S^*는 최적해이다.

Greedy forward selection 알고리즘:

```
S ←
while |S| < k:
    x* ← argmax_{x   V\S}  f(S   {x}) - f(S)
    S ← S   {x*}
return S
```

본 연구에서의 사용: 발견된 모든 cycle 중에서 위상 구조 보존도가 가장 높은 부분집합을 선택하는 데 사용한다. 보존도 함수 f는 다음과 같이 정의된다:

$$f(S) = w_J \cdot J(S) + w_C \cdot C(S) + w_B \cdot B(S)$$

여기서:

- $J(S)$: Note Pool Jaccard similarity (가중치 $w_J = 0.5$)
- $C(S)$: Overlap pattern correlation (가중치 $w_C = 0.3$)
- $B(S)$: Betti curve similarity (가중치 $w_B = 0.2$)

참고: 본 연구의 보존도 함수는 엄밀히 submodular임이 증명되지는 않았으나, 실험적으로 greedy 방법이 90% 보존도를 작은 k로 달성하는 것을 확인하였다 (예: 46개 cycle 중 15개로 90% 보존).

2.8 Multi-label Binary Cross-Entropy Loss

정의 2.10. Multi-label classification 문제에서, 각 예측 단위마다 여러 클래스가 동시에 정답일 수 있다. 모델 출력 $\hat{y} \in \mathbb{R}^N$을 sigmoid 함수로 [0, 1] 범위로 변환한 후, 각 클래스마다 독립적인 binary cross-entropy를 계산한다:

$$\sigma(z) = \frac{1}{1+e^{-z}}$$

$$\mathcal{L}_{\mathrm{BCE}}(y, \hat{y}) = -\frac{1}{N}\sum_{i=1}^{N}[y_i \log \sigma(\hat{y}_i) + (1-y_i)\log(1-\sigma(\hat{y}_i))]$$

여기서 $y \in \{0,1\}^N$은 정답 multi-hot vector이고, $\hat{y} \in \mathbb{R}^N$은 모델의 logit 출력이다.

본 연구에서의 사용: 각 시점 t에서 동시에 여러 note가 활성화될 수 있으므로, 단일 클래스 예측인 categorical cross-entropy 대신 multi-label BCE를 사용한다. 모델 입력은 중첩행렬의 한 행 $O[t,:] \in \mathbb{R}^C$이고, 출력은 23차원 multi-hot vector $y_t \in \{0,1\}^{23}$이다 (해당 시점의 활성 note 표시).

Adaptive threshold: 학습된 모델이 음악을 생성할 때, sigmoid 출력 $\sigma(\hat{y})$가 일정 임계값 이상인 클래스를 활성으로 판정한다. 본 연구에서는 원곡의 ON 비율(약 15%)에 맞춰 threshold를 동적으로 결정한다:

$$\theta_t = \mathrm{quantile}(\sigma(\hat{Y}),\ 1-0.15)$$

이를 통해 LSTM처럼 sigmoid 출력이 전체적으로 낮은 모델에서도 적절한 수의 음표를 생성할 수 있다.

2.9 음악 네트워크 구축과 가중치 분리

정의 2.11. 음악 네트워크 $G=(V,E)$는 다음과 같이 정의된다:

- Vertex set V: 곡에 등장하는 모든 고유 (pitch, duration) 쌍. hibari의 경우 $|V|=23$.
- Edge set E: 두 vertex가 곡에서 인접하여 등장한 경우 연결.
- Weight function $w: E \to \mathbb{R}_{\geq 0}$: 인접 등장 빈도.

가중치 행렬의 분리 (본 연구의 핵심 설계): 본 연구는 가중치를 다음과 같이 세 가지로 분리한다:

1. Intra weight W_{intra}: 같은 악기 내에서 연속한 두 화음 간 전이 빈도. 두 악기의 intra weight를 합산한다:

$$W_{\mathrm{intra}} = W_{\mathrm{intra}}^{(1)} + W_{\mathrm{intra}}^{(2)}$$

이는 각 악기의 선율적 흐름을 포착한다.

2. Inter weight $W_{\mathrm{inter}}^{(\ell)}$: 시차(lag) ℓ을 두고 악기 1의 화음과 악기 2의 화음이 동시에 출현하는 빈도. $\ell \in \{1,2,3,4\}$로 변화시키며 다양한 시간 스케일의 악기 간 상호작용을 탐색한다.
3. Simul weight W_{simul}: 같은 시점에서 두 악기가 동시에 발음하는 note 조합의 빈도. 순간적 화음 구조를 포착한다.

Timeflow weight (선율 중심 탐색):

$$W_{\mathrm{timeflow}}(r_t) = W_{\mathrm{intra}} + r_t \cdot W_{\mathrm{inter}}$$

$r_t \in [0, 1.5]$를 변화시키며 위상 구조의 출현·소멸을 추적한다.

Complex weight (선율-화음 결합):

$$W_{\mathrm{complex}}(r_c) = W_{\mathrm{timeflow,\,refined}} + r_c \cdot W_{\mathrm{simul}}$$

$r_c \in [0, 0.5]$로 제한하여 "음악은 시간 예술이므로 화음보다 선율에 더 큰 비중을 둔다"는 음악적 해석을 반영한다.

거리 행렬: 가중치 $w(n_i, n_j) > 0$에 대해 거리는 역수로 정의된다:

$$d(n_i, n_j) = 1/w(n_i, n_j) \mathrm{if} w > 0, d_\infty \mathrm{otherwise}$$

여기서 d_∞는 "도달 불가능한 큰 값"으로, $d_\infty = 1 + 2/(\min_{w>0} w \cdot \text{step})$로 계산된다.

참고문헌

- Carlsson, G. (2009). "Topology and data". Bulletin of the AMS, 46(2), 255–308.
- Edelsbrunner, H., & Harer, J. (2010). Computational Topology: An Introduction. AMS.
- Catanzaro, M. J. (2016). "Generalized Tonnetze". arXiv:1612.03519.
- Tymoczko, D. (2012). "The Generalized Tonnetz". Journal of Music Theory, 56(1).
- Tymoczko, D. (2008). "Set-Class Similarity, Voice Leading, and the Fourier Transform". Journal of Music Theory, 52(2).
- Bauer, U. (2021). "Ripser: efficient computation of Vietoris–Rips persistence barcodes". Journal of Applied and Computational Topology, 5, 391–423.
- Nemhauser, G. L., Wolsey, L. A., & Fisher, M. L. (1978). "An analysis of approximations for maximizing submodular set functions". Mathematical Programming, 14(1), 265–294.
- Nielsen, F. (2019). "On the Jensen–Shannon symmetrization of distances". Entropy, 21(5), 485.
- Endres, D. M., & Schindelin, J. E. (2003). "A new metric for probability distributions". IEEE Transactions on Information Theory, 49(7), 1858–1860.
- Tran, M. L., Park, C., & Jung, J.-H. (2021). "Topological Data Analysis of Korean Music in Jeongganbo". arXiv:2103.06620.
- 이동진, Tran, M. L., 정재훈 (2024). "국악의 기하학적 구조와 인공지능 작곡".