# 위상수학적 음악 분석 — Step 3

## 실험 설계와 결과

본 장에서는 지금까지 제안한 TDA 기반 음악 생성 파이프라인의 성능을 정량적으로 평가한다. 세 가지 유형의 실험을 수행하였다.

1. **Distance function 비교** — frequency(기본), Tonnetz, voice-leading, DFT 네 종류의 거리 함수에 대해 동일 파이프라인을 적용하고 생성 품질을 비교.
2. **Cycle subset ablation** — 최적 거리 함수(Tonnetz)에서 cycle 수를 $K = 10, 17, 46$으로 변화시켜 cycle 수의 효과를 분리.
3. **통계적 유의성** — 각 설정에서 Algorithm 1을 $N = 20$회 독립 반복 실행하여 mean ± std를 보고.

모든 실험은 동일한 chord height 패턴 (32-element module × 33 = 1,056 timepoints), 동일 random seed 체계($s = c + i,\ i = 0, \ldots, 19$, 설정별 상수 $c$ 사용)로 수행되었다. 실험 러너는 `tda_pipeline/run_step3_experiments.py`이며, 모든 trial의 상세 기록(mean, std, min, max 포함)은 `tda_pipeline/docs/step3_data/step3_results.json`에 저장되어 있다.

### 평가 지표

**Jensen-Shannon Divergence (주 지표).** 생성곡과 원곡의 pitch 빈도 분포 간 JS divergence를 주 지표로 사용한다 (2.6절 정의). 값이 낮을수록 두 곡의 음 사용 분포가 유사하며, 이론상 최댓값은 $\log 2 \approx 0.693$이다.

**Note Coverage.** 원곡에 존재하는 고유 (pitch, duration) 쌍 중, 생성곡에 한 번 이상 등장하는 쌍의 비율. $1.00$이면 모든 note가 최소 한 번 이상 사용된 것이다.

**보조 지표.** Pitch count (생성곡의 고유 pitch 수), 생성 소요 시간 (초), KL divergence.

### 거리 함수 구현 참고

본 장의 네 가지 거리 함수는 모두 `tda_pipeline/musical_metrics.py` 파일 하나에 정의되어 있다. 사용 패턴은 다음과 같다.

| 함수 | 역할 | 입력 | 출력 |
|---|---|---|---|
| `tonnetz_distance(pc1, pc2)` | 두 pitch class 간 Tonnetz 격자 거리 | `pc1, pc2` $\in \{0, \ldots, 11\}$ | 정수 (최단 경로 길이) |
| `tonnetz_note_distance(n1, n2)` | 두 note 간 거리 (옥타브/duration 보정 포함) | `(pitch, duration)` 튜플 × 2 | 실수 |
| `voice_leading_note_distance(n1, n2)` | 두 note 간 semitone 차이 기반 거리 | `(pitch, duration)` 튜플 × 2 | 실수 |
| `dft_note_distance(n1, n2)` | pitch class DFT 계수 간 Euclidean 거리 | `(pitch, duration)` 튜플 × 2 | 실수 |
| `compute_note_distance_matrix(notes_label, metric)` | 전체 note 집합의 거리 행렬 생성 | `{(pitch,dur): label}` 딕셔너리, metric 이름 | $N \times N$ numpy 행렬 |

__Tonnetz 거리의 핵심 구현 (`_build_tonnetz_distance_table`).__ 12개 pitch class를 정점으로 두고, 장3도(±4 semitone), 단3도(±3), 완전5도(±7) 세 종류의 이웃 관계로 이루어진 무방향 그래프에서 BFS(너비 우선 탐색)로 모든 쌍의 최단 경로를 미리 계산하여 $12 \times 12$ 정수 테이블로 캐싱한다. 이후 `tonnetz_distance(pc1, pc2)`는 이 테이블을 $O(1)$에 조회한다.

**두 note 간 확장.** Tonnetz는 원래 pitch class(mod 12)만 고려하므로 옥타브와 duration 정보가 손실된다. 본 연구는 이를 보완하기 위해

$$d(n_1, n_2) = \text{tonnetz}(p_1 \bmod 12,\ p_2 \bmod 12) + w_o \cdot |o_1 - o_2| + w_d \cdot \frac{|d_1 - d_2|}{\max(d_1, d_2)}$$

로 정의한다 ($w_o = 0.5$, $w_d = 0.3$; $o_i = \lfloor p_i/12 \rfloor$). 이 식이 `tonnetz_note_distance` 함수의 본체이다. 파이프라인에서는 이 함수가 `compute_note_distance_matrix`를 통해 $N \times N$ 거리 행렬로 벡터화되어, 이후 refine 단계(2.2절)와 Vietoris-Rips 복합체 구축(2.1절)에 입력된다.

---

## 3.1 Experiment 1 — Distance Function Baseline 비교

네 종류의 거리 함수 각각으로 사전 계산한 중첩행렬을 로드하여 Algorithm 1을 실행한다. 각 거리 함수에서 발견되는 cycle의 수도 함께 보고한다.

| 거리 함수 | 발견 cycle 수 | JS Divergence (mean ± std) | Note Coverage | 생성 시간 (ms) |
|---|---|---|---|---|
| frequency (baseline) | 43 | $0.0753 \pm 0.0033$ | $0.991$ | $31.2$ |
| Tonnetz | 46 | $0.0398 \pm 0.0031$ | $1.000$ | $38.9$ |
| voice-leading | 22 | $0.0891 \pm 0.0048$ | $1.000$ | $22.2$ |
| DFT | 20 | $0.0511 \pm 0.0029$ | $1.000$ | $26.3$ |

**해석 1 — Tonnetz가 가장 우수.** Tonnetz 거리 함수는 baseline(frequency)에 비해 JS divergence를 $0.0753 \to 0.0398$로 **약** $47\%$ **감소**시켰다. 두 조건의 표준편차가 각각 $0.0033$, $0.0031$로 매우 작으므로, 이 차이는 통계적으로 명확한 개선이다(자세한 분석은 3.3절).

**해석 2 — 거리 함수가 위상 구조 자체를 바꾼다.** 동일한 hibari 데이터에서 거리 함수만 교체했을 뿐인데 발견되는 cycle 수가 $20 \sim 46$으로 크게 달라졌다. 이는 "거리 함수의 선택이 곧 어떤 음악적 구조를 '동치'로 간주할 것인가를 정의한다"는 음악이론적 관점과 일치한다. Tonnetz는 완전 5도 / 장3도 / 단3도 관계의 pitch class 쌍을 가깝게 배치하므로, 이러한 관계를 공유하는 note들이 한 cycle에 더 자주 모이게 된다.

**해석 3 — voice-leading은 cycle을 적게 발견한다.** Voice-leading 거리(반음 수 기반)는 22개의 cycle만 찾아내며 JS divergence도 가장 나쁘다 ($0.0891$). 이는 voice-leading이 "인접 pitch 사이의 거리"를 너무 엄격하게 측정하여, hibari처럼 넓은 음역에 걸쳐 느슨하게 연결된 곡에서는 위상 구조가 적게 드러난다는 것을 시사한다.

**해석 4 — Note Coverage는 대부분의 설정에서 포화.** 네 거리 함수 모두 note coverage가 $0.99 \sim 1.00$이므로, "원곡의 모든 note 종류가 생성곡에 최소 한 번 등장"하는 기본 요구는 모두 만족된다. 따라서 품질의 주된 차이는 "같은 note pool을 얼마나 자연스러운 비율로 섞는가"에서 발생한다.

---

## 3.2 Experiment 2 — Cycle Subset Ablation

거리 함수를 Tonnetz로 고정하고, cycle 수 $K$를 변화시켜 "더 많은 cycle = 더 좋은 생성인가?"를 검증한다. $K = 10$과 $K = 17$은 전체 $46$개 중 처음 $K$개의 cycle(prefix subset)을 사용하였다.

| 설정 | $K$ | JS Divergence | KL Divergence | Note Coverage | 생성 시간 (ms) |
|---|---|---|---|---|---|
| Tonnetz, $K = 10$ | $10$ | $0.0991 \pm 0.0038$ | $0.556 \pm 0.035$ | $0.980$ | $24.4$ |
| Tonnetz, $K = 17$ | $17$ | $0.0740 \pm 0.0038$ | $0.550 \pm 0.344$ | $0.996$ | $26.3$ |
| Tonnetz, $K = 46$ (full) | $46$ | $0.0397 \pm 0.0025$ | $0.172 \pm 0.013$ | $1.000$ | $40.8$ |

**해석 5 — Cycle이 많을수록 JS가 단조 감소.** $K$가 $10 \to 17 \to 46$으로 늘어남에 따라 JS divergence는 $0.099 \to 0.074 \to 0.040$으로 단조 감소하였다. 이는 "위상 구조가 더 풍부하게 드러날수록 생성곡의 음 사용 분포가 원곡에 더 근접한다"는 본 연구의 핵심 가설을 뒷받침한다.

**해석 6 — 한계 효용의 감소.** $K$ 증가에 따른 JS 감소폭을 보면:

- $K = 10 \to 17$: 개선 $\Delta = 0.025$
- $K = 17 \to 46$: 개선 $\Delta = 0.034$

cycle 수가 거의 세 배($17 \to 46$)가 된 것에 비해 개선 폭은 $K = 10 \to 17$(7개 추가)과 크게 차이나지 않는다. 즉 뒤쪽 cycle들은 이미 어느 정도 포화된 구조를 재확인하는 수준의 기여를 한다. 이는 2.7절에서 논의한 greedy forward selection으로 "소수의 cycle로도 $90\%$ 보존"이 가능하다는 관찰과 일관된다.

**해석 7 — KL 분산의 불안정성.** $K = 17$ 설정에서 KL divergence의 표준편차가 $0.344$로 유난히 크다. 이는 일부 trial에서 KL이 $1.55$까지 튀는 경우가 있었기 때문이며 (원본 JSON은 `docs/step3_data/step3_results.json`의 `experiment_2_ablations.subset_K17.kl_divergence.max` 필드에서 확인 가능), "$\log(P/Q)$가 $Q \to 0$에서 발산하는" KL의 구조적 불안정성에서 기인한다. JS divergence는 동일 trial들에서 $0.064 \sim 0.079$ 범위로 안정되어 있어, JS가 더 안정적인 평가 지표임을 재확인한다 (2.6절의 "대칭화와 유계성" 논의와 일관).

---

## 3.3 통계적 유의성 분석

두 baseline 비교 (frequency vs Tonnetz) 의 차이가 통계적으로 유의한지 확인한다. 두 표본의 평균을 비교하는 표준적인 방법은 Student $t$-test이지만, Student의 고전적 $t$-test는 "두 집단의 모분산이 같다"는 강한 가정을 필요로 한다. 본 실험에서 두 조건의 표본표준편차는 $s_1 = 0.0033$, $s_2 = 0.0031$으로 매우 비슷하지만 완전히 같지는 않으며, 모분산이 같다는 사전 근거도 없다. 따라서 등분산 가정을 요구하지 않는 **Welch's $t$-test**를 사용한다. Welch는 "모평균과 모분산을 모를 때 표본평균과 표본분산만으로 검정"이 가능하며, 자유도를 Welch-Satterthwaite 근사로 계산한다.

**데이터.**

- Frequency: $\bar{x}_1 = 0.0753$, $s_1 = 0.0033$, $n_1 = 20$
- Tonnetz: $\bar{x}_2 = 0.0398$, $s_2 = 0.0031$, $n_2 = 20$

**Welch $t$ 통계량** 은 다음과 같이 정의된다:

$$t = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

수치를 대입하면:

$$t = \frac{0.0753 - 0.0398}{\sqrt{\frac{0.0033^2}{20} + \frac{0.0031^2}{20}}} = \frac{0.0355}{\sqrt{1.025 \times 10^{-6}}} \approx 35.1$$

**Welch-Satterthwaite 자유도.** Welch 검정에서 $t$ 통계량은 정확한 Student 분포를 따르지 않고, 다음 식으로 근사된 자유도 $\nu$의 $t$-분포를 따른다:

$$\nu \approx \frac{(\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2})^2}{\frac{(s_1^2/n_1)^2}{n_1 - 1} + \frac{(s_2^2/n_2)^2}{n_2 - 1}}$$

$n_1 = n_2 = 20$이고 두 표본분산이 거의 같으므로 $\nu$는 $\approx n_1 + n_2 - 2 = 38$에 매우 가깝게 나온다. 수치 계산 결과 $\nu \approx 37.9$이며, 반올림하여 $\nu = 38$로 사용한다.

자유도 $\nu = 38$에서 양측 임계값은 $t_{0.001,\,38} \approx 3.56$이므로, $|t| = 35.1 \gg 3.56$이며 $p < 10^{-20}$이다. 따라서 **Tonnetz가 frequency보다 JS divergence를 낮춘 것은 극도로 통계적으로 유의**하다.

**효과 크기 (Cohen's $d$).** $p$-값만으로는 "차이가 실질적으로 얼마나 큰가"를 알 수 없으므로, 표본평균 차를 표본표준편차로 정규화한 Cohen's $d$를 함께 보고한다:

$$d = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{(s_1^2 + s_2^2)/2}}$$

$$d = \frac{0.0355}{\sqrt{(0.0033^2 + 0.0031^2)/2}} \approx 11.1$$

Cohen의 관례상 $d > 0.8$이 "큰 효과"인데 $d \approx 11$은 비교할 수 없는 초대형 효과이다. 두 분포가 실질적으로 분리되어 있음을 의미한다.

---

## 3.3a Experiment 2.5 — Continuous Overlap Matrix 실험

본 절은 2.5절에서 정의한 **연속값 중첩행렬** $O_{\text{cont}} \in [0,1]^{T \times K}$가 이진 중첩행렬 $O \in \{0,1\}^{T \times K}$ 대비 어떤 영향을 주는지를 정량적으로 검증한다. 거리 함수는 모든 설정에서 Tonnetz로 고정한다 (3.1절 결과상 가장 강한 baseline).

### 실험 설계

cycle별 시점 활성도 $a_{c,t}$는 두 가지 방식으로 계산할 수 있다.

**이진 (binary)**: 단순 OR 연산이다. $V(c)$에 속하는 note가 시점 $t$에 하나라도 활성이면 $a_{c,t} = 1$, 그렇지 않으면 $0$이다.

**연속값 (continuous)**: cycle을 구성하는 note 중 얼마나 많은 비율이 활성화되어 있는지를 $[0,1]$ 실수로 표현한다. 분수 형태가 아니라 단일 라인으로 쓰면:

$$a_{c,t} = \Big( \sum_{n \in V(c)} w(n) \cdot \mathbb{1}[n \in A_t] \Big) \Big/ \Big( \sum_{n \in V(c)} w(n) \Big)$$

여기서 $A_t$는 시점 $t$에 활성인 note들의 집합, $w(n) = 1/N_{\text{cyc}}(n)$은 note $n$의 **희귀도 가중치**이며 $N_{\text{cyc}}(n)$은 note $n$이 등장하는 cycle의 개수이다. 적은 cycle에만 등장하는 희귀 note일수록 가중치 $w(n)$이 커져, 그 note가 활성화되면 $a_{c,t}$에 더 큰 기여를 한다.

연속값 활성도가 만들어진 후, 최종 overlap matrix를 만드는 방식에 따라 다시 두 가지 변형이 가능하다.

- **직접 사용 (direct)**: $O[t,c] = a_{c,t} \in [0,1]$
- **임계값 이진화 (threshold $\tau$)**: $O[t,c] = \mathbb{1}[a_{c,t} \geq \tau]$, $\tau \in \{0.3, 0.5, 0.7\}$

이 다섯 가지 설정 (binary 캐시 + continuous direct + 세 가지 임계값) 각각에 대해 Algorithm 1을 $N = 20$회 독립 반복 실행하여 pitch JS divergence를 측정한다. 실험 러너는 `tda_pipeline/run_step3_continuous.py`이며 원본 결과는 `docs/step3_data/step3_continuous_results.json`에 저장되어 있다.

### 결과

| 설정 | Density | JS Divergence (mean ± std) |
|---|---|---|
| (A) Binary (기존 캐시) | $0.751$ | $0.0387 \pm 0.0027$ |
| (B) Continuous direct | $0.264$ | $0.0382 \pm 0.0021$ |
| (C) Continuous → bin $\tau = 0.3$ | $0.373$ | $0.0386 \pm 0.0022$ |

| | | |
|---|---|---|
| **(C) Continuous → bin $\tau=0.5$** | $0.201$ | $0.0343 \pm 0.0027$ |
| (C) Continuous → bin $\tau=0.7$ | $0.077$ | $0.0364 \pm 0.0032$ |

여기서 "Density"는 overlap matrix에서 활성으로 표시되는 셀의 평균 비율 ($\bar{O}$). Binary 캐시는 $0.751$로 매우 dense한 반면, continuous direct는 $0.264$로 훨씬 sparse하다 (희귀도 가중치가 평균값을 낮춘다).

### 해석

**해석 7a — Continuous direct는 binary와 거의 동등.** 단순히 활성도를 그대로 사용한 (B) 설정은 (A) 대비 평균 JS가 약간 낮고 ($0.0382$ vs $0.0387$), 표준편차도 약간 작다 ($0.0021$ vs $0.0027$). 차이는 통계적으로 유의하지 않으며, "연속값을 직접 쓰는 것 자체"는 큰 이득이 없다.

**해석 7b — $\tau=0.5$ 임계값이 최우수.** 흥미롭게도 연속값을 만들어 놓고 다시 $\tau=0.5$로 이진화한 설정이 평균 JS $0.0343$로 가장 좋다. 이는 (A) baseline 대비 약 $11.4\%$ 개선이며, $\tau$ 변화에 대한 모양이 $0.3 \to 0.5$ 구간에서 단조 감소, $0.5 \to 0.7$에서 다시 증가하는 명확한 U자 패턴을 보인다.

이 결과의 음악적 해석은 다음과 같다. 기존 binary overlap (A)는 "한 cycle의 vertex 중 하나라도 활성이면 cycle 전체가 활성"으로 판정하므로 cycle 활성도가 과대평가되며 ($\bar{O}=0.751$), Algorithm 1의 교집합 sampling이 너무 자주 호출되어 다양성이 떨어진다. 반대로 $\tau=0.7$은 너무 까다로워서 cycle 활성 시점이 너무 드물어진다 ($\bar{O}=0.077$). 그 사이의 $\tau=0.5$는 "cycle vertex의 절반 이상이 활성일 때만 그 cycle을 살아 있는 것으로 간주"한다는 음악적으로도 자연스러운 기준이며, 이 sweet spot이 최우수 결과를 만든다.

**해석 7c — Welch $t$-test (binary vs $\tau=0.5$).** 두 설정의 차이가 통계적으로 유의한지 검정한다.

- (A) Binary: $\bar{x}_A=0.0387$, $s_A=0.0027$, $n_A=20$
- (C@$\tau$=0.5): $\bar{x}_C=0.0343$, $s_C=0.0027$, $n_C=20$

$$t=\frac{0.0387-0.0343}{\sqrt{0.0027^2/20+0.0027^2/20}}\approx 5.16$$

자유도 $\nu\approx 38$에서 $t_{0.001,38}\approx 3.56$이므로 $|t|=5.16>3.56$, 즉 $p<0.001$이다. Cohen의 효과 크기 $d\approx 1.63$ ($d>0.8$ "큰 효과" 범주). 따라서 **continuous → $\tau=0.5$ 이진화의 개선은 통계적으로 유의**하다.

이 결과는 본 연구의 향후 방향에 함의를 준다. 본 실험에서는 연속값 overlap matrix의 잠재력을 최소한만 사용했음에도 (단일 임계값 $\tau$ grid search 정도) 이미 약 $11\%$의 추가 개선을 얻을 수 있었으며, 더 정교한 가중치 학습이나 soft activation을 받아들이는 Algorithm 2 변형을 통해 추가 향상이 가능할 것으로 기대된다.

---

## 3.4 Experiment 3 — DL 모델 비교 (참고)

### 왜 $N=20$ 통계적 반복을 수행하지 않았는가

Algorithm 1은 한 번의 실행에 $\sim 50$ ms 만 걸리므로 $N=20$ 반복이 수 초 안에 끝난다. 반면 Algorithm 2의 학습은 한 config 당 $30$ s $\sim 3$ min이 걸리므로, 동일한 수준의 반복 실험을 전체 grid에 대해 수행하려면 수 시간이 필요하다. 본 연구는 대신 다음 두 가지 선행 실험을 수행하였다.

1. **하이퍼파라미터 튜닝 ($30$ 조합, 단일 run).** `run_tuning.py` 스크립트로 FC/LSTM/Transformer 각각에 대해 hidden dim $\in\{64,128,256\}$, learning rate $\in\{0.0005,0.001,0.003\}$, dropout $\in\{0.1,0.3\}$, augmentation 배수 $\in\{5\times,10\times\}$ 조합으로 grid search를 실행하였다. 이 튜닝에서 FC 모델이 top 10을 모두 차지했고, 최적 조합은 `FC / hidden=256 / lr=0.001 / dropout=0.3`으로 validation loss $0.282$, pitch JS divergence $0.0015$를 달성하였다. 튜닝 실험은 각 조합에 대해 $1$회만 수행되었으며, 동일 seed 하에서 결과가 결정적이므로 표준편차 정보는 없다.
2. **본 장에서 보고.** 아래 표는 튜닝에서 얻은 모델별 최우수 구성의 단일 run 결과를 그대로 가져온 것이다.

| 모델 | Validation Loss | Pitch JS Divergence | 생성 note 수 |
|---|---|---|---|

| | | | |
|---|---|---|---|
| FC (hidden=256, lr=0.001, dropout=0.3) | $0.282$ | $0.0015$ | $3{,}754$ |
| LSTM (2-layer, hidden=128) | $0.385$ | $0.0448$ | $3{,}753$ |
| Transformer (2-layer, 4-head, $d_{\text{model}} = 128$) | $0.676$ | $0.0104$ | $3{,}753$ |

향후 $N = 5$ 반복 재검증이 Step 4에서 계획되어 있으나, 본 장에 DL 결과를 먼저 수록한 이유는 두 가지이다. 첫째, 거리 함수 비교 실험(3.1절)이 "Tonnetz가 Algorithm 1에서 우월하다"는 결론을 냈는데, **같은 결론이 DL 기반 Algorithm 2에서도 유효한지**를 동일 장에서 함께 논의해야 연구 전체의 일관성이 드러나기 때문이다(아래 해석 9). 둘째, DL 튜닝의 상위권이 FC 모델로 완전히 쏠린 것은 통계적 반복 없이도 확인되는 정성적 관측이며, 그 현상 자체가 hibari라는 곡의 고유한 성격에서 기인한다는 해석(해석 8)을 제시하기 위해서이다. Step 4의 재검증은 효과 크기의 수치적 안정성을 보강하는 용도이지, 현재 결론 자체를 뒤집기 위한 것이 아니다.

### 해석

**해석 8 — FC가 가장 낮은 JS, 그리고 "Out of Noise"라는 맥락.** 가장 단순한 FC 모델이 가장 낮은 JS divergence를 달성한 것은 얼핏 이상해 보인다. 통상적으로 시퀀스 모델(LSTM / Transformer)이 시간 문맥을 활용해 더 정교한 출력을 낼 것으로 기대되기 때문이다. 그러나 **hibari는 2009년 사카모토 류이치의 앨범 out of noise에 수록된 곡**이며, 이 앨범 자체가 "소음과 음악의 경계를 탐구한다"는 기획 의도로 제작되었다. 앨범의 많은 곡은 전통적 선율 진행을 의도적으로 회피하고, 각 음이 시간적 인과(causality)보다는 공간적 배치에 가까운 방식으로 놓인다.

이 미학적 맥락에서 보면 FC 모델의 우수한 결과는 역설이 아니라 **곡의 성격에 대한 실증**에 가깝다. FC는 시점 $t$의 note를 결정할 때 이전 시점 $t-1, t-2, \ldots$를 전혀 참조하지 않는, 다시 말해 "시간 맥락 없이 각 음을 독립적으로 배치하는" 모델이다. 이것이 LSTM/Transformer보다 원곡에 더 가까운 결과를 내었다는 것은, hibari가 선율적 인과보다는 음들의 비맥락적 배치로 구성되어 있다는 원곡의 작곡적 특성을 모델 선택이 간접적으로 드러낸 셈이다. 즉 FC가 "의미 없이 친 것 같은" 분포가 실제로 원곡과 일치했던 것은, 원곡 자체가 그러한 방식으로 설계되었기 때문이라는 해석이 가능하다.

**해석 9 — Tonnetz + FC 조합의 최고 성능.** Tonnetz hybrid distance ($\alpha = 0.3$) 로 사전 계산한 중첩행렬을 FC 모델에 입력했을 때, 선행 실험에서 pitch JS divergence $\approx 0.003$을 기록하였다 (기준 frequency + FC의 $0.053$ 대비 약 $18$**배 개선**). 이것이 본 연구 전체에서 관측된 최우수 결과이며, Experiment 1의 "Tonnetz가 우수한 구조적 사전"이라는 결론이 DL 기반 생성에서도 유효함을 시사한다.

---

## 3.4a Experiment 4 — 개선 F: Continuous overlap + Algorithm 2 (FC)

§7.1.5 에서 제안된 개선 F — continuous activation matrix 를 Algorithm 2 (DL) 의 입력으로 직접 사용 — 를 구현 및 검증한다. §3.3a 에서 Algorithm 1 에 대해 continuous 변형이 $11\%$ 개선을 주었음을 확인한 바 있는데, 본 절은 동일한 아이디어를 FC 모델에 적용했을 때 얼마나 더 큰 효과가 있는가 를 정량화한다. 실험 러너는 `tda_pipeline/run_improvement_F.py`, 결과는 `docs/step3_data/step_improvementF_results.json` 에 저장되어 있다.

### 실험 설계

FC 모델 (§3.4 최우수 아키텍처: 2-layer, hidden 128, dropout 0.3) 을 고정하고, **학습 입력 데이터만** 두 가지로 바꾸어 비교한다.

**F-bin (baseline)**: 기존 §3.4 와 동일. `build_activation_matrix(continuous=False)` 로 얻은 이진 활성행렬 $X_{\text{bin}} \in \{0,1\}^{T \times K}$ 를 FC 의 입력으로 사용.

**F-cont**: 희귀도 가중치가 적용된 연속값 활성행렬 $X_{\text{cont}} \in [0,1]^{T \times K}$ 를 사용. 구체적으로 $X_{\text{cont}}[t,c] = a_{c,t}$ (§4.3a 에서 정의한 $a_{c,t}$, $w(n) = 1/N_{\text{cyc}}(n)$ 의 희귀도 가중치). 모든 다른 조건 — 모델 아키텍처, learning rate, epochs, batch size, train/valid split — 는 F-bin 과 완전히 동일.

**핵심 관찰**: FC 의 입력층은 `nn.Linear` 이므로 binary 와 continuous 입력 양쪽 모두를 자연스럽게 처리할 수 있다. 즉 본 실험은 모델 변경 없이 데이터 표현만 바꾸었을 때의 효과 를 측정하며, 이는 continuous 버전의 정보 이득을 isolated 하게 평가한다.

각 설정에 대해 서로 다른 torch seed $(8100, 8107, 8114, 8121, 8128)$ 로 $N=5$ 회 학습 + 생성 + JS 측정.

## 결과

| 설정 | JS (mean ± std) | best | validation loss (mean) | coverage |
|---|---|---|---|---|
| **F-bin** (기존 §3.4) | $0.0017 \pm 0.0005$ | $0.0012$ | $0.0929$ | $0.954$ |
| **F-cont ★** | $0.0004 \pm 0.0001$ | $0.0003$ | $0.0401$ | $1.000$ |

**핵심 발견 1: JS divergence 약 $4.25$배 감소.** F-cont 의 평균 JS $0.0004$ 는 F-bin 의 $0.0017$ 대비 약 $76\%$ 감소이다. §3.1 에서 distance function 교체 (frequency $\rightarrow$ Tonnetz) 가 $47\%$ 감소, §3.3a 에서 $\tau=0.5$ 이진화가 추가 $11\%$ 감소를 주었다면, 본 개선 F 는 그 위에 또 한 단계 개선을 쌓아 $0.0017 \rightarrow 0.0004$ **라는 본 연구 최저값** 을 달성한다.

**핵심 발견 2: 분산도 대폭 감소 ( $\sim 5$배).** F-bin 의 표준편차 $0.0005$ 대비 F-cont 는 $0.0001$. 즉 seed 별 결과의 일관성도 크게 개선되었다.

**핵심 발견 3: Validation loss 도 $2.3$배 낮음 ($0.093 \rightarrow 0.040$).** 이는 모델이 학습 자체를 더 잘 한다는 뜻으로, 연속값 표현이 이진화 대비 학습 신호가 더 풍부하고 gradient landscape 이 더 부드러움을 시사한다.

**핵심 발견 4: Note coverage 가 $0.954 \rightarrow 1.000$ 으로 완전화.** F-bin 에서는 일부 rare note 가 생성되지 않는 경우가 있었지만, F-cont 에서는 전체 $23$개 note 가 항상 생성된다. 이는 희귀도 가중치 ($w(n)=1/N_{\text{cyc}}(n)$) 가 의도한 효과 — 희귀 note 에 더 큰 학습 신호 — 가 실제로 작동함을 뒷받침한다.

## 왜 이렇게 큰 개선이 나오는가 — 음악적 해석

**이진화는 "있다/없다" 만 말하지만, 연속값은 "얼마나 확신하는가" 를 말한다.** 이진 $X_{\text{bin}}[t,c]$ 는 "시점 $t$ 에 cycle $c$ 의 vertex 중 하나라도 울리면 $1$"이다. 이것은 cycle $c$ 의 활성 여부에 대해 이진 판정만 내린다. 반면 연속값 $X_{\text{cont}}[t,c]=a_{c,t}$ 는 "cycle $c$ 의 vertex 중 희귀도 가중치 기준으로 몇 퍼센트가 활성인가" 를 $[0,1]$ 실수로 표현한다. 즉 "이 시점에 이 cycle 이 어떤 종류의 note 조합으로 부분적으로 활성화되어 있는가" 라는 훨씬 풍부한 정보를 전달한다.

FC 모델 입장에서 이 차이는 결정적이다. 이진 입력에서 한 cycle 의 활성은 "on/off" 두 상태뿐이지만, 연속 입력에서는 "오직 common note 2 개만 활성 (낮은 값)" vs "rare note 포함 전체가 활성 (높은 값)" 같은 구별이 가능해진다. FC 가 이 구별을 학습하여 output note 분포를 조정할 수 있기 때문에, 원곡의 pitch 분포에 더 가까운 결과가 나온다.

## 기존 모든 결과와의 통합 비교

| 실험 | 설정 | JS divergence | 출처 |
|---|---|---|---|
| §3.1 Algo 1 | frequency baseline | $0.0753$ | §3.1 |
| §3.1 Algo 1 | Tonnetz hybrid | $0.0398$ | §3.1 |
| §3.3a Algo 1 | Tonnetz + continuous $\tau=0.5$ | $0.0343$ | §3.3a |
| §7.1.6 Algo 1 | P4 + C (module-level) | $0.0590$ | §7.1.6 |
| §7.1.8 Algo 1 | P4 + C, best trial (seed 9302) | $0.0258$ | §7.1.8 |
| §3.4 Algo 2 FC | Tonnetz binary | $0.0017$ | §3.4a (본 절) |
| **§3.4a Algo 2 FC** | **Tonnetz continuous** | $0.0004 \pm 0.0001$ | **본 절 ★** |

**§3.4a (개선 F) 는 본 연구 전체에서 관측된 최저 JS divergence** 이며, 이론적 최댓값 $\log 2 \approx 0.693$ 의 약 $0.06\%$ 에 해당한다. 이는 §2.6 JS divergence 절에서 보고한 " $0.002$, 가능한 최댓값의 $0.3\%$ " 수치보다도 5배 낮다.

### 한계 및 후속 과제

1. **학습 시 분산이 충분히 측정되었는가**: $N=5$ 는 §3.1 의 $N=20$ 에 비해 적다. FC 학습이 빠르므로 $N=20$ 재확장이 비교적 쉽게 가능하다.
2. **LSTM / Transformer 에도 F-cont 적용**: 본 절은 FC 만 다루었다. §3.4 에서 관찰한 "FC > LSTM/Transformer" 패턴이 continuous 입력에서도 유지되는지 검증해야 한다.
3. **Continuous + module-local (P4)**: §7.1 의 P4 + C 와 개선 F 를 결합하여 "module-local continuous activation 을 FC 에 입력" 하는 실험도 의미가 있다.

---

## 3.5 종합 논의

**(1) 음악이론적 거리 함수의 중요성.** Experiment 1의 결과는 "빈도 기반 거리(frequency)는 기본 선택일 뿐, Tonnetz처럼 음악이론적 구조를 반영한 거리가 훨씬 더 좋은 위상적 표현을 만든다"는 본 연구의 가설을 강하게 지지한다. frequency → Tonnetz 전환만으로 JS divergence가 $47\%$ 감소했다.

**(2) Cycle 수의 효과는 단조 증가이나 점진적.** Experiment 2는 "cycle 수가 많을수록 좋다"는 기대를 확인하였으나, 한계 효용이 감소함을 보였다. 이는 $K$를 무작정 늘리기보다 greedy forward selection (2.7절) 으로 소수의 핵심 cycle을 고르는 전략이 실용적임을 시사한다.

**(3) 통계적 엄밀성.** 각 설정에서 $N=20$ 반복을 통해 표준편차가 $\sim 0.003$ 수준임을 확인하였으며, 주요 baseline 비교의 Welch $t$ 값이 $>35$으로 매우 유의했다. 이는 본 연구의 결론이 random seed에 의존하는 artifact가 아님을 보장한다.

**(4) 곡의 맥락과 모델 선택.** FC가 시퀀스 모델을 능가한 해석 8의 관찰은, 모델의 성능이 단순히 "표현력이 높을수록 좋다"는 법칙을 따르지 않고 **원곡의 미학적 설계와 공명하는 모델**이 가장 좋은 결과를 낸다는 것을 보여준다. 이는 본 연구가 다른 곡(예: 전통적 선율 진행이 뚜렷한 클래식 작품)으로 확장될 때 시퀀스 모델의 우위가 뒤바뀔 수 있음을 암시한다.

**(5) 향후 과제.**

1. DL 모델 comparison을 $N=5$ 이상 반복으로 재검증 (효과 크기 수치 안정화)
2. Ablation에서 prefix subset 대신 greedy selected subset으로 재실행하여 "어떤 cycle이 선택되는지"의 효과 분리
3. Tonnetz hybrid의 $\alpha$ 값 ($0.0, 0.3, 0.5, 0.7, 1.0$) 에 대한 grid search
4. 다른 곡(Ravel, Debussy, 또는 out of noise 앨범의 다른 곡) 으로의 일반화 검증 — 해석 8의 "곡의 미학이 모델 선택을 결정한다"는 가설 검증

---

## 3.6 곡 고유 구조 분석 — hibari 의 수학적 불변량

본 절은 hibari 가 가지는 수학적 고유 성질을 분석하고, 이 성질들이 본 연구의 실험 결과와 어떻게 연결되는지를 서술한다. 비교 대상으로 사카모토의 다른 곡인 solari 와 aqua 를 함께 분석한다.

### 3.6.1 Deep Scale Property — hibari 의 pitch class 집합이 갖는 대수적 고유성

hibari 가 사용하는 7개 pitch class 는 $\{0,2,4,5,7,9,11\} \subset \mathbb{Z}/12\mathbb{Z}$이다 (C major / A natural minor scale). 이 집합의 **interval vector** — 각 음정 클래스(1~6 반음)가 집합 안에서 몇 번 등장하는지를 센 벡터 — 는 $[2,5,4,3,6,1]$ 이다.

이 벡터의 6개 성분이 **모두 다른 수**이다 ($\{1,2,3,4,5,6\}$의 순열). 이것을 **deep scale property** 라 한다 (Gamer & Wilson, 2003). 이 성질을 갖는 7-note subset 은 $\binom{12}{7}=792$개 중 **diatonic scale 류 (장/단음계, 교회 선법) 뿐**이다.

즉 hibari 가 7개 PC 를 선택한 것은 임의가 아니라, 12음 체계에서 **각 음정 클래스가 고르게 (그러면서도 모두 다른 횟수로) 등장하는 유일한 부분집합**을 선택한 것이다.

또한 7개 PC 사이의 간격 패턴은 $[2,2,1,2,2,2,1]$로, 오직 $\{1,2\}$ 두 종류의 간격만으로 구성된다. 이것은 **maximal evenness** — 12개 칸 위에 7개 점을 가능한 한 균등하게 배치한 상태 — 를 의미한다 (Clough & Douthett, 1991). deep scale 과 maximal evenness 는 모두 diatonic scale 의 고유 성질이다.

solari 와 aqua 는 12개 PC 모두를 사용하므로 이 성질이 적용되지 않는다.

### 3.6.2 근균등 Pitch 분포 — Pitch Entropy

| 곡 | 사용 pitch 수 | 정규화 pitch entropy | 해석 |
|---|---|---|---|
| **hibari** | $17$ | $0.974$ | 거의 완전 균등 |
| solari | $34$ | $0.905$ | 덜 균등 |
| aqua | $51$ | $0.891$ | 가장 치우침 |

pitch entropy 는 곡 안에서 사용된 모든 pitch 의 빈도 분포에 대한 Shannon entropy 를 계산하고, 이론적 최댓값 $\log_2(\mathrm{uniquepitchcount})$ 로 나눠 정규화한 것이다. $1.0$이면 모든 pitch 가 완전히 동일한 빈도로 등장하고, $0$에 가까우면 한두 개 pitch 가 지배적이다.

hibari 의 $0.974$ 는 **"모든 pitch 를 거의 같은 빈도로 사용"**한다는 뜻이며, 전통 조성 음악에서는 매우 드문 수치이다 (으뜸음이 지배적인 것이 보통). 이 성질은 **§3.4 의 "FC 모델 우위"를 수학적으로 설명**한다. pitch 분포가 거의 균등하면, 시간 순서를 무시하고 그 분포에서 독립적으로 뽑는 것 (FC 의 행동) 이 이미 원곡의 분포에 가깝다. 반면 solari 같이 특정 pitch 가 더 자주 나오는 곡에서는 시간 맥락 (Transformer) 이 그 편향을 학습해야 하므로 FC 가 불리하다.

### 3.6.3 Tonnetz 구별력과 Pitch Class 수의 관계

hibari 의 7개 PC 는 Tonnetz 위에서 **하나의 연결 성분**을 이루며, 평균 degree 가 $3.71/6 = 62\%$이다. 이것은 7개 PC 안에서 Tonnetz 이웃 관계가 매우 밀집되어 있다는 뜻이다.

그런데 왜 이것이 중요한가? Tonnetz 거리의 핵심은 "이 두 음이 화성적으로 얼마나 가까운가"를 숫자로 말해주는 것이다. 이 구별력은 **PC 수가 적을수록 강해진다**. 다음 비유가 도움이 된다:

> 7명이 모여 사는 작은 마을에서 "누구와 누가 친한가"를 물으면 의미 있는 답이 나온다 (어떤 쌍은 친하고, 어떤 쌍은 아니므로). 그러나 12명이 모두 사는 세계에서 "누구와 누가 친한가"를 물으면 "다 친하다" 에 가까운 답이 나온다.

구체적으로:

- **hibari (7 PC)**: Tonnetz 거리가 $1 \sim 4$ 범위로 분포하여, "가까운 쌍"과 "먼 쌍"이 명확히 구별됨 → Tonnetz 가 위상 구조를 선명하게 포착
- **solari / aqua (12 PC)**: 모든 PC 가 Tonnetz 에 있으므로 대부분의 쌍이 거리 $1 \sim 2$ 안에 있어 구별력이 사라짐 → voice-leading (반음 거리) 같은 더 세밀한 거리가 유효

이것이 **"hibari 에서 Tonnetz 최적, solari 에서 voice-leading 최적"**(§3.1 vs §7.2)의 구조적 근거이다.

### 3.6.4 Cycle 교차 밀도 — $77\%$

Tonnetz 기반으로 발견된 46개 $H_1$ cycle 중, 쌍별 교집합을 계산하면 $\binom{46}{2} = 1{,}035$ 쌍 가운데 $797$ 쌍 ($77\%$) 이 적어도 하나의 vertex 를 공유한다. 즉 cycle 들이 독립적으로 흩어져 있는 것이 아니라 **"그물처럼 촘촘히 엮여 있다"**.

이 높은 교차 밀도는 두 가지 실험 결과와 직접 연결된다.

**(a) Greedy selection 의 효과.** 46개 cycle 이 서로 많은 vertex 를 공유하므로, 소수의 cycle 만 선택해도 전체 note pool 의 대부분을 커버할 수 있다. 실제로 §2.7 에서 15개 cycle ( $\sim 33\%$) 만으로 $90\%$ 보존도를 달성한 것이 이 구조적 중복성 덕분이다.

**(b) Algorithm 1 의 교집합 규칙이 잘 작동하는 이유.** Algorithm 1 은 "활성 cycle 들의 교집합"에서 음을 뽑는데 (§2.10 규칙 1), 만약 cycle 들이 vertex 를 거의 공유하지 않으면 교집합이 항상 빈 집합이 되어 이 규칙이 작동하지 않는다. $77\%$ 의 쌍이 vertex 를 공유하므로 교집합이 비어있지 않을 확률이 높고, 교집합에서 뽑힌 음은 "여러 cycle 이 공통으로 중요하게 여기는 음"이라는 구조적 의미를 갖는다.

### 3.6.5 세 곡의 비교 요약

| 불변량 | hibari | solari | aqua | 실험적 결과 연결 |
|---|---|---|---|---|
| Deep scale | **YES** | no | no | — (diatonic 고유) |
| Maximal evenness | **YES** | no | no | — (diatonic 고유) |
| 정규화 pitch entropy | $0.974$ | $0.905$ | $0.891$ | FC 우위 (hibari) vs Transformer 우위 (solari) |
| Tonnetz 평균 degree (7-PC 한정) | $3.71/6$ | (trivial) | (trivial) | Tonnetz 최적 (hibari) vs voice-leading 최적 (solari) |
| Cycle 교차 밀도 | $77\%$ | (미측정) | (미측정) | Greedy 효율 + 교집합 규칙 작동 |

**핵심 주장.** hibari 의 수학적 고유성은 크게 두 축으로 이뤄진다.

1. **선택의 절제** — 12개 PC 중 7개만 쓰되, 그 7개가 deep scale + maximal evenness 를 만족하는 유일한 부분집합
2. **사용의 균등** — 선택된 7개 안에서 어느 하나를 중심으로 두지 않고 거의 동등하게 사용 (entropy $0.974$)

이 두 축이 "out of noise" 의 기획 의도 — "소음과 음악의 경계" — 를 정확히 수학적으로 구현한다. 소음은 모든 주파수가 동등한 것이고, 전통 음악은 으뜸음이 지배하는 것인데, hibari 는 **diatonic 구조 안에서 가능한 한 균등한 중간 지점**에 위치한다. 그리고 이 위치가 본 연구의 모든 실험 결과 — Tonnetz 우위, FC 우위, 높은 cycle 교차 밀도 — 의 구조적 원인이다.

---

## 참고문헌 (Step 3 추가분)


- Welch, B. L. (1947). "The generalization of 'Student's' problem when several different population variances are involved". Biometrika, 34(1/2), 28-35.
- Satterthwaite, F. E. (1946). "An approximate distribution of estimates of variance components". Biometrics Bulletin, 2(6), 110-114.
- Cohen, J. (1988). Statistical Power Analysis for the Behavioral Sciences (2nd ed.). Lawrence Erlbaum.
- Tymoczko, D. (2011). A Geometry of Music: Harmony and Counterpoint in the Extended Common Practice. Oxford University Press.
- Sakamoto, R. (2009). out of noise [Album]. commmons.