3. 두 가지 음악 생성 알고리즘

표기 정의

별도의 서술이 없을 시 본 논문에서 사용할 표기는 다음과 같이 통일되며 이는 DFT를 거리함수 baseline으로 하여 정해진 값이다.

기호 및 용어	의미	hibari 값
T	시간축 길이 (8분음표 단위)	$1{,}088$
N	고유 note 수 (pitch-duration 쌍)	23
C	발견된 전체 cycle 수	14
K	분석에 사용한 cycle 수	14
O	OM, $\{0,1\}$ 값의 $T \times K$ 행렬	—
L_t	시점 t에서 추출할 note 개수	$3 \sim 4$
$V(c)$	cycle c의 note 집합	원소 수 $4 \sim 6$
R	재샘플링 최대 시도 횟수	50
B	학습 미니배치 크기	32
E	학습 epoch 수	200
H	DL 모델의 hidden dimension	128
module	hibari 반복 선율 단위 (A-B-A'-C)	inst 1에서 33회, inst 2에서 32회 반복

3.1 Algorithm 1 — 확률적 샘플링 기반 음악 생성

> **참고:** Algorithm 1의 샘플링 규칙 1, 2는 선행연구(정재훈 외, 2022)에서 설계된 것이며, 본 연구는 이를 계승하여 사용한다.

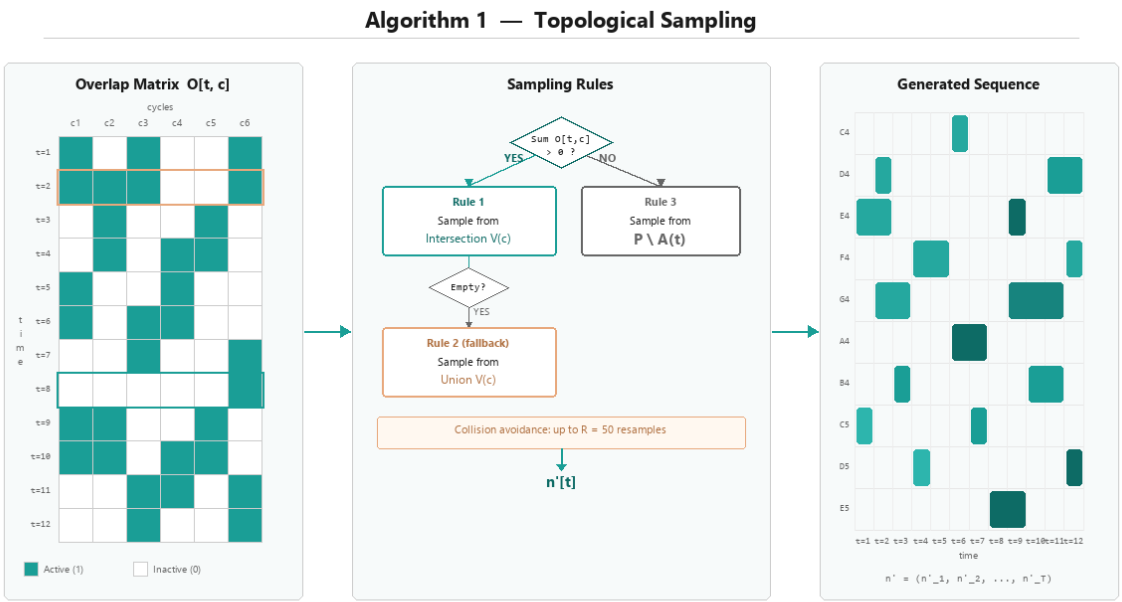

핵심 아이디어 (3가지 규칙)

규칙 1 — 시점 t에서 활성 cycle이 있는 경우, 즉

$$\sum_{c=1}^{K} O[t, c] > 0$$

일 때, 활성화되어 있는 모든 cycle들의 note 교집합 $I(t)$에서 note 하나를 균등 추출한다. 만약 교집합이 공집합이면, 활성 cycle들의 합집합 $U(t)$에서 note 하나를 균등 추출한다.

$$I(t) = \bigcap_{c\,:\,O[t,c]=1} V(c), \qquad U(t) = \bigcup_{c\,:\,O[t,c]=1} V(c)$$

규칙 2 — 시점 t에서 활성 cycle이 없는 경우, 즉

$$\sum_{c=1}^{K} O[t, c] = 0$$

일 때, 인접 시점 $t-1, t+1$에서 활성화된 cycle들의 note의 합집합

$$A(t) = \bigcup_{c\,:\,O[t-1,c]=1} V(c) \cup \bigcup_{c\,:\,O[t+1,c]=1} V(c)$$

을 계산한 뒤, 전체 note pool P에서 이 합집합을 제외한 영역 $P \setminus A(t)$에서 균등 추출한다.

규칙 3 — 중복 onset 방지. 같은 시점 t에서 동일한 (pitch, duration) 쌍이 두 번 추출되지 않도록 검사하며, 충돌이 발생하면 최대 R회까지 재샘플링한다. R회 모두 실패하면 그 시점의 해당 note 자리는 비워둔다.

3.2 Algorithm 2 — 신경망 기반 시퀀스 음악 생성

> **참고:** Algorithm 2의 전체 구조는 아래 그림에 시각적으로 요약되어 있다. FC / LSTM / Transformer 세 아키텍처 중 하나를 선택하여 사용한다.

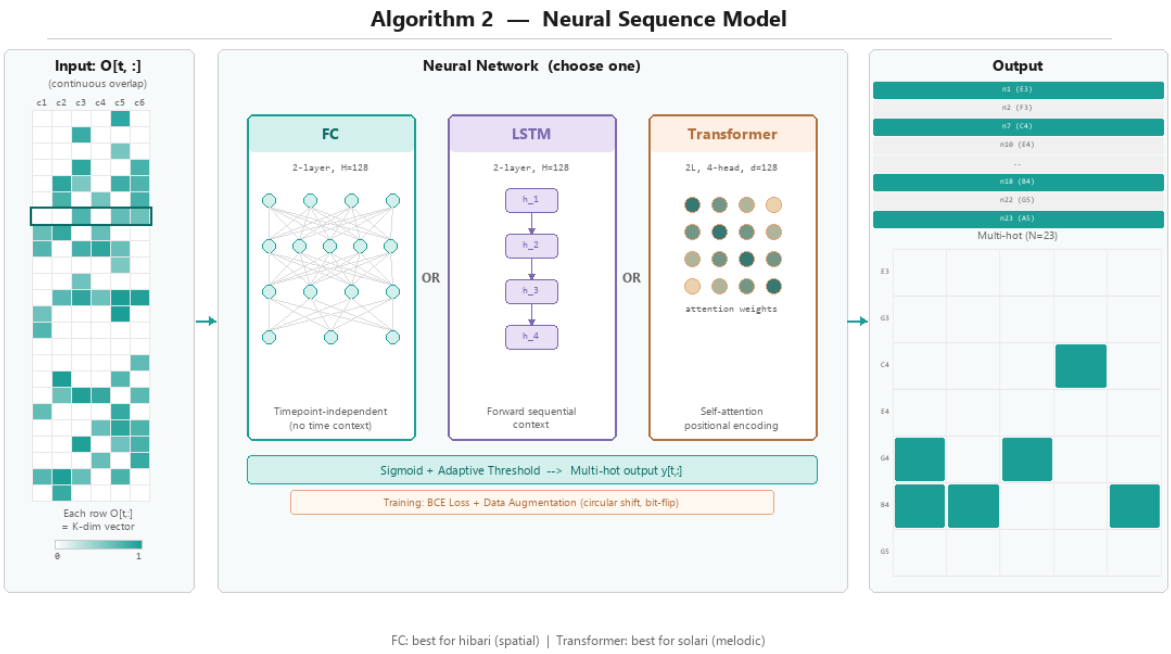

알고리즘 개요

Algorithm 2는 OM을 입력, 원곡의 multi-hot note 행렬을 정답 레이블로 두고 매핑

$$f_\theta : \{0,1\}^{T\times C} \longrightarrow \mathbb{R}^{T\times N}$$

을 학습한다 (FC 모델은 시점별 독립이므로 $\{0,1\}^C \to \mathbb{R}^N$). 학습된 모델은 학습 중 접하지 않은 cycle subset 크기(예: 학습 K 범위 밖의 K')나 threshold / 시간 재배치로 변형된 OM에 대해서도 원곡과 닮은 note 시퀀스를 출력하도록 기대된다 — 단, 같은 cycle set 위에서의 변형에 한정된 일반화임을 유의한다.

DL 모델은 Algorithm 1처럼 "교집합 규칙"으로 위상구조를 직접 강제하지는 않는다. 대신 $K \in \{10, 15, 20, 30, 46\}$과 같은 다양한 크기의 subset에 대해서도 같은 원곡 y를 복원하도록 학습한다. 이 과정에서 모델은 "서로 다른 cycle subset이 같은 음악을 유도할 때, 그 공통적인 구조적 특성"을 잠재 표현으로 내부화한다. 따라서 학습 시 구체적으로 보지 못한 subset(예: $K=12$)에 대해서도, 모델이 학습한 잠재 표현이 충분히 일반화되어 있다면 합리적 출력이 가능하다. 그러나 이 일반화는 동일 cycle set 위에서 변형된 OM(subset 선택, threshold 변경, 시간 재배치 등)에 한정된다. 새로운 cycle set(거리 함수 변경, 다른 곡)이 입력되면 재학습이 필요하다.

모델 아키텍처 비교

본 연구는 동일한 학습 파이프라인 위에서 세 가지 모델 아키텍처를 비교한다.

모델	입력 형태	시간 정보 처리 방식	파라미터 수
FC	(B, C)	시점 독립	4×10^4
LSTM (2-layer)	(B, T, C)	순방향 hidden state	2×10^5
Transformer (2-layer, 4-head)	(B, T, C)	self-attention	4×10^5

표기 설명: B는 batch size(한 번에 묶어서 학습하는 데이터 개수), T는 시간 길이(timestep 수), C는 cycle 수(OM의 열 수)이다.

FC: 시점을 독립적으로 처리하므로 한 번에 시점 하나씩(C차원 벡터)을 입력받아 (B, C) 형태가 된다. 여기서 B는 T개 시점 중 묶어서 처리하는 수이며 기본값 $B=32$이다.

LSTM/Transformer: 곡 전체 시퀀스를 한 번에 입력받으므로 (B, T, C) 형태가 된다. 단, $T=1{,}088$이 batch size $(=32)$보다 크므로 ($\lfloor 32/1{,}088 \rfloor = 0$) 실제로는 한 번에 시퀀스 1개씩 처리된다 ($B=1$). Augmentation으로 생성된 변형본들은 배치 크기를 늘리는 것이 아니라, epoch 내 학습 스텝 수를 늘린다.

학습 손실 함수

§2.8에서 정의한 binary cross-entropy 손실을 사용한다.

추론 단계

학습이 끝난 모델 f_{θ^*}로 새로운 음악을 생성하는 단계를 하나하나 풀어 설명한다.

1단계 — 모델 통과 : logit 생성.

2단계 — sigmoid 변환.

3단계 — adaptive threshold 결정. 가장 단순한 방법은 " $P[t,n] \geq 0.5$이면 켠다"라고 고정 임계값을 쓰는 것이다. 그러나 LSTM이나 Transformer 같은 시퀀스 모델은 sigmoid 출력이 전반적으로 낮게 형성되는 경향이 있어, 0.5를 그대로 쓰면 활성화되는 note가 거의 없어 음악이 텅 비어버린다. 이를 해결하기 위해 본 연구는 원곡의 ON ratio에 맞춰 threshold를 데이터 기반으로 동적 결정한다.

ON ratio란 "원곡의 multi-hot 행렬 $y \in \{0,1\}^{T\times N}$에서 전체 $T\times N$개의 셀 중 값이 1인 셀의 비율"을 뜻한다. 수식으로는

$$\rho_{\text{on}} = \frac{1}{T\cdot N}\sum_{t=1}^{T}\sum_{n=1}^{N} y[t,n]$$

이다. hibari의 경우 $T = 1{,}088$, $N = 23$이므로 전체 셀 수는 약 $25{,}024$개이고, 그 중 note가 활성인 셀 수를 세어 나누면 약 15%($\rho_{\text{on}} \approx 0.15$)가 된다. 직관적으로는 "한 시점당 23개 note 중 평균 $3 \sim 4$개가 켜져 있는 정도"라고 이해할 수 있다. 이 ρ_{on}을 목표 활성 비율로 삼아, P의 모든 값 중 상위 15%에 해당하는 경계값 θ를 임계값으로 쓴다.

4단계 — note 활성화 판정. 모든 (t, n) 쌍에 대해 $P[t, n] \geq \theta$이면 시점 t에 note n을 활성화한다. 이 note의 (pitch, duration) 정보를 label 매핑에서 복원하여 $(t,\ \text{pitch},\ t + \text{duration})$ 튜플을 결과 리스트 G에 추가한다.

5단계 — onset gap 후처리 (Algorithm 1, 2 공통). 너무 짧은 간격으로 onset이 연속되면 생성된 음악이 지저분하다고 느껴질 수 있다. 그럴 땐 "이전 onset으로부터 일정 시점 안에는 새 onset을 허용하지 않는다"는 최소 간격 제약을 적용한다. 본 연구에선 별도의 제약을 두지 않았다.

이 과정으로 최종적으로 얻은 $G = [(start, pitch, end), \ldots]$를 MusicXML로 직렬화하면 재생 가능한 음악이 된다.

3.3 두 알고리즘의 비교 요약

항목	Algorithm 1 (Sampling)	Algorithm 2 (DL)
학습 필요 여부	불필요	필요 (E epoch)
결정성	확률적 (난수)	결정적 (학습 후)
위상 보존 방식	직접 (교집합 규칙으로 강제)	간접 (손실함수를 통해)
생성 시간	약 50 ms	약 100 ms (학습 후)
학습 시간	해당 없음	30 s ~ 3 min

해석. Algorithm 1은 cycle 교집합 규칙을 통해 위상 정보를 직접 강제하므로, 생성된 note의 근거가 "시점 t에 활성화된 cycle들의 교집합"이라는 구조적 규칙으로 투명하게 설명된다 — 설계상 위상 보존이 보장된다. 반면 Algorithm 2는 OM → note 매핑을 학습된 손실함수를 통해 간접적으로 위상을 보존하며 분포의 재현 정확도(§2.6 JS divergence)가 훨씬 높다: 즉 두 알고리즘은 **위상구조 보존 방식의 투명성**(Algorithm 1)과 **note 분포의 재현 정확도**(Algorithm 2)라는 서로 다른 장점이 있다.