4. 실험 설계와 결과

본 장에서는 지금까지 제안한 TDA 기반 음악 생성 파이프라인의 성능을 **정량적으로** 평가한다.

1. **거리 함수 비교** — frequency(기본), Tonnetz, voice leading, DFT 네 종류의 거리 함수에 대해 동일 파이프라인을 적용하고 생성 품질을 비교 (§4.1).
2. **연속값 OM 효과 검증** — 이진 OM 대비 연속값 OM의 효과를 Algorithm 1 및 Algorithm 2 (FC/LSTM/Transformer)에서 검증 (§4.2, §4.3).
3. **DL 모델 비교** — FC / LSTM / Transformer 세 아키텍처를 동일 조건에서 비교하고, 연속값 OM을 직접 입력으로 활용하는 효과를 검증 (§4.3).
4. **통계적 유의성** — 각 설정에서 Algorithm 1을 $N=20$회 독립 반복 실행하여 mean ± std를 보고한다. Algorithm 2는 학습 시간을 고려해 $N=10$회로 수행한다.

평가 지표

Jensen-Shannon Divergence. 생성곡과 원곡의 pitch 빈도 분포 간 JS divergence를 주 지표로 사용한다 (§2.6).

Note Coverage. 원곡에 존재하는 고유 (pitch, duration) 쌍 중, 생성곡에 한 번 이상 등장하는 쌍의 비율. 1.00이면 모든 note가 최소 한 번 이상 사용된 것이다.

거리 함수 구현

두 note 간 확장 — 옥타브와 duration 보정. §2.4의 음악적 거리 함수들은 원래 pitch class만 고려하므로 옥타브와 duration 정보가 손실된다. 본 연구에서 note는 (pitch, duration) 쌍으로 정의되므로, 세 거리 함수 모두에 다음 두 항을 추가한다.

$$d(n_1, n_2) = d_{\text{base}}(p_1, p_2) + w_o \cdot |o_1 - o_2| + w_d \cdot \frac{|d_1 - d_2|}{\max(d_1, d_2)}$$

여기서 d_{base}는 Tonnetz / voice leading / DFT 중 하나, $o_i = \lfloor p_i/12 \rfloor$는 옥타브 번호, d_i는 duration이다.

각 항의 설계 근거:

- **옥타브 항** $w_o|o_1 - o_2|$: 같은 pitch class라도 옥타브가 다르면 음악적으로 다른 역할을 한다(예: C4와 C5).
- **Duration 항** $w_d|d_1 - d_2|/\max(d_1, d_2)$: 분자를 $\max$로 정규화하여 $[0, 1]$ 범위로 만든다.
- **계수 최적화:** $w_o = 0.3$ (§4.1a)과 $w_d = 1.0$ (§4.1b)은 hibari DFT 조건 N=10 grid search로 최적화되었다.

> **한계 및 후속 과제 — duration tie 정규화로 인한 w_d 해석의 제약.** 본 연구는 hibari를 제외한 모든 곡에서 note를 최소 duration으로 정규화했다. 이 과정에서 긴 음은 붙임줄(tie)로 연결된 여러 짧은 음들로 환원되므로 원 악보의 duration 다양성이 축소된다. §4 이후 일반화 실험(§5.1~§5.2)을 제외하고는 정규화가 적용되지 않는다. aqua·solari에서는 note 수를 줄이기 위해 tie 정규화를 적용하여 모든 duration이 GCD 단위(=1)로 수렴하므로 $|d_1 - d_2| = 0$이 되어 duration 항이 비활성화된다. 결과적으로 원곡의 리듬·지속 구조를 재현하는 음악을 생성할 수 없으며, **원 duration을 보존하면서도 계산 복잡도를 낮게 유지하는 파이프라인 설계는 후속 과제**로 남긴다.

4.1 Experiment 1 — 거리 함수 비교 ($N=20$)

네 종류의 거리 함수 각각으로 사전 계산한 OM을 로드하여, Algorithm 1을 $N=20$회 독립 반복 실행하고 JS divergence의 mean ± std를 측정한다.

거리 함수	발견 cycle 수	평균 cycle 크기	JS Divergence (mean ± std)	Note Coverage
frequency (baseline)	1	4.0	0.0344 ± 0.0023	0.957
Tonnetz	47	6.3	0.0493 ± 0.0038	1.000

voice leading	19	4.6	0.0566 ± 0.0027	0.989
DFT	17	4.8	0.0213 ± 0.0021	1.000

해석 1 — DFT가 가장 우수. DFT 거리 함수는 frequency 대비 JS를 $0.0344 \to 0.0213$으로 낮추어 약 38.2% 낮은 JS를 달성하였다. DFT 거리는 각 note의 pitch class를 $\mathbb{Z}/12\mathbb{Z}$ 위의 12차원 이진 벡터로 표현한 후 이산 푸리에 변환(DFT)을 적용하고, 복소수 계수의 **magnitude(크기)만** 거리 계산에 사용한다. 이조(transposition)는 DFT 계수의 **phase(위상)**만 바꿀 뿐 magnitude에는 영향을 주지 않는다. 이렇게 phase 정보를 버리고 magnitude만 고려함으로써 이조에 불변인 **화성 구조의 지문**을 추출하게 된다.

특히 $k=5$ 푸리에 계수가 diatonic scale과 강하게 반응하는 이유는 다음과 같다. 12개 pitch class를 **완전5도 순환(circle of fifths)** 순서 $\{C, G, D, A, E, B, F\sharp, C\sharp, G\sharp, D\sharp, A\sharp, F\}$로 재배열하면, diatonic scale에 속하는 7개 pitch class는 이 순환 상의 **연속된 7개 위치**를 차지한다. DFT의 $k=5$ 계수의 magnitude는 정확히 이 "5도 순환 상의 연속성"을 수치로 측정하는 양이며, $\binom{12}{7}=792$개의 7-note subset 중 diatonic scale 류가 $|F_5|$를 최대화한다 (§4.5.1 maximal evenness). hibari의 7개 PC 집합 $\{0, 2, 4, 5, 7, 9, 11\}$ (C major / A natural minor) 역시 이 최대화 subset 중 하나이므로, DFT magnitude 공간에서 hibari의 note들은 frequency 거리에서는 포착되지 않던 **음계적 동질성**에 의해 서로 가깝게 군집된다.

해석 2 — 거리 함수가 위상구조 자체를 바꾼다. 거리 함수의 선택이 곧 어떤 음악적 구조를 동치로 간주할 것인가를 정의한다.

해석 3 — Note Coverage는 대부분의 설정에서 포화. 원곡의 모든 note 종류가 생성곡에 최소 한 번 등장해야 한다는 기본 요구는 모두 만족된다. 따라서 품질의 주된 차이는 같은 note pool을 얼마나 자연스러운 비율로 섞는가에서 발생한다.

4.1a Octave Weight 튜닝 — DFT + N=10 Grid Search

DFT 거리 함수의 옥타브 가중치 w_o를 $\{0.1, 0.3, 0.5, 0.7, 1.0\}$에 대해 hibari Algo1 JS로 $N=10$ 반복 실험하였다. $w_d=1.0$ (§4.1b 최적값) 고정.

w_o	K (cycle 수)	JS (mean ± std)
0.1	14	0.0380 ± 0.0026
0.3	**19**	0.0163 ± 0.0014
0.5	16	0.0183 ± 0.0020
0.7	16	0.0231 ± 0.0019
1.0	16	0.0204 ± 0.0020

결론: $w_o=0.3$이 최적이다 (JS = 0.0163). 옥타브 패널티를 줄이면 pitch class 유사성이 거리 행렬을 더 강하게 지배하며, 이는 hibari의 좁은 옥타브 범위(52–81, 최대 2 옥타브)에서 옥타브 구분이 상대적으로 덜 중요하다는 음악적 직관과 일치한다.

4.1b Duration Weight 튜닝 — DFT + N=10 Grid Search

DFT 거리 함수의 duration 가중치 w_d를 $\{0.0, 0.1, 0.3, 0.5, 0.7, 1.0\}$에 대해 hibari Algo1 JS로 $N=10$ 반복 실험하였다. $w_o=0.3$ (§4.1a 최적값) 고정.

w_d	K (cycle 수)	JS (mean ± std)
0.0	10	0.0503 ± 0.0042
0.1	25	0.0311 ± 0.0021
0.3	16	0.0221 ± 0.0017
0.5	17	0.0215 ± 0.0024
0.7	17	0.0211 ± 0.0016

1.0 ★	19	0.0156 ± 0.0012

결론: $w_d = 1.0$이 최적이다 (JS = 0.0156). duration 가중치를 최대화할 때 성능이 가장 좋다. DFT는 pitch class 집합의 스펙트럼 구조(indicator vector $\chi_S \in \{0,1\}^{12}$의 이산 Fourier 계수 $|\hat{\chi}_S(k)|$가 나타내는 대칭성 패턴)를 정밀하게 포착하므로 w_d가 높아도 pitch 정보가 충분히 보존되며, 오히려 duration이 거리 행렬에 많이 기여할수록 cycle 수와 생성 품질이 향상되는 경향이 나타난다. 또한 $w_d = 0.0$ (duration 항 완전 제거)일 때 cycle 수가 10으로 급감하고 JS가 0.0503으로 크게 악화되어, duration 정보가 거리 행렬의 질에 유의미하게 기여함을 확인하였다.

DFT 계수 예시. hibari의 PC 집합 $S = \{0,2,4,5,7,9,11\}$의 indicator vector $\chi_S = (1,0,1,0,1,1,0,1,0,1,0,1)$에 대해 DFT magnitude $(|F_0|, \ldots, |F_6|) \approx (7, 0.27, 1.41, 1.0, 1.41, 2.73, 1)$으로 $|F_5|$가 다른 성분 대비 압도적으로 크다. 이는 diatonic이 완전5도 순환 $\{C, G, D, A, E, B, F\}$ 상에서 연속 7개 위치를 차지하기 때문이다. 반대로 chromatic cluster $S' = \{0,1,2,3,4,5,6\}$에서는 $|F_1|$이 커지고 $|F_5|$가 작아진다.

4.1c 감쇄 Lag 가중치 실험

§2.9에서 언급한 감쇄 합산 inter weight의 실험적 근거를 제시한다. lag 1 단일 옵션과 lag 1~4 감쇄 합산 옵션 두 설정을 비교하되, 거리 함수는 DFT와 Tonnetz 두 가지를 대조하여 거리 함수의 특성에 따라 효과가 달라짐을 확인한다.

실험 설정:

lag 1 단일 : $W_{\text{inter}} = W_{\text{inter}}^{(1)}$

lag 1~4 감쇄 합산 :

$$W_{\text{inter}} = \sum_{\ell=1}^{4} \lambda_\ell \cdot W_{\text{inter}}^{(\ell)}, \qquad (\lambda_1, \lambda_2, \lambda_3, \lambda_4) = (0.60,\ 0.30,\ 0.08,\ 0.02)$$

고정 조건: hibari, Algorithm 1, N=20

$N = 20$ 반복.

곡	거리 함수	lag 1 단일 (JS mean ± std)	lag 1~4 감쇄 합산 (JS mean ± std)	변화
hibari	DFT	0.0211 ± 0.0021	0.0196 ± 0.0022	-7.1% ★
hibari	Tonnetz	0.0488 ± 0.0040	0.0511 ± 0.0039	$+4.8\%$

해석 4 — DFT에서 개선, Tonnetz에서는 악화. DFT 거리에서는 감쇄 lag가 JS를 7.1% 개선한다. 반면 Tonnetz에서는 오히려 4.8% 악화한다. 경험적으로 DFT 조건에서만 감쇄 lag 합산이 유효하며, Tonnetz에서는 역효과였다. DFT의 pitch class 스펙트럼 표현이 먼 lag의 시간 상호작용 정보를 흡수하는 데 더 적합하다는 경험적 관찰이며, 이론적 설명은 후속 과제로 남긴다.

> **Tonnetz 결과 병기 이유.** §4.1에서 DFT를 본 연구의 baseline로 결정했지만, §5.6.1 Tonnetz 기반 통합 실험의 수치적 기반을 제공하고, §5.6.3 메타 통찰 시 참고하기 위해 두 거리 함수를 대조한다.

> **Algorithm 2 미실험 이유.** 감쇄 lag는 OM 생성 이전 단계인 가중치 행렬 W_{inter}에 적용된다. Algorithm 2는 이미 완성된 OM을 입력으로 받으므로, §4.3 DFT baseline 실험의 입력 OM에 감쇄 lag를 묵시적으로 반영하였다. 독립 ablation은 별도로 수행하지 않았다.

> **향후 과제 — inter 감쇄 계수 재탐색.** 본 실험에선 임의로 $\lambda_1 = 0.60$으로 설정하였는데, intra weight에서 lag=1 계수를 1.0으로 두는 것과의 비대칭이 존재한다. inter lag 감쇄 계수 $(\lambda_1, \lambda_2, \lambda_3, \lambda_4)$는 휴리스틱으로 설정된 것이므로, 향후 $\lambda_1 = 1.0$을 포함한 grid search 및 uniform/exponential decay 비교 실험이 가능하다.

4.2 연속값 OM 실험

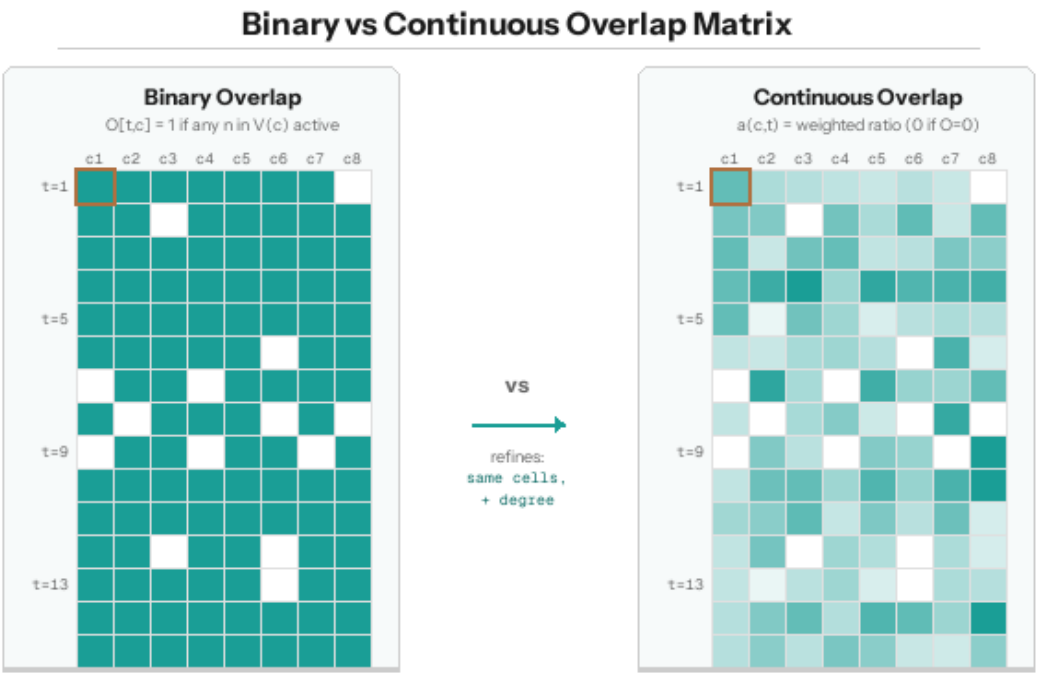

본 절은 §2.5에서 정의한 연속값 OM $O_{\text{cont}} \in [0,1]^{T\times K}$가 이진 OM $O \in \{0,1\}^{T\times K}$ 대비 어떤 영향을 주는지를 정량적으로 검증한다. 거리 함수는 모든 설정에서 DFT로 고정한다. 본 실험은 Algorithm 1에 대해서만 수행하였다. Algorithm 2에서 이진/연속값 입력의 효과는 §4.3에서 세 모델(FC/LSTM/Transformer) 비교 실험의 일부로 다룬다.

실험 설계

cycle별 시점 활성도 $a_{c,t}$는 두 가지 방식으로 계산할 수 있다.

이진 (binary): 단순 OR 연산이다. $V(c)$에 속하는 note가 시점 t에 하나라도 활성이면 $a_{c,t}=1$, 그렇지 않으면 0이다.

연속값 (continuous): cycle을 구성하는 note들이 얼마나 많은 비율로 활성화되어 있는지를 $[0,1]$ 실수로 표현한다 :

$$a_{c,t} = \Big(\sum_{n\in V(c)} w(n)\cdot \mathbb{1}[n\in A_t]\Big) \Big/ \Big(\sum_{n\in V(c)} w(n)\Big)$$

여기서 A_t는 시점 t에 활성인 note들의 집합, $w(n)=1/N_{\text{cyc}}(n)$은 note n의 **희귀도 가중치**이며 $N_{\text{cyc}}(n)$은 note n이 등장하는 cycle의 개수이다.

연속값 활성도가 만들어진 후, 최종 OM을 만드는 방식에 따라 다시 두 가지 변형이 가능하다.

- **직접 사용 (direct)**: $O[t,c]=a_{c,t}\in[0,1]$
- **임계값 이진화 (threshold τ)**: $O[t,c]=\mathbb{1}[a_{c,t}\geq\tau]$, $\tau\in\{0.3,0.5,0.7\}$

결과

DFT 조건, $w_o=0.3$, $w_d=1.0$, $N=20$ 반복.

설정	Density	JS Divergence (mean ± std)
(A) Binary	0.313	0.0157 ± 0.0018 ★
(B) Continuous direct	0.728	0.0186 ± 0.0015
(C) Continuous → bin $\tau=0.3$	0.367	0.0360 ± 0.0029
(C) Continuous → bin $\tau=0.5$	0.199	0.0507 ± 0.0027
(C) Continuous → bin $\tau=0.7$	0.060	0.0449 ± 0.0024

여기서 "Density"는 **OM (1,088 timestep × K cycle) 기준** 활성 셀의 평균 비율 ($\bar{O}$)이다. §3.2의 ON ratio는 **원곡 multi-hot 행렬** $y \in \{0,1\}^{T \times N}$ **기준**으로 대상 행렬이 다르다.

해석

해석 5a — Binary가 최우수. DFT 거리는 스펙트럼 구조를 정밀하게 포착하므로 이진 표현만으로도 cycle 활성 신호가 충분히 구별된다. DFT 이진 OM의 density 0.313은 **선택적 sparsity** — 즉 의미 있는 시점에만 해당 cycle이 활성화되는 상태 — 를 자체적으로 달성한다는 뜻이다. Algorithm 1의 교집합 sampling은 density가 너무 낮으면 활성 cycle이 부족해 note 선택의 다양성이 떨어지고, 너무 높으면 cycle 간 교집합이 비어 fallback(전체 pool 균등 추출)된다.

해석 5b — Continuous direct는 오히려 열세. (B) continuous direct ($\bar{O} = 0.728$)는 이진보다 훨씬 dense하여, Algorithm 1의 교집합 sampling이 과도하게 자주 호출되어 Binary 대비 18.5% 악화한다.

해석 5c — 임계값 이진화는 모두 열세. DFT 이진 OM이 이미 cycle 활성의 핵심 구간만을 선별하므로 추가적인 임계값 필터링($\tau = 0.3 \sim 0.7$)은 과도한 sparsity를 만들어 성능을 저하시킨다.

4.3 Experiment 3 — Algorithm 2 DL 모델 비교

DFT 기반 OM 입력 ($\alpha = 0.5$, $w_o = 0.3$, $w_d = 1.0$)에서 세 모델을 비교한다. 각 모델을 이진 OM $O \in \{0,1\}^{T \times K}$과 연속값 OM $O_{\text{cont}} \in [0,1]^{T \times K}$의 두 입력에서 모두 학습하였다. $N = 10$ 반복. (α grid search 결과는 §5.7에서 별도 탐색하며, Algo2 조건의 $\alpha = 0.25$ 재실험은 §5.8.2 참조.)

모델 아키텍처

FC (Fully Connected, 2-layer, $H = 128$, dropout $= 0.3$): 각 시점 t의 cycle 활성 벡터 $O[t,:] \in \{0,1\}^K$ 또는 $O_{\text{cont}}[t,:] \in [0,1]^K$를 입력으로 받아 동시점의 note label 분포를 출력. **시점 간 독립 매핑**이므로 시간 문맥 없음.

LSTM (2-layer, $H = 128$): cycle 활성 벡터 시퀀스 $\{O[t,:]\}_{t=1}^{T}$를 순차 입력. 순차 구조 $h_t = f(x_t, h_{t-1})$로 과거 문맥을 hidden state에 누적.

Transformer (2-layer, 4-head self-attention, $d_{\text{model}} = 128$): positional embedding으로 시간 위치를 인코딩하고 self-attention으로 **전 시점 동시 참조**가 가능.

세 모델 모두 동일한 학습 조건에서 multi-label BCE loss (§2.8)로 학습한다. 각 시점에서 예측된 note 확률로부터 샘플링하여 생성곡을 얻는다. **validation loss**는 학습 시점 validation set에서 측정한 BCE loss의 평균이다.

모델	입력	Pitch JS (mean ± std)	validation loss (mean)
FC	binary	0.00217 ± 0.00056	0.339
FC	**continuous**	0.00035 ± 0.00015 ★	0.023
LSTM	binary	0.233 ± 0.029	0.408
LSTM	continuous	0.170 ± 0.027	0.395
Transformer	binary	0.00251 ± 0.00057	0.836
Transformer	continuous	0.00082 ± 0.00026	0.152

해석

해석 6 — FC + continuous 입력이 최우수. FC가 연속값 입력에서 JS 0.00035로 가장 낮은 값을 달성하였다. 동일한 FC의 이진 입력 (0.00217) 대비 83.9% 개선된 수치이며, Welch's t-test $p = 1.50 \times 10^{-6}$로 통계적으로 유의하다. Transformer continuous와의 비교에서도 FC continuous가 유의하게 우수하다 (Welch $p = 1.66 \times 10^{-4}$). FC의 cell-wise 표현력이 DFT continuous OM의 cycle 활성 강도 차이를 세밀하게 반영한다.

해석 7 — LSTM의 심각한 열화. LSTM은 이진 입력 0.233, 연속값 입력 0.170으로 다른 두 모델과 비교할 수 없는 수준으로 열화하였다. LSTM의 **순차 구조(recurrent structure)** 란 시점 t의 hidden state h_t가 직전 시점 h_{t-1}로부터 $h_t = f(x_t, h_{t-1})$로 갱신되는 순차적 정보 전파 메커니즘을 의미하며, 이 구조는 시점이 연속적으로 이어지는 부드러운

시계열(예: 자연어, 음향 파형)에 적합하다. 그러나 OM은 본질적으로 시점별 이산 on/off 활성 패턴이며, 특히 hibari의 cycle 활성 위치는 모듈 기반 phase shifting 구조(§4.5.4)를 따라 모듈 단위로 평행 이동하므로 직전 시점의 hidden state가 현재 시점 예측에 기여하는 바가 작다.

해석 8 — 연속값 입력의 보편적 이점. 세 모델 모두 연속값 입력이 이진 입력보다 유의하게 우수하다 (모두 Welch $p < 10^{-4}$). 그러나 그 개선율은 모델별로 다르다: FC(-83.9%), Transformer(-67.4%), LSTM(-27.3%).

해석 9 — Validation loss와 JS의 동시 감소. FC-continuous는 validation loss (0.023)가 FC-binary (0.339)의 약 7% 수준이며 JS도 동시에 크게 감소한다. 연속값 입력이 모델의 학습 signal을 더 부드럽게 만들어, 과적합 없이 일반화된 분포를 학습하게 한다.

통합 비교 (§4.1 ~ §4.3)

실험	설정	JS divergence	출처
§4.1 Algo 1	frequency baseline	0.0344	§4.1
§4.1 Algo 1	DFT (최적)	0.0213	§4.1
§4.2 Algo 1	DFT binary (최적 파라미터)	0.0157 ± 0.0018 ★	§4.2
§4.3 Algo 2 FC	DFT continuous	0.00035 ± 0.00015 ★	§4.3

§4.3 FC (DFT continuous)는 DFT 기반 실험 내에서 관측된 최저 JS divergence이다. 이론적 최댓값 $\log 2 \approx 0.693$의 약 0.05%에 해당한다.

4.4 종합 논의

(1) 음악이론적 거리 함수의 중요성. §4.1. Experiment 1 결과는 "DFT처럼 음악이론적 구조를 반영한 거리가 더 좋은 위상적 표현을 만들 수 있다"는 가설을 지지한다.

(2) Algorithm 1의 이진 OM, Algorithm 2의 연속값 OM. 거리 함수 baseline으로 DFT를 채택했을 때 Algorithm 1에서는 이진 OM이 연속값 OM보다 우수한 반면 (§4.2), Algorithm 2의 FC에서는 연속값 OM이 큰 폭으로 우수하다 (§4.3, -83.9%). 규칙 기반 Algorithm 1은 sparse한 이진 활성 패턴을 직접 샘플링에 사용하므로 이진 OM이 적합하지만, DL 기반 Algorithm 2의 FC는 continuous activation의 강도 정보를 학습 signal로 활용하여 cell-wise 표현력이 극대화된다.

(3) FC + continuous 입력의 결정적 우위. DL 모델 비교 (§4.3)에서 FC-cont가 JS 0.00035로 Transformer-cont (0.00082) 대비 유의하게 우수하다.

4.5 곡 고유 구조 분석 — hibari 의 수학적 불변량

본 절은 hibari 가 가지는 수학적 고유 성질을 분석하고, 이 성질들이 본 연구의 실험 결과와 어떻게 연결되는지를 서술한다. 비교 대상으로 사카모토의 다른 곡인 solari 와 aqua 를 함께 분석한다.

4.5.1 Deep Scale Property — hibari 의 pitch class 집합이 갖는 대수적 고유성

hibari 가 사용하는 7개 pitch class 는 $\{0, 2, 4, 5, 7, 9, 11\} \subset \mathbb{Z}/12\mathbb{Z}$이다. 이 집합의 **interval vector**는 $[2, 5, 4, 3, 6, 1]$로 여기서 k번째 성분은 "집합 안에서 interval class k에 해당하는 쌍의 수"이다. 옥타브 대칭에 의해 k는 $12 - k$와 동치이므로 interval class는 $1 \sim 6$까지만 존재한다.

이 벡터의 6개 성분은 **모두 다른 수**($\{1, 2, 3, 4, 5, 6\}$의 순열)로 이것을 **deep scale property** 라 한다 (Gamer & Wilson, 2003). 이 성질을 갖는 7-note subset 은 $\binom{12}{7} = 792$개 중 **diatonic scale 류 뿐**이다.

또한 7개 PC 사이의 간격 패턴은 $[2, 2, 1, 2, 2, 2, 1]$로, 오직 $\{1, 2\}$ 두 종류의 간격만으로 구성된다. 이것은 **maximal evenness** — 12개 칸 위에 7개 점을 가능한 한 균등하게 배치한 상태 — 를 의미한다 (Clough & Douthett, 1991). deep scale property와 maximal evenness 는 모두 diatonic scale 의 고유 성질이다.

solari 와 aqua 는 12개 PC 모두를 사용하므로 이 성질을 갖지 않는다.

4.5.2 근균등 Pitch 분포 — Pitch Entropy

곡	사용 pitch 수	정규화 pitch entropy	해석
hibari	17	0.974	거의 완전 균등
solari	34	0.905	덜 균등
aqua	51	0.891	가장 치우침

pitch entropy는 곡 안에서 사용된 모든 pitch의 빈도 분포에 대한 Shannon entropy를 이론적 최댓값으로 나눈 **정규화 Shannon entropy**이다. hibari 의 0.974 는 **"모든 pitch 를 거의 같은 빈도로 사용"**한다는 뜻이며, §4.3 의 "FC 모델 우위"를 뒷받침한다.

4.5.3 Tonnetz 구별력과 Pitch Class 수의 관계

hibari 의 7개 PC 는 Tonnetz 위에서 **하나의 연결 성분**을 이루며, 평균 degree 가 $3.71/6 = 62\%$이다. Tonnetz 이웃 관계는 ± 3 (단3도), ± 4 (장3도), ± 5 (완전5도) 의 세 가지 방향이며, 각 방향이 양쪽으로 작용하므로 최대 6개의 이웃이 가능하다.

예를 들어 C(0) 의 Tonnetz 이웃은 $\{E, F, G, A\}$의 **4개** 이다:

관계	$+$ 방향	$-$ 방향	hibari 에 있는가
단3도 (± 3)	D#(3)	A(9)	A 있음
장3도 (± 4)	E(4)	G#(8)	E 있음
완전5도 (± 5)	G(7)	F(5)	G, F 있음

Tonnetz 그래프의 지름(diameter).

12개 PC를 전부 사용하는 곡 (solari, aqua) 에서는 어떤 두 PC 든 Tonnetz 거리가 ≤ 2이다. 이는 **"가까운 음"과 "먼 음"을 구별할 여지가 거의 없다**는 뜻이다. 반면 hibari에서는 Tonnetz 거리가 $1 \sim 4$ 범위로 분포하여, 가까운 쌍 (예: C-G, 거리 1) 과 먼 쌍 (예: F-B, 거리 3 이상) 이 명확히 구별된다.

단, 이는 **Tonnetz 거리 함수가 빈도 기반(frequency)보다 유리할 구조적 정황**일 뿐, hibari의 최적 거리 함수가 Tonnetz임을 의미하지는 않는다. §4.1의 hibari 실험에서는 **DFT가 Tonnetz 대비 -56.8%로 유의하게 우수**하였고 §5.1의 solari 실험에서는 "12-PC에서는 Tonnetz 구별력이 소실되어 frequency와 Tonnetz가 동등해진다"는 결과가 나왔다.

4.5.4 Phase Shifting — inst 1 과 inst 2 의 서로소 주기 구조

그림 2.9 에서 관찰한 패턴을 더 정밀하게 분석하면, 마디 내 쉼의 상대위치가 모듈마다 정확히 1칸씩 이동한다는 것이 발견된다. inst 2 의 모듈별 쉼 위치를 조사하면 **대각선 패턴**이 나타난다. :

```
module  1: rest at position  0
module  2: rest at position  1
module  3: rest at position  2
module  4: rest at position  3
  ...
module  k: rest at position  k-1
```

32-timestep의 마디 안에서 쉼의 위치가 매 모듈마다 정확히 1칸씩 오른쪽으로 밀린다. 32개 모듈을 거치면 쉼이 마디 내 모든 상대위치 $(0, 1, 2, \ldots, 31)$ 를 정확히 한 번씩 방문한다. 이 구조는 미니멀리즘 작곡가 Steve Reich 가 Piano Phase (1967) 에서 사용한 **phase shifting** 기법과 수학적으로 동일하다. 같은 패턴을 연주하는 두 악기 중 하나가 아주 조금 느리게 진행하여, 같은 패턴이 점점 어긋나다가 한참 뒤에야 정렬되는 것이다. hibari 에서 이 phase shifting 은 다음과 같이 수치화된다.

	inst 1	inst 2

모듈 주기	$M = 32$ (쉼 없음)	$M + 1 = 33$ (32 음 + 1 쉼)
반복 횟수	33 회	32 회
총 길이	$33 \times 32 = 1{,}056$	$32 \times 33 = 1{,}056$

두 주기가 32 와 33 으로 **서로소**이다. 이 관계 때문에 두 악기의 위상(phase)이 곡 전체에서 한 번도 **모듈 단위로** 동기화되지 않는다. 이때, 모듈 자체가 A-B-A'-C 구조로 구성되어 국소적으로는 같은 위상(phase)이 반복되는 시점이 있다.

이 구조는 수학적으로 **Euclidean rhythm** (Bjorklund, 2003; Toussaint, 2005) 과도 연결된다. Euclidean rhythm 은 "n 비트 중 k 개를 가능한 한 균등하게 배치" 하는 알고리즘으로, 아프리카 전통 음악과 전자 음악에서 널리 사용된다. hibari 의 경우 "33 칸 중 1 칸을 비운다" 를 32번 반복하면서 매번 1칸씩 이동하는 것이 Euclidean rhythm 의 가장 단순한 형태이다.