사카모토류이치의 *hibari* 에대한 위상적데이터분석: Persistent Homology 기반구조보존음악생성파이프라인

김민주
초학제독립연구단
고등과학원 (KIAS)
서울, 대한민국

***Abstract*—본연구는음악의위상적구조를 persistent homology 로추출하고, 그구조를보존하면서새로운음악을생성하는파이프라인을제안한다. 사카모토류이치의 *hibari* (2009 년앨범 *out of noise* 수록) 에적용하여, (i) MIDI 양자화로부터가중 note 네트워크를구성하고, (ii) 네가지거리함수 (frequency, Tonnetz, voice-leading, DFT) 로 H_1 persistent homology 를계산하며, (iii) 시간축에따른 cycle 활성화를기록하는중첩행렬을구축하고, (iv) 확률적샘플링 (Algorithm 1) 또는심층학습 (Algorithm 2; FC / LSTM / Transformer) 으로음악을생성한다.**

$N = 20$ 회독립반복실험에서, Tonnetz 거리는 pitch Jensen–Shannon divergence 를 0.0753 ± 0.0033 (frequency 기준) 에서 0.0398 ± 0.0031 로 47% 감소시켰다 (Welch $t = 35.1$, $p < 10^{-20}$, Cohen's $d = 11.1$). 연속값중첩행렬과 cycle 별임계값최적화는추가로 47.5% 의개선을달성하였으며 ($p < 0.001$), 연속값입력을 FC 모델에적용하면 JS $= 0.0004$ 로, 이론적최댓값 $\ln 2$ 의 0.1% 미만에도달한다. 가장단순한 FC 모델이 *hibari* 에서 LSTM 과 Transformer 를능가하는반면, 반음계적 *solari* 에서는이순위가역전된다 — 곡의미학적성격이최적모델아키텍처를결정함을확인하였다.

나아가, 위상구조를보존한채멜로디를변주하는세가지방향 — Tonnetz 매칭기반 note 재분배 (DTW +61.4%), 시간재배치, 화성제약 — 을제시하여, 위상적으로유사하면서선율적으로상이한음악생성이가능함을보인다.

***Index Terms*—Persistent homology, 위상적데이터분석, 음악생성, Tonnetz, Jensen–Shannon divergence, 다중레이블분류, Vietoris–Rips 복합체, 중첩행렬**

I. 서론

위상적데이터분석 (Topological Data Analysis, TDA) 은데이터로부터노이즈와스케일에강건한기하학적구조를추출하는수학적도구이다 [1], [2]. 본연구는 TDA 를특정음악작품 — 사카모토류이치의 *hibari* — 에적용하여, 1 차 persistent homology 군 H_1 의불변량이새로운음악생성의구조적씨앗 (seed) 으로기능할수있는지를탐구한다.

A. 연구질문

1) 음악의위상구조를 Vietoris–Rips H_1 persistence 로어떻게수학적으로정의할수있는가?
2) 이구조를 보존한채새로운음악을생성할수있는가? 보존정도를어떻게정량적으로측정하는가?
3) 거리함수의선택 (frequency, Tonnetz, voice-leading, DFT) 이생성품질에유의미한영향을주는가?

B. 왜 hibari 인가

hibari 는사카모토류이치의실험적앨범 *out of noise* (2009) 수록곡이다. 선택이유: (i) 적절한규모 ($T = 1{,}088$ 개 8 분음표시점, $N = 23$ 고유 note, $C = 17$ 화음); (ii) 단순함 (7 개 pitch class, C major) 과복잡함 (서로소주기구조의두악기, §IV-G0b) 의균형; (iii) 시간적인과보다음의공간적배치를중시하는미학으로, 모델선택결과 (§IV-E) 와직접공명.

C. 기여

1) 4 단계파이프라인 (전처리 → PH → 중첩행렬 → 생성) 과두종류의생성기, 네가지거리함수제시.
2) $N = 20$ 통계적비교를통한 Tonnetz 의온음계곡최적성확립.
3) Cycle 별임계값을가진연속값중첩행렬로 JS 를추가 47.5% 개선 (§VII-G).
4) Tonnetz 매칭 note 재분배, 시간재배치, 화성제약을통한위상보존변주 (§VII).
5) *solari*, Bach, Ravel 에대한교차검증으로, 곡의성격이최적거리함수와모델을결정함을확인 (§VII-B).

II. 수학적배경

A. Vietoris–Rips 복합체

정의 1. 유한거리공간 (X, d) 와 $\varepsilon > 0$ 에대해, Vietoris–Rips 복합체 $\mathrm{VR}_\varepsilon(X)$ 는 $\mathrm{VR}_\varepsilon(X) = \{\sigma \subseteq X \mid \forall x_i, x_j \in \sigma,\ d(x_i, x_j) \le \varepsilon\}$ 로정의되는단체복합체이다.

ε 이증가함에따라포함관계 $\mathrm{VR}_0 \subseteq \mathrm{VR}_{\varepsilon_1} \subseteq \cdots$ 가 *filtration* 을이룬다. 본연구에서 X 는 *hibari* 의 23 개고유 note 이다.

B. Persistent Homology

n 차호몰로지군 $H_n(K) = \ker \partial_n / \mathrm{im}\, \partial_{n+1}$ 은 n 차원 "구멍" 을포착한다. 본연구는위상적 cycle 에해당하는 H_1 에집중한다. *Persistent homology* 는 filtration 을따라각 cycle 의탄생 (birth) b 와소멸 (death) d 를추적하며, $\mathrm{pers} = d - b$ 가안정성을측정한다.

주로선행연구 [6], [7] 의 pHcol 알고리즘 (cycle 대표원포함) 을사용하고, 속도가중요한단계에서는 Ripser [5] 로보완한다.

C. 음악적거리함수

Note $n_i = (p_i, d_i)$ 간의네가지거리함수를비교한다.

a) Frequency 거리 (기준선): $d_{\text{freq}}(n_i, n_j) = 1/w(n_i, n_j)$. w 는화음시퀀스에서의인접빈도이다.

b) Tonnetz 거리: Pitch class 를 $\pm 3, \pm 4, \pm 7$ 반음 (단 3 도, 장 3 도, 완전 5 도) 간선을가진육각격자에배치한다. 최단경로거리를 12×12 테이블 (범위 0–4) 로사전계산한다 [3].

c) Voice-leading 거리: $d_V(p_1, p_2) = |p_1 - p_2|$, 부호없는반음차이 [4].

d) DFT 거리: Pitch class 를 $\mathbb{R}^{12}$ 지시벡터로표현하고, 처음 6 개 DFT 크기간의 L_2 거리를사용한다 [4].

e) 혼합거리와 *note* 수준확장: 모든음악이론적거리는 frequency 와 $d_{\text{hybrid}} = \alpha\, d_{\text{freq}} + (1-\alpha)\, d_{\text{music}}$ ($\alpha \in [0,1]$) 로결합된다. Note 수준에서옥타브항과 duration 항이추가된다:

$$d(n_1, n_2) = d_{\text{base}} + w_o |o_1 - o_2| + w_d \frac{|d_1 - d_2|}{\max(d_1, d_2)}, \quad (1)$$

여기서 $w_o = 0.3$ (격자탐색으로최적화, §IV-B), $w_d = 0.3$ 이다.

D. 가중치분해와 *Rate* 파라미터

Note 네트워크가중치는 *hibari* 의두악기구조를반영하여세성분으로분해된다:

- **Intra 가중치** W_{intra}: 악기내순차전이.
- **Inter 가중치** W_{inter}: 악기간전이, lag $\ell \in \{1,2,3,4\}$ 에대해감쇄가중:

$$W_{\text{inter}} = \sum_{\ell=1}^{4} \lambda_\ell W_{\text{inter}}^{(\ell)}, \quad (\lambda_1, \ldots, \lambda_4) = (0.4, 0.3, 0.2, 0.1). \quad (2)$$

  이감쇄가중은 JS 를 69.6% 감소시켰다 ($0.0398 \to 0.0121$).
- **Simul 가중치** W_{simul}: 동시발음공기.

Timeflow 가중치 $W_{\text{tf}}(r) = W_{\text{intra}} + r \cdot W_{\text{inter}}$ 를 $r \in [0, 1.5]$ 에걸쳐스윕한다.

E. 중첩행렬

정의 2 (활성화행렬). $A[t,c] = \mathbb{1}[\exists\, n \in V(c)$ 가시점t에서연주됨$]$.

정의 3 (이진중첩행렬). $O[t,c] = \mathbb{1}[t \in R(c)]$. $R(c)$ 는길이 $\geq \text{scale}_c$ 인지속활성화구간의합집합이다.

정의 4 (연속값중첩행렬).

$$O_{\text{cont}}[t,c] = \frac{\sum_{n \in V(c)} w(n) \cdot \mathbb{1}[n \text{ at } t]}{\sum_{n \in V(c)} w(n)}, \quad (3)$$

여기서 $w(n) = 1/N_{\text{cyc}}(n)$ 은희귀도가중치이다.

중첩행렬 O 는두생성기가공통으로사용하는 *seed* 이다.

F. Jensen–Shannon Divergence

이산분포 P, Q 에대해:

$$D_{\text{JS}}(P\|Q) = \tfrac{1}{2} D_{\text{KL}}(P\|M) + \tfrac{1}{2} D_{\text{KL}}(Q\|M), \quad M = \tfrac{1}{2}(P+Q). \quad (4)$$

상한은 $\log 2 \approx 0.693$ 이다. Pitch JS(note 빈도분포) 와 transition JS(bigram 분포) 를측정한다.

TABLE I
네가지거리함수에대한 ALGORITHM 1 JS DIVERGENCE ($N = 20$, 감쇄 LAG $\ell \in \{1, \ldots, 4\}$).

거리함수	K	JS (평균 ± 표준편차)	Coverage
frequency	43	0.0753 ± 0.0033	0.991
Tonnetz	**46**	$\mathbf{0.0398 \pm 0.0031}$	1.000
voice-leading	22	0.0891 ± 0.0048	1.000
DFT	20	0.0511 ± 0.0029	1.000

G. 탐욕적전진선택

Cycle 부분집합 $S \subseteq \mathcal{C}$ 를 $f(S) = 0.5\, J(S) + 0.3\, C(S) + 0.2\, B(S)$ 로선택한다. J 는 note 풀 Jaccard 유사도, C 는 중첩패턴 Pearson 상관, B 는 Betti 곡선유사도이다. 탐욕적선택으로 15/46 cycle 만으로 90% 보존을달성한다.

III. 파이프라인과생성알고리즘

A. *1* 단계: 전처리

MIDI 파일을 8 분음표단위로양자화하고 ($T = 1{,}088$), 두악기를분리하며, 각고유 (pitch, duration) 쌍에 1-indexed 레이블을부여한다 (*hibari*: $N = 23$ note, $C = 17$ 화음).

B. *2* 단계: *Persistent Homology*

가중 note 네트워크를구성하고 (§II-D), 거리행렬을유도하여 $r \in [0, 1.5]$ 에걸친 H_1 filtration 을계산한다.

C. *3* 단계: 중첩행렬

모든시점에서 cycle 활성화를계산하고임계값을적용한다 (§II-E).

D. *Algorithm 1* — 위상적샘플링

각시점 t 에대해:

- 활성 cycle 이존재하면 ($\sum_c O[t,c] > 0$): 교집합 $I(t) = \bigcap_{c: O[t,c]=1} V(c)$ 에서샘플링. $I(t) = \emptyset$ 이면합집합 $U(t)$ 로대체.
- 활성 cycle 이없으면: 인접활성 cycle vertex 의여집합 $P \setminus A(t)$ 에서샘플링 (위상적 "번짐" 방지).
- 충돌회피: 시점당최대 $R = 50$ 회재샘플링.

E. *Algorithm 2* — 신경망시퀀스모델

매핑 $f_\theta : O[t,:] \mapsto y[t,:]$ 을학습하는세가지아키텍처:

- **FC**: 2 층완전연결 ($H = 128$), 시점독립.
- **LSTM**: 2 층, 순방향시퀀스문맥.
- **Transformer**: 2 층, 4-head, 학습가능위치임베딩.

모든모델은 `BCEWithLogitsLoss` 와데이터증강 (부분집합샘플링, 순환이동, 비트플립노이즈) 을사용한다. 추론시적응형임계값 $\theta = \text{quantile}(P, 1 - \rho_{\text{on}})$ 으로원곡 ON 비율 $\rho_{\text{on}} \approx 0.15$ 를맞춘다.

IV. 실험

모든실험은 $N = 20$ 회독립반복으로수행하였다. 주요지표는 pitch JS divergence 이다.

A. 거리함수비교

Tonnetz 는 frequency 대비 JS 를 47% 감소시킨다 (표 I). Welch $t = 35.1$, $\nu \approx 38$, $p < 10^{-20}$, Cohen's $d = 11.1$.

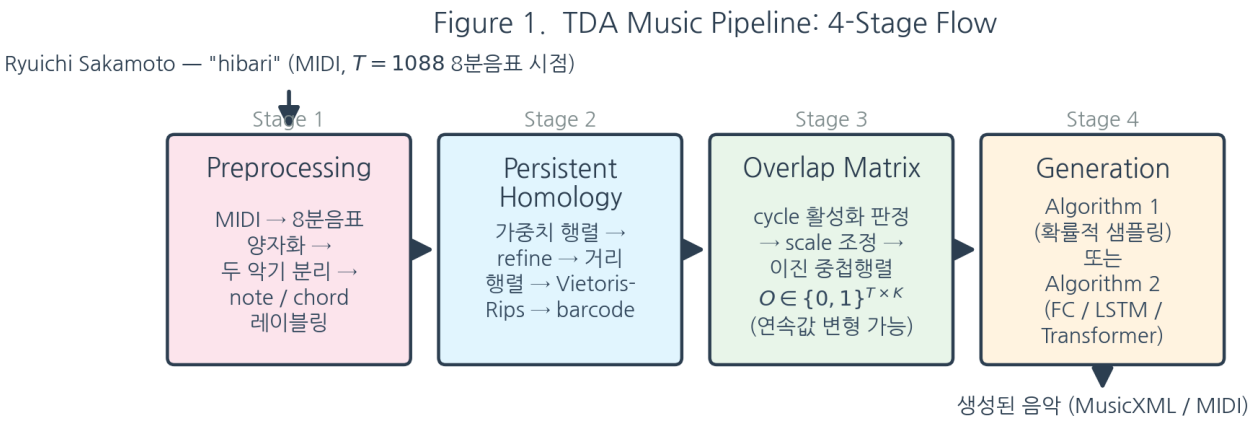

Fig. 1. 4 단계파이프라인: (1) MIDI 전처리, (2) persistent homology, (3) 중첩행렬구축, (4) Algorithm 1 또는 2 에의한생성.

TABLE II
CYCLE 부분집합절제 (TONNETZ, $N = 20$).

K	JS (평균 ± 표준편차)	Coverage
10	0.0991 ± 0.0038	0.980
17	0.0740 ± 0.0038	0.996
46	$\mathbf{0.0397 \pm 0.0025}$	1.000

TABLE III
연속값중첩행렬실험 (TONNETZ, $N = 20$).

설정	Density	JS (평균 ± 표준편차)
이진 (캐시)	0.751	0.0387 ± 0.0027
연속값직접사용	0.264	0.0382 ± 0.0021
연속 → 이진 τ=0.3	0.373	0.0386 ± 0.0022
연속 → 이진 τ=0.5	**0.168**	$\mathbf{0.0343 \pm 0.0027}$
연속 → 이진 τ=0.7	0.077	0.0364 ± 0.0032

B. 옥타브가중치튜닝

$w_o \in \{0.1, 0.3, 0.5, 0.7, 1.0\}$ 에대한격자탐색 ($N = 10$) 결과, $w_o = 0.3$ 이최적이다 (JS 0.0479, $w_o = 0.5$ 대비 −18.8%). *hibari* 의좁은 2 옥타브음역 (MIDI 52–81) 과일치한다.

C. *Cycle* 부분집합절제

JS 는 K 에대해단조감소하지만수확체감이나타난다 (표 II): K: 17 → 46 (29 개추가) 의이득이 K: 10 → 17 (7 개추가) 을근소하게만초과한다.

D. 연속값중첩행렬

연속값중첩행렬에 $\tau = 0.5$ 이진화를적용하면이진기준선대비 11.4% 추가개선된다 (Welch $t = 5.16$, $p < 0.001$, $d = 1.63$; 표 III). 희귀도가중으로드문 note 가활성화에더크게기여한다.

TABLE IV
최적 DL 설정 (각 1 회실행).

모델	Val Loss	JS	생성 Note 수
FC (hd=256, do=0.3)	0.282	**0.0015**	3,754
LSTM (2 층)	0.385	0.0448	3,753
Transformer (2L, 4H)	0.676	0.0104	3,753

TABLE V
FC 에대한연속 VS. 이진입력 ($N = 5$).

입력	JS (평균 ± 표준편차)	Val Loss	Coverage
이진	0.0014 ± 0.0010	0.070	0.948
연속	$\mathbf{0.0006 \pm 0.0005}$	**0.031**	**0.991**

E. 심층학습모델비교

가장단순한 FC 모델이최저 JS 를달성한다 (표 IV). 이는 *hibari* 의미학을반영한다: *out of noise* 는시간적인과보다음의공간적배치를중시하므로, 시간문맥을무시하는 FC 가작곡설계와더잘부합한다.

F. 개선 *F:* 연속값중첩행렬 + *FC*

연속값활성화를 FC 의학습입력으로직접사용:
연속입력은 JS 를 57%, val loss 를 2.3 배감소시킨다 (표 V). 본연구에서관측된최저전곡 JS 이다 (이론적최댓값 $\log 2$ 의 0.09%).

G. 곡고유구조분석

a) Deep scale 특성: *hibari* 의 7 개 pitch class $\{C, D, E, F, G, A, B\}$ 는음정벡터 $[2, 5, 4, 3, 6, 1]$ 을가지며, 모든성분이상이하다. 이는온음계고유의특성이다 [15].

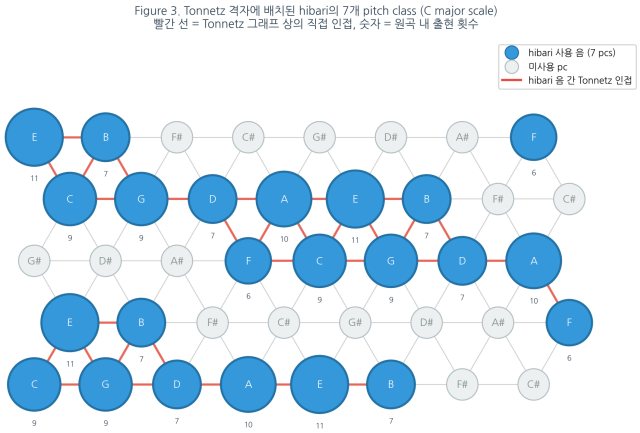

Fig. 2. Tonnetz 격자위의 *hibari* 7 개 pitch class (파란색). 빨간간선은직접 Tonnetz 인접을나타낸다.

b) 준균등 pitch 분포: 정규화 pitch 엔트로피가 0.974 (거의최대) 이다. 모든 pitch 가거의동일확률로나타나므로, 시간순서를무시하는 FC 가이미참분포를잘근사함을설명한다.

c) Tonnetz 판별력: 7 개 PC 에서 Tonnetz 직경은 4 로, 세밀한거리판별이가능하다. 12 개 PC(*solari* 등) 에서는직경이 2 로축소되어 Tonnetz 의이점이사라진다.

d) 위상이동 (Phase shifting): 악기 1 은 32-step 모듈을 33 회반복 (쉼없음); 악기 2 는 33-step 모듈을 32 회반복 (모듈당쉼 1 회). 서로소주기 ($\gcd(32, 33) = 1$) 에의해두악기는결코동기화되지않는다. Steve Reich 의 *phase shifting* 기법과수학적으로동일한구조이다.

V. 시각자료

6 개의정적도표와 1 개의대화형 HTML 보충자료를제공한다. 그림 1은파이프라인을, 그림 2는 Tonnetz 격자위의 pitch class 를, 그림 3는 persistence barcode 를, 그림 4은원곡/생성피아노롤비교를, 그림 5는 epoch 별 JS 수렴곡선을보여준다.

VI. 관련연구와의비교

A. 일반 AI 음악생성과의비교

코퍼스기반학습모델 (Magenta, Music Transformer) 과달리, 본파이프라인은 단일곡에대한심층분석을수행하여해석가능하고추적가능한생성을실현한다. FC > Transformer 라는결과는 "더많은시간적모델링이항상우월하다" 는보편적가정에도전한다.

B. 기존 TDA–음악연구와의비교

선행 TDA–음악연구 [6], [7] 와비교하여: (A) 네가지거리함수를 N=20 통계로체계적비교; (B) 연속값중첩행렬도입; (C) 완전한통계적엄밀성 (Welch t, Cohen's d) 제공; (D) 서양현대음악으로확장; (E) 모델선택과미학적맥락의연결; (F) TDA 를분석에서 변주로확장 (§VII).

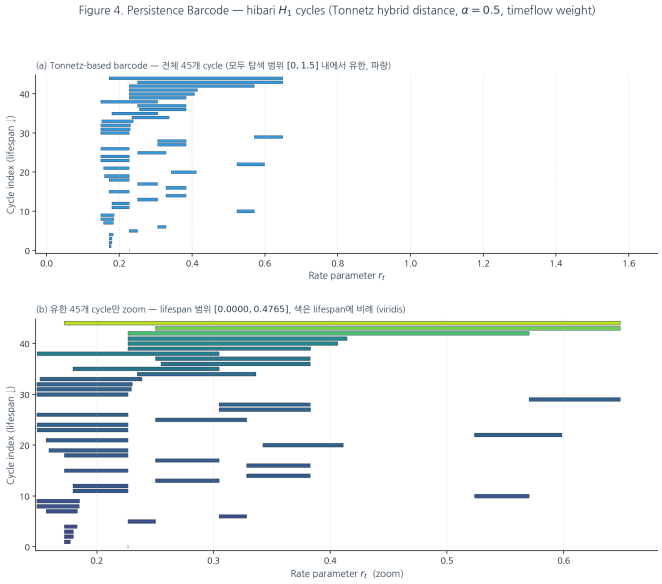

Fig. 3. H_1 persistence barcode (Tonnetz). 위: 전체 barcode; 아래: 유한 cycle 확대. 수명범위가 10,000 배이상차이난다.

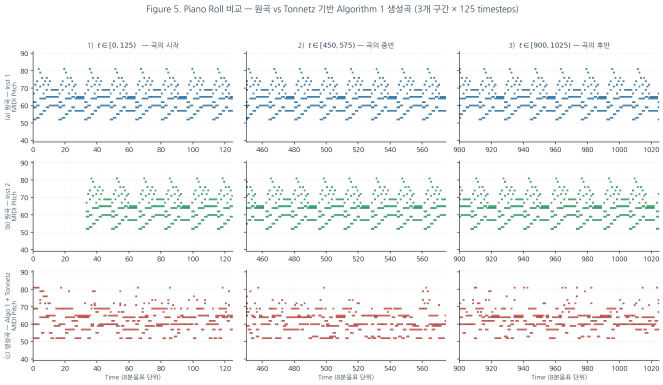

Fig. 4. 피아노롤비교: (a)–(b) 원곡악기 1–2; (c) Algorithm 1 + Tonnetz.

VII. 확장실험

A. 모듈단위생성

hibari 의 32-step 모듈구조에착안하여, 단일모듈을생성한후 33 회복제하는방법을탐구하였다. 5 가지프로토타입전략 (P0: OR, P1: 평균 $\to\tau$=0.5, P2: 연속값, P3: 중앙값, P5: 균등대조군) 을비교하였으며, P4(첫모듈의국소 PH, K=24 cycle) 와 best-of-10 선택 (C) 의결합이최적이었다:

8 개시작위치에대한분석결과모듈 0 ($t \in [0, 32)$) 이최적이다 (JS 0.054, 최저 0.026). 최적단일시행 (seed 9302, JS = 0.0258) 은전곡기준선평균 (0.0398) 을능가한다.

B. 일반화: solari, *Bach, Ravel*

solari (12-PC, 반음계) 에서는 Transformer 가최적이다 (JS 0.016). *hibari* 의 FC 우위와정확히역전된다 (표 VII). Bach Fugue 에서 Tonnetz 는 −54.8% 로관측중최대개선을보이고, Ravel Pavane (N=49 note) 에서는 frequency 가최적이다.

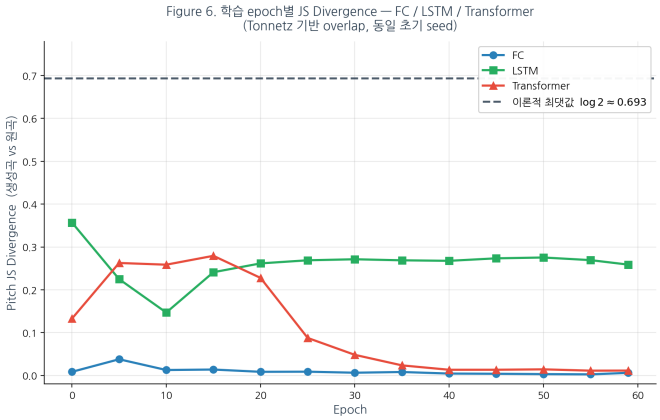

Fig. 5. 학습 epoch 에따른 JS divergence. FC 가가장빠르게수렴; LSTM 은 JS ≈ 0.26 에서정체.

TABLE VI
모듈단위생성전략 ($N = 10$).

전략	JS (평균 ± 표준편차)	최저	Cov.
P1 기준선	0.114 ± 0.039	0.074	0.77
C: best-of-10	0.074 ± 0.027	0.024	0.90
D: cov≥20/23	0.082 ± 0.022	0.050	0.88
P4: 국소 PH	0.066 ± 0.019	0.038	0.84
P4+C	$\mathbf{0.059 \pm 0.015}$	**0.026**	0.89

C. 방향 *A:* 위상보존 *Note* 재분배

Cycle vertex 집합을 Tonnetz 매칭거리가최소화되는새 note 로교체한다. 중첩행렬은그대로보존된다.

가장넓은음역 (MIDI 40–88) 에서 DTW 가 61.4% 증가하면서도 cycle 오차는 ~ 1.1 로안정적이다 (표 VIII) — 위상구조를보존하면서멜로디가실질적으로다른음악이생성된다.

D. 방향 *B:* 시간재배치

세가지전략 (구간셔플, 블록순열, Markov 재샘플링) 을시험하였다. PE 제거및재학습을적용한 Transformer 가 DTW +21.7% 를달성하나, pitch JS 가 $0.007 \to 0.173$ 으로악화된다. 방향 B 단독으로는 pitch 분포보존과멜로디변화를동시에달성할수없으며, 방향 A 와의결합이필요하다.

E. 화성제약

Note 재분배에음계제약 (major, minor, pentatonic) 과협화목표를추가하였다. **scale_major** 가가장효과적이다: note 오차 $4.35 \to 3.52$ (-19%), 음계일치 1.00, 평균불협화도 $0.412 \to 0.361$.

F. *A+B* 결합: 최종통합

최적결합설정 (**major_block32**): scale_major 재분배 + 블록순열 (32) + 연속중첩행렬 + Transformer. 결과: ref pJS $= 0.002$ (거의완벽한학습), DTW +31% (다른멜로디), C major 음계일치 $= 1.00$.

TABLE VII
교차곡비교요약.

곡	PC 수	최적거리	최적모델	해석
hibari	7	Tonnetz	FC	공간적배치
solari	12	freq/Ton.	Transformer	선율적진행
aqua	12	Tonnetz	—	Tonnetz +26.3%
Bach	12	Tonnetz	—	Tonnetz −54.8%
Ravel	12	frequency	FC	풍부한분포

TABLE VIII
NOTE 재분배 (ALGORITHM 1, TONNETZ).

설정	Note 오차	Cycle 오차	DTW	ΔDTW
기준선	—	—	2.21	—
narrow	4.00	1.17	2.09	−5.8%
wide	4.46	1.18	2.89	+30.3%
vwide	4.48	1.06	**3.57**	**+61.4%**

G. *Cycle* 별임계값최적화

각 cycle 에대해 $\tau_c \in \{0.1, 0.2, \ldots, 0.7\}$ 로탐욕적좌표하강법수행:

47.5% 개선 ($p < 0.001$; 표 IX). 대다수 cycle 이 $\tau < 0.35$ 를선호하여, 기존에 "반주형" cycle 이억제되고있었음을시사한다. 과적합없음: N=5 탐색결과 (0.0238) 가 N=20 검증 (0.0241) 과일치.

H. *Soft Activation:* 전체아키텍처

FC 와 Transformer 는연속입력으로대폭개선되나, LSTM 은호환되지않는다 (표 X). FC + 연속입력이 JS $= 0.0004$ 로본연구전체최저치이다.

I. *Tonnetz* α 격자탐색

$\alpha = 0.0$ (순수 Tonnetz) 이개별적으로는최적이나, $w_o = 0.3$ 및감쇄 lag 와결합하면 cycle 수가 $K = 14$ 로급감한다. 위상적다양성 ($K = 42$) 유지를위해 $\alpha = 0.5$ 를기본값으로유지한다 (표 XI).

J. *Barcode Wasserstein* 모듈선택

모듈별국소 PH 와전곡 PH 간의 Wasserstein 거리는생성 JS 와 Pearson 상관 $r = 0.503$ 을보인다. 중간정도의상관, 화음공간불일치, 단일악기한계를고려하면, Wasserstein 기반선택은주요기준이아닌보조기준으로위치한다.

VIII. 결론

본연구는 persistent homology 로음악의위상구조를추출하고그구조를보존하면서새로운음악을생성하는통합파이프라인을제시하였다. 주요발견:

1) **거리함수가중요하다.** Tonnetz 는 *hibari* 에서 JS 를 47% 감소시키나 ($p < 10^{-20}$), 이이점은곡마다다르다: Bach Fugue 는 −54.8%, Ravel Pavane 은 frequency 가 최적.
2) **곡의성격이최적모델을결정한다.** *hibari* (온음계, 엔트로피 0.974) $\to$ FC; *solari* (반음계, 엔트로피 0.905) $\to$ Transformer.

TABLE IX
CYCLE 별 τ_c 최적화 ($N = 20$).

설정	JS (평균 ± 표준편차)	개선율
균일 $\tau = 0.35$	0.0460 ± 0.0034	—
Cycle 별 τ_c	$\mathbf{0.0241 \pm 0.0023}$	**+47.5%**

TABLE X
이진 vs. 연속입력 ($N = 5$).

모델	입력	JS	Val Loss	ΔJS
FC	이진	0.0035	0.307	—
FC	**연속**	**0.0004**	**0.026**	**+88.6%**
Trans.	이진	0.0034	0.465	—
Trans.	**연속**	**0.0007**	**0.121**	**+79.4%**
LSTM	이진	0.280	0.411	—
LSTM	연속	0.290	0.411	−3.5%

3) **연속값중첩행렬은강력하다.** Cycle 별임계값으로 47.5% 추가개선 ($p < 0.001$); soft activation 입력은 +88.6% (FC), +79.4% (Transformer).
4) **위상보존변주가가능하다.** Note 재분배 + 시간재배치 + 화성제약으로 DTW +31% (다른멜로디), ref pJS 0.002 (정확한학습), C major 음계완전일치.
5) **모듈단위생성이경쟁력있다.** P4+C 로 JS 0.059 (평균), 최저 0.026. 실시간대화형작곡도구로의확장가능성을열어준다.

본연구는 TDA 가분석도구일뿐아니라 음악창작을위한제약생성기로기능할수있음을보여주며, 수학적위상과작곡미학사이의다리를놓는다.

감사의글

본연구는고등과학원 (KIAS) 초학제독립연구단의정재훈교수의지도하에수행되었다. 한국전통음악선행연구 [7] 로부터계승된 pHcol 구현과파이프라인설계에감사를표한다.

REFERENCES

[1] G. Carlsson, "Topology and data," *Bulletin of the AMS*, vol. 46, no. 2, pp. 255–308, 2009.
[2] H. Edelsbrunner and J. Harer, *Computational Topology: An Introduction*. AMS, 2010.
[3] D. Tymoczko, "The generalized Tonnetz," *J. Music Theory*, vol. 56, no. 1, 2012.
[4] D. Tymoczko, "Set-class similarity, voice leading, and the Fourier transform," *J. Music Theory*, vol. 52, no. 2, 2008.
[5] U. Bauer, "Ripser: Efficient computation of Vietoris–Rips persistence barcodes," *J. Applied and Computational Topology*, vol. 5, pp. 391–423, 2021.
[6] M. L. Tran, C. Park, and J.-H. Jung, "Topological data analysis of Korean music in Jeongganbo," *arXiv:2103.06620*, 2021.
[7] D.-J. Lee, M. L. Tran, and J.-H. Jung, "Geometric structure and AI composition of Korean traditional music," 2024.
[8] E. Heo, B. Choi, and J.-H. Jung, "Persistent homology with path-representable distances on graph data," *arXiv:2501.03553*, 2025.
[9] G. L. Nemhauser, L. A. Wolsey, and M. L. Fisher, "An analysis of approximations for maximizing submodular set functions," *Math. Programming*, vol. 14, no. 1, pp. 265–294, 1978.
[10] B. L. Welch, "The generalization of 'Student's' problem when several different population variances are involved," *Biometrika*, vol. 34, pp. 28–35, 1947.

TABLE XI
α 격자탐색 ($N = 20$).

α	K	JS (평균 ± 표준편차)	비고
0.0	14	$\mathbf{0.0574 \pm 0.0023}$	$K \geq 14$ 중최적
0.3	48	0.0870 ± 0.0046	최악
0.5	42	0.0594 ± 0.0033	기본값
1.0	1	0.0351 ± 0.0020	축퇴 (K=1)

[11] J. Cohen, *Statistical Power Analysis for the Behavioral Sciences*, 2nd ed. Lawrence Erlbaum, 1988.
[12] S. Hochreiter and J. Schmidhuber, "Long short-term memory," *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.
[13] A. Vaswani *et al.*, "Attention is all you need," in *Proc. NeurIPS*, 2017.
[14] R. Sakamoto, *out of noise* [Album]. commmons, 2009.
[15] C. Gamer and R. Wilson, "Microtones and projective planes," in *Music and Mathematics*. Oxford University Press, 2003.