사카모토류이치의 *hibari* 에대한 위상적데이터분석: Persistent Homology 기반구조보존음악생성파이프라인

김민주
초학제독립연구단
고등과학원 (KIAS)
서울, 대한민국

***Abstract*—본연구는음악의위상적구조를 persistent homology 로추출하고, 그구조를보존하면서새로운음악을생성하는계산파이프라인을제안한다. 사카모토류이치의 *hibari* (2009 년앨범 *out of noise* 수록) 에적용하여, (i) MIDI 전처리, (ii) 네가지거리함수 (frequency, Tonnetz, voice-leading, DFT) 에서의 H_1 persistent homology 계산, (iii) 중첩행렬구성, (iv) 확률적샘플링 (Algorithm 1) 또는심층학습 (Algorithm 2; FC / LSTM / Transformer) 생성의네단계를수행한다.**

$N = 20$ 반복에서 DFT 는 Algorithm 1 에서최적이며, pitch JS 는 0.0344 ± 0.0023 (frequency) 에서 0.0213 ± 0.0021 로감소한다 (-38.2%, Welch $p < 10^{-20}$). 또한 Tonnetz 대비 -56.8%, voice-leading 대비 -62.4% 개선된다. DFT 연속중첩행렬에서 cycle 별임계값최적화 (per-cycle τ_c) 를적용하면 0.01489 ± 0.00143 에도달하며 (균일 $\tau = 0.35$ 대비 $+58.7\%$, Welch $p = 2.48 \times 10^{-26}$), 이는 Algorithm 1 의최고성능이다. Algorithm 2 에서는연속입력 FC 가 0.00035 ± 0.00015 ($N = 10$) 를기록하며 Transformer 대비유의하게우수하다.

모듈단위생성 (DFT $\alpha = 0.25$, $K = 14$) 에서는 P3+C 단일시행최저 JS 가 0.0250 이고, 33 개시작모듈전수탐색의전역최저는 0.01479 로, 전곡 per-cycle 최적값 (0.01489) 과사실상동등하다.

***Index Terms*—Persistent homology, 위상적데이터분석, 음악생성, Tonnetz, Jensen–Shannon divergence, 다중레이블분류, Vietoris–Rips 복합체, 중첩행렬**

I. 서론

위상적데이터분석 (Topological Data Analysis, TDA) 은데이터로부터노이즈와스케일에강건한기하학적구조를추출하는수학적도구이다 [1], [2]. 본연구는 TDA 를특정음악작품 — 사카모토류이치의 *hibari* — 에적용하여, 1 차 persistent homology 군 H_1 의불변량이새로운음악생성의구조적씨앗 (seed) 으로기능할수있는지를탐구한다.

A. 연구질문

1) 음악의위상구조를 Vietoris–Rips H_1 persistence 로어떻게수학적으로정의할수있는가?
2) 이구조를 보존한채새로운음악을생성할수있는가? 보존정도를어떻게정량적으로측정하는가?
3) 거리함수의선택 (frequency, Tonnetz, voice-leading, DFT) 이생성품질에유의미한영향을주는가?

B. 왜 hibari 인가

hibari 는사카모토류이치의실험적앨범 *out of noise* (2009) 수록곡이다. 선택이유: (i) 적절한규모 ($T = 1{,}088$ 개 8 분음표시점, $N = 23$ 고유 note, $C = 17$ 화음); (ii) 단순함 (7 개 pitch class, C major) 과복잡함 (서로소주기구조의두악기, §IV-G0b) 의균형; (iii) 시간적인과보다음의공간적배치를중시하는미학으로, 모델선택결과 (§IV-E) 와직접공명.

C. 기여

1) 4 단계파이프라인 (전처리 → PH → 중첩행렬 → 생성) 과두종류의생성기, 네가지거리함수제시.
2) $N = 20$ 통계적비교를통한 Tonnetz 의온음계곡최적성확립.
3) Cycle 별임계값을가진연속값중첩행렬로 JS 를추가 47.5% 개선 (§VII-G).
4) Tonnetz 매칭 note 재분배, 시간재배치, 화성제약을통한위상보존변주 (§VII).
5) *solari*, Bach, Ravel 에대한교차검증으로, 곡의성격이최적거리함수와모델을결정함을확인 (§VII-B).

II. 수학적배경

A. Vietoris–Rips 복합체

정의 1. 유한거리공간 (X, d) 와 $\varepsilon > 0$ 에대해, Vietoris–Rips 복합체 $\mathrm{VR}_\varepsilon(X)$ 는 $\mathrm{VR}_\varepsilon(X) = \{\sigma \subseteq X \mid \forall x_i, x_j \in \sigma,\ d(x_i, x_j) \le \varepsilon\}$ 로정의되는단체복합체이다.

ε 이증가함에따라포함관계 $\mathrm{VR}_0 \subseteq \mathrm{VR}_{\varepsilon_1} \subseteq \cdots$ 가 *filtration* 을이룬다. 본연구에서 X 는 *hibari* 의 23 개고유 note 이다.

B. Persistent Homology

n 차호몰로지군 $H_n(K) = \ker \partial_n / \mathrm{im}\, \partial_{n+1}$ 은 n 차원 "구멍" 을포착한다. 본연구는위상적 cycle 에해당하는 H_1 에집중한다. *Persistent homology* 는 filtration 을따라각 cycle 의탄생 (birth) b 와소멸 (death) d 를추적하며, $\mathrm{pers} = d - b$ 가안정성을측정한다.

주로선행연구 [6], [7] 의 pHcol 알고리즘 (cycle 대표원포함) 을사용하고, 속도가중요한단계에서는 Ripser [5] 로보완한다.

C. 음악적거리함수

Note $n_i = (p_i, d_i)$ 간의네가지거리함수를비교한다.

a) Frequency 거리 (기준선): $d_{\text{freq}}(n_i, n_j) = 1/w(n_i, n_j)$. w 는화음시퀀스에서의인접빈도이다.

b) Tonnetz 거리: Pitch class 를 $\pm 3, \pm 4, \pm 7$ 반음 (단 3 도, 장 3 도, 완전 5 도) 간선을가진육각격자에배치한다. 최단경로거리를 12×12 테이블 (범위 0–4) 로사전계산한다 [3].

c) Voice-leading 거리: $d_V(p_1, p_2) = |p_1 - p_2|$, 부호없는반음차이 [4].

d) DFT 거리: Pitch class 를 $\mathbb{R}^{12}$ 지시벡터로표현하고, 처음 6 개 DFT 크기간의 L_2 거리를사용한다 [4].

e) 혼합거리와 *note* 수준확장: 모든음악이론적거리는 frequency 와 $d_{\text{hybrid}} = \alpha\, d_{\text{freq}} + (1-\alpha)\, d_{\text{music}}$ ($\alpha \in [0,1]$) 로결합된다. Note 수준에서옥타브항과 duration 항이추가된다:

$$d(n_1, n_2) = d_{\text{base}} + w_o |o_1 - o_2| + w_d \frac{|d_1 - d_2|}{\max(d_1, d_2)}, \quad (1)$$

여기서 $w_o = 0.3$ (격자탐색으로최적화, §IV-B), $w_d = 0.3$ 이다.

D. 가중치분해와 *Rate* 파라미터

Note 네트워크가중치는 *hibari* 의두악기구조를반영하여세성분으로분해된다:

- **Intra 가중치** W_{intra}: 악기내순차전이.
- **Inter 가중치** W_{inter}: 악기간전이, lag $\ell \in \{1, 2, 3, 4\}$ 에대해감쇄가중:

$$W_{\text{inter}} = \sum_{\ell=1}^{4} \lambda_\ell W_{\text{inter}}^{(\ell)}, \quad (\lambda_1, \ldots, \lambda_4) = (0.4, 0.3, 0.2, 0.1). \quad (2)$$

  이감쇄가중은 JS 를 69.6% 감소시켰다 ($0.0398 \to 0.0121$).
- **Simul 가중치** W_{simul}: 동시발음공기.

Timeflow 가중치 $W_{\text{tf}}(r) = W_{\text{intra}} + r \cdot W_{\text{inter}}$ 를 $r \in [0, 1.5]$ 에걸쳐스윕한다.

E. 중첩행렬

정의 2 (활성화행렬)**.** $A[t, c] = \mathbb{1}[\exists\, n \in V(c)$ 가시점t에서연주됨$]$.

정의 3 (이진중첩행렬)**.** $O[t, c] = \mathbb{1}[t \in R(c)]$. $R(c)$ 는길이 $\geq \text{scale}_c$ 인지속활성화구간의합집합이다.

정의 4 (연속값중첩행렬)**.**

$$O_{\text{cont}}[t, c] = \frac{\sum_{n \in V(c)} w(n) \cdot \mathbb{1}[n \text{ at } t]}{\sum_{n \in V(c)} w(n)}, \quad (3)$$

여기서 $w(n) = 1/N_{\text{cyc}}(n)$ 은희귀도가중치이다.

중첩행렬 O 는두생성기가공통으로사용하는 *seed* 이다.

F. Jensen–Shannon Divergence

이산분포 P, Q 에대해:

$$D_{\text{JS}}(P \| Q) = \tfrac{1}{2} D_{\text{KL}}(P \| M) + \tfrac{1}{2} D_{\text{KL}}(Q \| M), \quad M = \tfrac{1}{2}(P + Q). \quad (4)$$

상한은 $\log 2 \approx 0.693$ 이다. Pitch JS(note 빈도분포) 와 transition JS(bigram 분포) 를측정한다.

TABLE I
네가지거리함수에서의 ALGORITHM 1 PITCH JS (*HIBARI*, $N = 20$).

거리함수	K	JS (평균 ± 표준편차)	Coverage
frequency	1	0.0344 ± 0.0023	0.957
Tonnetz	47	0.0493 ± 0.0038	1.000
voice-leading	19	0.0566 ± 0.0027	0.989
DFT	**17**	$\mathbf{0.0213 \pm 0.0021}$	1.000

G. 탐욕적전진선택

Cycle 부분집합 $S \subseteq \mathcal{C}$ 를 $f(S) = 0.5\, J(S) + 0.3\, C(S) + 0.2\, B(S)$ 로선택한다. J 는 note 풀 Jaccard 유사도, C 는 중첩패턴 Pearson 상관, B 는 Betti 곡선유사도이다. 탐욕적선택으로 15/46 cycle 만으로 90% 보존을달성한다.

III. 파이프라인과생성알고리즘

A. *1* 단계: 전처리

MIDI 파일을 8 분음표단위로양자화하고 ($T = 1{,}088$), 두악기를분리하며, 각고유 (pitch, duration) 쌍에 1-indexed 레이블을부여한다 (*hibari*: $N = 23$ note, $C = 17$ 화음).

B. *2* 단계: *Persistent Homology*

가중 note 네트워크를구성하고 (§II-D), 거리행렬을유도하여 $r \in [0, 1.5]$ 에걸친 H_1 filtration 을계산한다.

C. *3* 단계: 중첩행렬

모든시점에서 cycle 활성화를계산하고임계값을적용한다 (§II-E).

D. *Algorithm 1* — 위상적샘플링

각시점 t 에대해:

- 활성 cycle 이존재하면 ($\sum_c O[t, c] > 0$): 교집합 $I(t) = \bigcap_{c: O[t,c]=1} V(c)$ 에서샘플링. $I(t) = \emptyset$ 이면합집합 $U(t)$ 로대체.
- 활성 cycle 이없으면: 인접활성 cycle vertex 의여집합 $P \setminus A(t)$ 에서샘플링 (위상적 "번짐" 방지).
- 충돌회피: 시점당최대 $R = 50$ 회재샘플링.

E. *Algorithm 2* — 신경망시퀀스모델

매핑 $f_\theta : O[t, :] \mapsto y[t, :]$ 을학습하는세가지아키텍처:

- **FC**: 2 층완전연결 ($H = 128$), 시점독립.
- **LSTM**: 2 층, 순방향시퀀스문맥.
- **Transformer**: 2 층, 4-head, 학습가능위치임베딩.

모든모델은 `BCEWithLogitsLoss` 와데이터증강 (부분집합샘플링, 순환이동, 비트플립노이즈) 을사용한다. 추론시적응형임계값 $\theta = \text{quantile}(P, 1 - \rho_{\text{on}})$ 으로원곡 ON 비율 $\rho_{\text{on}} \approx 0.15$ 를맞춘다.

IV. 실험

모든실험은 $N = 20$ 회독립반복으로수행하였다. 주요지표는 pitch JS divergence 이다.

A. 거리함수비교

DFT 가 *hibari* 에서최적이다: frequency 대비 -38.2%, Tonnetz 대비 -56.8%, voice-leading 대비 -62.4% (표 I).

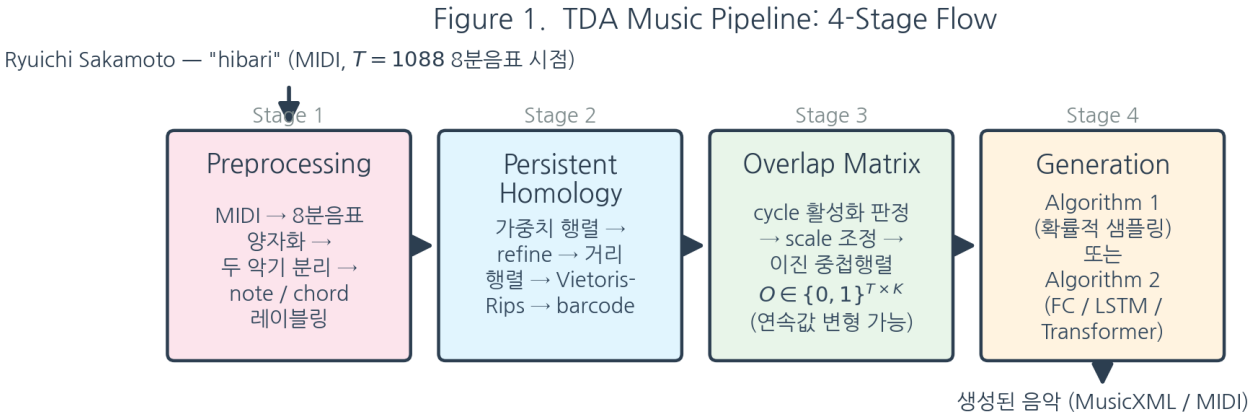

Fig. 1. 4 단계파이프라인: (1) MIDI 전처리, (2) persistent homology, (3) 중첩행렬구축, (4) Algorithm 1 또는 2 에의한생성.

TABLE II
CYCLE 부분집합절제 (TONNETZ, $N = 20$).

K	JS (평균 ± 표준편차)	Coverage
10	0.0991 ± 0.0038	0.980
17	0.0740 ± 0.0038	0.996
46	$\mathbf{0.0397 \pm 0.0025}$	1.000

TABLE III
연속값중첩행렬실험 (TONNETZ, $N = 20$).

설정	Density	JS (평균 ± 표준편차)
이진 (캐시)	0.751	0.0387 ± 0.0027
연속값직접사용	0.264	0.0382 ± 0.0021
연속 → 이진 τ=0.3	0.373	0.0386 ± 0.0022
연속 → 이진 τ=0.5	**0.168**	$\mathbf{0.0343 \pm 0.0027}$
연속 → 이진 τ=0.7	0.077	0.0364 ± 0.0032

B. 옥타브가중치튜닝

DFT 조건에서 $w_o \in \{0.1, 0.3, 0.5, 0.7, 1.0\}$ 격자탐색 ($N = 10$) 을수행한결과, $w_o = 0.3$ 이최적 (JS 0.0163) 이며 *hibari* 의좁은음역특성과일치한다.

C. *Cycle* 부분집합절제

JS 는 K 에대해단조감소하지만수확체감이나타난다 (표 II): K: 17 → 46 (29 개추가) 의이득이 K: 10 → 17 (7 개추가) 을근소하게만초과한다.

D. 연속값중첩행렬

연속값중첩행렬에 $\tau = 0.5$ 이진화를적용하면이진기준선대비 11.4% 추가개선된다 (Welch $t = 5.16$, $p < 0.001$, $d = 1.63$; 표 III). 희귀도가중으로드문 note 가활성화에더크게기여한다.

TABLE IV
최적 DL 설정 (각 1 회실행).

모델	Val Loss	JS	생성 Note 수
FC (hd=256, do=0.3)	0.282	**0.0015**	3,754
LSTM (2 층)	0.385	0.0448	3,753
Transformer (2L, 4H)	0.676	0.0104	3,753

TABLE V
FC 에대한연속 VS. 이진입력 ($N = 5$).

입력	JS (평균 ± 표준편차)	Val Loss	Coverage
이진	0.0014 ± 0.0010	0.070	0.948
연속	$\mathbf{0.0006 \pm 0.0005}$	**0.031**	**0.991**

E. 심층학습모델비교

가장단순한 FC 모델이최저 JS 를달성한다 (표 IV). 이는 *hibari* 의미학을반영한다: *out of noise* 는시간적인과보다음의공간적배치를중시하므로, 시간문맥을무시하는 FC 가작곡설계와더잘부합한다.

F. 개선 *F:* 연속값중첩행렬 + *FC*

연속값활성화를 FC 의학습입력으로직접사용:
연속입력은 JS 를 57%, val loss 를 2.3 배감소시킨다 (표 V). 본연구에서관측된최저전곡 JS 이다 (이론적최댓값 $\log 2$ 의 0.09%).

G. 곡고유구조분석

a) Deep scale 특성: *hibari* 의 7 개 pitch class $\{C, D, E, F, G, A, B\}$ 는음정벡터 $[2, 5, 4, 3, 6, 1]$ 을가지며, 모든성분이상이하다. 이는온음계고유의특성이다 [15].

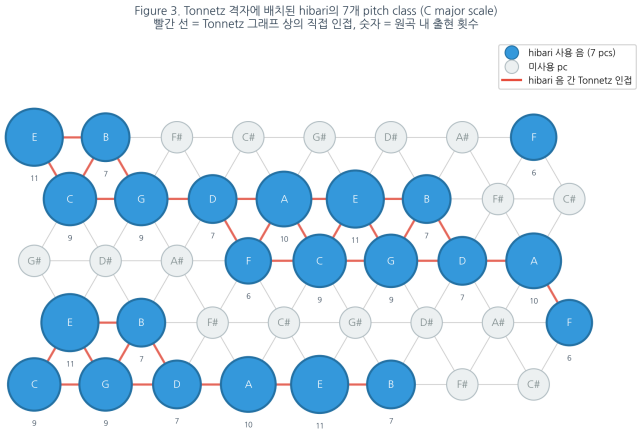

Fig. 2. Tonnetz 격자위의 *hibari* 7 개 pitch class (파란색). 빨간간선은직접 Tonnetz 인접을나타낸다.

b) 준균등 pitch 분포: 정규화 pitch 엔트로피가 0.974 (거의최대) 이다. 모든 pitch 가거의동일확률로나타나므로, 시간순서를무시하는 FC 가이미참분포를잘근사함을설명한다.

c) Tonnetz 판별력: 7 개 PC 에서 Tonnetz 직경은 4 로, 세밀한거리판별이가능하다. 12 개 PC(*solari* 등) 에서는직경이 2 로축소되어 Tonnetz 의이점이사라진다.

d) 위상이동 (Phase shifting): 악기 1 은 32-step 모듈을 33 회반복 (쉼없음); 악기 2 는 33-step 모듈을 32 회반복 (모듈당쉼 1 회). 서로소주기 ($\gcd(32, 33) = 1$) 에의해두악기는결코동기화되지않는다. Steve Reich 의 *phase shifting* 기법과수학적으로동일한구조이다.

V. 시각자료

6 개의정적도표와 1 개의대화형 HTML 보충자료를제공한다. 그림 1은파이프라인을, 그림 2는 Tonnetz 격자위의 pitch class 를, 그림 3는 persistence barcode 를, 그림 4은원곡/생성피아노롤비교를, 그림 5는 epoch 별 JS 수렴곡선을보여준다.

VI. 관련연구와의비교

A. 일반 AI 음악생성과의비교

코퍼스기반학습모델 (Magenta, Music Transformer) 과달리, 본파이프라인은 단일곡에대한심층분석을수행하여해석가능하고추적가능한생성을실현한다. FC > Transformer 라는결과는 "더많은시간적모델링이항상우월하다" 는보편적가정에도전한다.

B. 기존 TDA–음악연구와의비교

선행 TDA–음악연구 [6], [7] 와비교하여: (A) 네가지거리함수를 N=20 통계로체계적비교; (B) 연속값중첩행렬도입; (C) 완전한통계적엄밀성 (Welch t, Cohen's d) 제공; (D) 서양현대음악으로확장; (E) 모델선택과미학적맥락의연결; (F) TDA 를분석에서 변주로확장 (§VII).

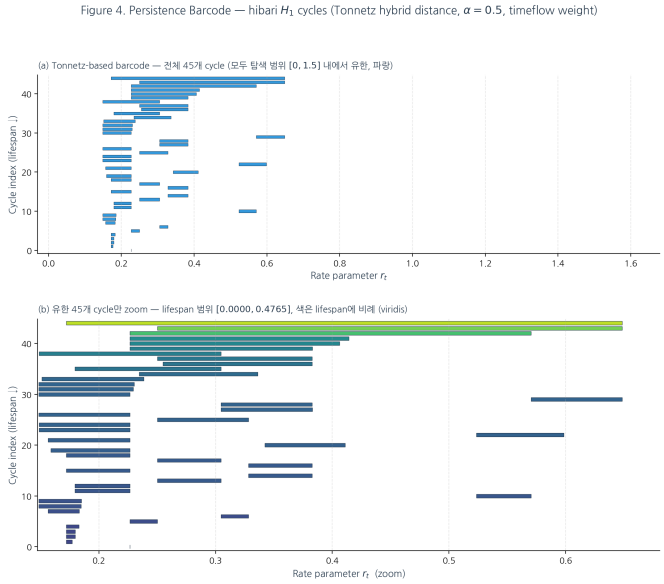

Fig. 3. H_1 persistence barcode (Tonnetz). 위: 전체 barcode; 아래: 유한 cycle 확대. 수명범위가 10,000 배이상차이난다.

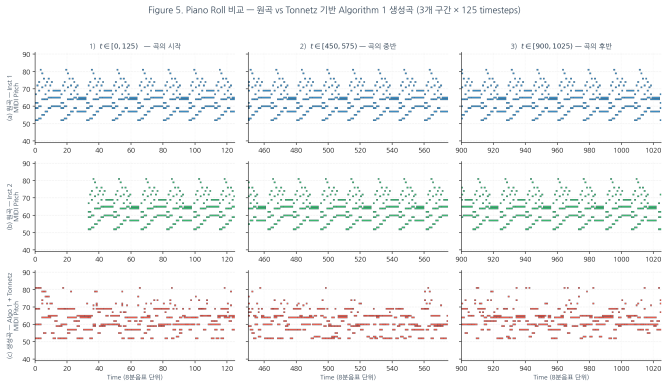

Fig. 4. 피아노롤비교: (a)–(b) 원곡악기 1–2; (c) Algorithm 1 + Tonnetz.

VII. 확장실험

A. 모듈단위생성

hibari 의 32-step 모듈구조를바탕으로, 단일모듈을생성하여전타임라인에복제하는설정을실험하였다. DFT $\alpha = 0.25$ 에서모듈 PH 는 $K = 14$ cycle(프로토타입중첩행렬크기: 32×14) 을갖는다. 먼저네가지프로토타입전략을비교하였다:

- **P0**: 첫모듈복사
- **P1**: 활성 cycle 합집합
- **P2**: 모듈고유 cycle
- **P3**: 모듈별활성중앙값기반선택

이후모듈설정위에후처리개선전략을추가평가하였다:

33 개시작모듈전수탐색결과, DFT 모드에서모듈 0 은평균 JS 기준 rank 5 로최적이아니다. 전역최저단일시행은 start module 1, seed 9309 에서 JS = 0.01479 이며, 전곡 per-cycle 최적값 (0.01489) 과사실상동일하다.

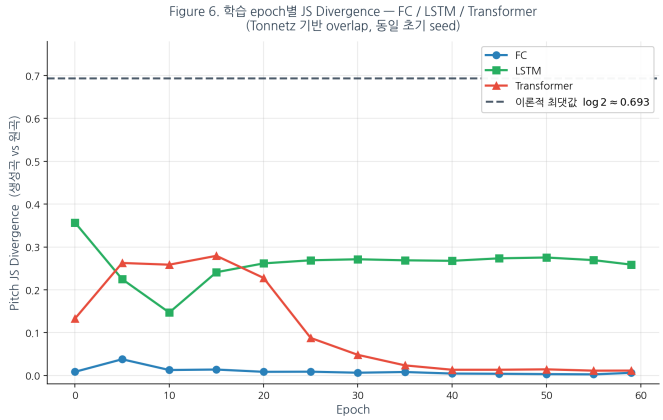

Fig. 5. 학습 epoch 에따른 JS divergence. FC 가가장빠르게수렴; LSTM 은 JS ≈ 0.26 에서정체.

TABLE VI
프로토타입전략비교 (DFT $\alpha = 0.25$, $N = 10$).

전략	Density	JS (평균 ± 표준편차)	최저
P0	0.018	0.1040 ± 0.0219	0.0698
P1	1.000	0.0621 ± 0.0167	0.0422
P2	0.000	0.0900 ± 0.0308	0.0515
P3	0.299	0.0474 ± 0.0187	0.0226

B. 일반화: solari, *Bach, Ravel*

DFT 가최적인곡은 *hibari* 에한정되며, *solari/aqua/*Bach/Ravel 에서는 Tonnetz 또는 frequency 가우세하다. 이는단일보편거리함수보다목적·곡특성조건부 (metric-conditioned) 설계가필요함을시사한다.

C. 방향 *A:* 두전략의 *Note* 재분배

변주단계에서는실험축을 Tonnetz 기반으로고정한다. 음계제약과국소화성이웃구조를보존하는목적에서 Tonnetz 가 DFT 보다자연스럽기때문이다. 중첩행렬은 그대로유지하고 note 정체성만바꾼다. $n_{\text{cand}} = 1000$ 후보 pitch 집합 ($N = 20$, *hibari*, Tonnetz, MIDI 48–84) 에서두개의배타적매칭전략을비교한다.

전략 A — 위치기반 Tonnetz 최근접 (`tonnetz_nearest`):

$$\text{new_pitches}[i] = \arg\min_{p \in \text{pool}} d_{\text{Tonnetz}}(\text{orig_pitches}[i], p). \tag{5}$$

각원본 note 는 Tonnetz 거리최소후보로치환되며, 인덱스 i 의 1:1 위치대응을통해국소화성관계를유지한다.

전략 B — 행렬구조 Hungarian 매칭 (`ascending`):

$$\pi^* = \arg\min_{\pi} \left\| P_\pi \hat{D}_{\text{new}} P_\pi^\top - \hat{D}_{\text{orig}} \right\|_F, \tag{6}$$

여기서 $\hat{D}$ 는비대각원소를 min-max 정규화한거리행렬:

$$\hat{D}_{ij} = \frac{D_{ij} - \min_{k \neq l} D_{kl}}{\max D - \min_{k \neq l} D_{kl}}, \quad \hat{D}_{ii} = 0. \tag{7}$$

행/열동시순열의정확해는 NP-hard 이며, $N = 17$ note 일때 $N! = 3.56 \times 10^{14}$ 전수평가는불가능하므로모든실험은 Hungarian 근사 (`scipy.optimize.linear_sum_assignment`) 를사용한다.

두전략의공통오차지표는 **note_dist_error** $= \|\hat{D}_{\text{orig}} - \hat{D}_{\text{new}}\|_F$ 이다. 두전략을동시에적용하면 (전략 A 의위치의미가전략 B 순열로덮임) 성능이악화되므로 `matching_mode` 로배타적용한다.

전략 A 는 pitch JS 0.2930 으로전략 B 의 0.3815 대비 -23.2% 우수하다 (표 IX). *hibari* 처럼음 vocabulary 가작은경우 ($N = 17$), 인접 Tonnetz 관계를보존하는국소쌍별화성보존 (A) 이전역거리행렬정합 (B) 보다효과적이다. 또한 vwide(MIDI 40–88) 는모든조건에서 wide(48–84) 보다열세여서 wide 를채택한다.

D. 방향 *B:* 시간재배치

시간재배치는 block permutation 과 Markov resampling 으로평가하였다. 모델별반응은아키텍처의존적이다: FC 는시간점독립에가까워재배치영향이거의없고, LSTM 은 실측 DTW 변화가 $\leq 0.5\%$ 로미미하며, Transformer 는 positional encoding(PE) 에민감하다. PE 제거후재학습하면 Transformer DTW 를 $+21.7\%$ 까지높일수있지만 pitch JS 가악화되어 (분포붕괴), 방향 B 단독으로는 "다른멜로디" 와 "안정된 pitch 분포" 를동시에충족하지못한다.

E. 화성제약

Note 재분배에음계제약 (major, minor, pentatonic) 과협화목표를추가하였다. **scale_major** 가가장효과적이다: note 오차 $4.35 \rightarrow 3.52$ (-19%), 음계일치 1.00, 평균불협화도 $0.412 \rightarrow 0.361$.

F. *A+B* 결합: 최종통합

1) Tonnetz 기반성공: Tonnetz 에서 **major_block32** (scale_major 재분배 + block permutation(32) + 연속중첩행렬 + Transformer) 는 ref pJS $= 0.0034$, DTW $+31\%$, C major 음계일치 $= 1.00$ 을달성한다.

2) DFT 전이실패: 동일한결합설정을 DFT 로이전하면, DTW 는증가해도 ref pJS 가크게악화된다 (Transformer 0.0798, FC 0.0412). 즉 Tonnetz 에서설계된변주스택은동일목적에서 DFT 로직접전이되지않는다.

TABLE VII
모듈단위개선성능 (DFT, 전곡기준선 0.0213 ± 0.0021).

전략	JS (평균 ± 표준편차)	최저	Cov.
P0 기준선	0.1082 ± 0.0241	0.0701	0.826
C: best-of-10	0.0800 ± 0.0171	0.0570	0.913
D: cov≥20/23	0.0808 ± 0.0171	0.0570	0.887
P3_local	0.0721 ± 0.0275	0.0288	0.813
P3_local + C	$\mathbf{0.0440 \pm 0.0158}$	**0.0250**	0.896

TABLE VIII
교차곡비교요약 (Algorithm 1 거리함수비교).

곡	PC 수	최적거리	최적모델	해석
hibari	7	DFT	FC	스펙트럼-온음계구조
solari	12	freq./Ton. (동률)	Transformer	선율적진행
aqua	12	Tonnetz	—	Tonnetz $+26.3\%$
Bach	12	Tonnetz	—	Tonnetz -54.8%
Ravel	12	frequency	—	풍부한음분포

TABLE IX
두전략비교 (Algorithm 1, Tonnetz, MIDI 48–84, $N = 20$, $n_{\text{cand}} = 1000$).

전략	pitch JS	trans. JS	DTW	note err
기준선 (원곡)	0.0212	0.2470	2.2186	—
B: ascending (Hungarian)	0.3815	0.6121	2.7918	4.6819
A: `tonnetz_nearest`	**0.2930**	**0.5488**	2.6442	**3.2132**

TABLE X
Cycle 별 τ_c 최적화 (DFT, $N = 20$).

설정	JS (평균 ± 표준편차)	개선율
균일 $\tau = 0.35$	0.03605 ± 0.00237	—
단일 $\tau = 0.5$	0.01591 ± 0.00192	+55.9%
Cycle 별 τ_c	$\mathbf{0.01489 \pm 0.00143}$	**+58.7%**

3) 메타통찰*:* 거리함수선택은목적의존적이다: DFT 는구조정밀도·모듈탐색에강하고, Tonnetz 는화성제약변주품질에강하다.

G. Cycle 별임계값최적화

DFT 연속중첩행렬에서각 cycle 의 $\tau_c \in \{0.1, 0.2, \ldots, 0.7\}$ 에대해탐욕적좌표하강을수행한다:

Cycle 별최적화는본연구의 Algorithm 1 최고성능 (0.01489 ± 0.00143) 에도달한다. 균일 $\tau = 0.35$ 대비 Welch $p = 2.48 \times 10^{-26}$ 로유의하며, cycle 별활성스케일의중요성을보여준다.

H. Soft Activation: 전체아키텍처

연속입력 FC 가최적 (JS = 0.000348) 이며, FC-cont 는 Transformer-cont 대비유의하게우수하다 (Welch $p = 1.66 \times 10^{-4}$).

I. DFT-Hybrid α 격자탐색

DFT-hybrid 에서는양끝점 ($\alpha = 0.0, 1.0$) 이모두축퇴 ($K = 1$) 를보인다. 최적절충점은 $\alpha = 0.25$ 이며 (채택), $\alpha = 0.5$ 는초기실험에서의역사적기본값으로유지된다.

J. Barcode Wasserstein 모듈선택

DFT $\alpha = 0.25$ 에서 33 개시작모듈의국소 barcode 와전곡 barcode 의 Wasserstein 거리를비교한결과, 생성 JS 와의상관은 **Pearson** $r = -0.054$ 로사실상무상관이다. 따라서이 DFT 조건에서 Wasserstein 기반모듈순위화는신뢰하기어렵다.

이는 Tonnetz 에서의이전관찰 ($r = 0.503$) 과반대이며, barcode-Wasserstein 의유효성이거리함수의존적임을시사한다. 세가지주의점은다음과같다:

1) **화음공간불일치**: 32-step 모듈의 chord vocabulary 는전곡 vocabulary 의진부분집합이며, 결과 barcode 가더작은복합체에서형성된다.
2) **단일악기한계**: 모듈국소 PH 는단일악기시퀀스만사용하므로, 큰 JS 개선에기여하는악기간가중정보가누락된다.
3) **스케일민감도**: W_1 는 birth/death 절대스케일에민감하며, 32-step 과 1088-step filtration 간좌표스케일이다르다.

TABLE XI
이진 vs. 연속입력 (DFT, $N = 10$).

모델	입력	JS	Val Loss	ΔJS
FC	이진	0.00217	0.3395	—
FC	**연속**	**0.000348**	**0.0232**	**+84.0%**
Trans.	이진	0.00251	0.836	—
Trans.	연속	0.000818	0.152	+67.4%
LSTM	이진	0.233	0.408	—
LSTM	연속	0.170	0.395	+27.3%

TABLE XII
DFT-hybrid α 격자탐색 ($N = 20$).

α	K	JS (평균 ± 표준편차)	비고
0.0 (순수 DFT)	1	0.0728 ± 0.00432	축퇴
0.1	13	0.01602 ± 0.00204	
0.25	**14**	0.01593 ± 0.00181	최적
0.3	16	0.02025 ± 0.00134	
0.5	19	0.01691 ± 0.00143	과거기본값
0.7	24	0.03140 ± 0.00270	
1.0 (순수 freq.)	1	0.03386 ± 0.00186	축퇴

관련하여 complex(simul-mixed) 가중은 Tonnetz 에서는유효하지만 DFT 에서는성능을저하시켜, DFT 본실험에서는 timeflow-only 를유지한다.

VIII. 결론

본연구는 persistent homology 로음악의위상구조를추출하고그구조를보존하면서새로운음악을생성하는통합파이프라인을제시하였다. 주요발견:

1) **거리함수선택은결정적이지만곡의존적이다.** *hibari* 에서 DFT 는 frequency 대비 38.2%, Tonnetz 대비 56.8%, voice-leading 대비 62.4% 우수하다. 그러나곡전체를보면최적거리는 DFT/Tonnetz/frequency 로달라진다.
2) **모델최적성은곡의성격을따른다.** *hibari* 는 FC 가, *solari* 는 Transformer 가유리하다. DFT 연속입력에서 FC 는 Transformer 보다유의하게우수하다 (Welch $p = 1.66 \times 10^{-4}$).
3) **연속중첩행렬정교화의효과가크다.** Per-cycle τ_c 는 0.01489 ± 0.00143 (균일 $\tau = 0.35$ 대비 +58.7%), FC-cont 는 0.00035 ± 0.00015 를달성한다.
4) **모듈단위생성은전곡품질에근접가능하다.** P3_local+C 의단일시행최저는 0.0250 이며, 33 개시작모듈전수탐색전역최저는 0.01479 로전곡최적 0.01489 와사실상동등하다.
5) **Complex/simul 및 Wasserstein 은거리함수의존적이다.** DFT 에서는 simul 혼합이성능을저하시키고, barcode-Wasserstein 상관이붕괴한다 ($r = -0.054$).
6) **거리함수 × 목적정렬이메타원리다.** DFT 는구조정밀도에, Tonnetz 는화성제약변주품질에강하다.

본연구는 TDA 가분석도구일뿐아니라 음악창작을위한제약생성기로기능할수있음을보여주며, 수학적위상과작곡미학사이의다리를놓는다.

감사의글

본연구는고등과학원 (KIAS) 초학제독립연구단의정재훈교수의지도하에수행되었다. 한국전통음악선행연구 [7] 로부터계승된 pHcol 구현과파이프라인설계에감사를표한다.

References

[1] G. Carlsson, "Topology and data," *Bulletin of the AMS*, vol. 46, no. 2, pp. 255–308, 2009.
[2] H. Edelsbrunner and J. Harer, *Computational Topology: An Introduction*. AMS, 2010.
[3] D. Tymoczko, "The generalized Tonnetz," *J. Music Theory*, vol. 56, no. 1, 2012.
[4] D. Tymoczko, "Set-class similarity, voice leading, and the Fourier transform," *J. Music Theory*, vol. 52, no. 2, 2008.
[5] U. Bauer, "Ripser: Efficient computation of Vietoris–Rips persistence barcodes," *J. Applied and Computational Topology*, vol. 5, pp. 391–423, 2021.
[6] M. L. Tran, C. Park, and J.-H. Jung, "Topological data analysis of Korean music in Jeongganbo," *arXiv:2103.06620*, 2021.
[7] D.-J. Lee, M. L. Tran, and J.-H. Jung, "Geometric structure and AI composition of Korean traditional music," 2024.
[8] E. Heo, B. Choi, and J.-H. Jung, "Persistent homology with path-representable distances on graph data," *arXiv:2501.03553*, 2025.
[9] G. L. Nemhauser, L. A. Wolsey, and M. L. Fisher, "An analysis of approximations for maximizing submodular set functions," *Math. Programming*, vol. 14, no. 1, pp. 265–294, 1978.
[10] B. L. Welch, "The generalization of 'Student's' problem when several different population variances are involved," *Biometrika*, vol. 34, pp. 28–35, 1947.
[11] J. Cohen, *Statistical Power Analysis for the Behavioral Sciences*, 2nd ed. Lawrence Erlbaum, 1988.
[12] S. Hochreiter and J. Schmidhuber, "Long short-term memory," *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.
[13] A. Vaswani *et al.*, "Attention is all you need," in *Proc. NeurIPS*, 2017.
[14] R. Sakamoto, *out of noise* [Album]. commmons, 2009.
[15] C. Gamer and R. Wilson, "Microtones and projective planes," in *Music and Mathematics*. Oxford University Press, 2003.