사카모토류이치의 *hibari* 에대한위상적데이터분석

Persistent Homology 기반구조보존음악생성파이프라인

김민주

초학제독립연구단
고등과학원 (KIAS)
서울, 대한민국

2026

Abstract

본연구는음악의위상적구조를 persistent homology 로추출하고, 그구조를보존하면서새로운음악을생성하는파이프라인을제안한다. 사카모토류이치의 *hibari* (2009 년앨범 *out of noise* 수록) 에적용하여, (i) MIDI 양자화로부터가중 note 네트워크를구성하고, (ii) 네가지거리함수 (frequency, Tonnetz, voice-leading, DFT) 로 H_1 persistent homology 를계산하며, (iii) 시간축에따른 cycle 활성화를기록하는중첩행렬을구축하고, (iv) 확률적샘플링 (Algorithm 1) 또는심층학습 (Algorithm 2; FC / LSTM / Transformer) 으로음악을생성한다.

$N = 20$ 회독립반복실험에서, Algorithm 1 기준 DFT 거리가 frequency 대비 pitch JS divergence 를 $0.0344 \pm 0.0023 \to 0.0213 \pm 0.0021$ 로 38.2% 감소시켰다 (Welch $p < 10^{-20}$). 또한 DFT continuous OM 에서 per-cycle τ_c (Phase 1, $\alpha = 0.5$) 적용: JS 0.01489 ± 0.00143 (+58.7%). Phase 2 ($\alpha = 0.25$, $K = 14$) 재탐색으로신기록 $\mathbf{0.01156} \pm \mathbf{0.00147}$ (−22.35%, $p = 4.94 \times 10^{-11}$). (Welch $p = 2.48 \times 10^{-26}$), Algorithm 1 최저성능을달성한다. Algorithm 2 에서는 FC + continuous 입력이 $\mathbf{0.00035} \pm \mathbf{0.00015}$ ($N = 10$) 로최우수이며, Transformer 대비 Welch $p = 1.66 \times 10^{-4}$ 로유의우위다.

모듈단위생성 (DFT $\alpha = 0.25$, $K = 14$) 에서는 P3_local + C 조합의 best trial 이 0.0250 이고, 33 개시작모듈전수탐색의전역최저 trial 은 **0.01479** 로전곡 Phase 1 최저 (0.01489) 와동등 ($\alpha = 0.25$ 신기록 0.01156 대비 +28.0% 열세). 이결과는거리함수의절대우열보다 "거리함수 × 음악적목적" 정합성이핵심임을보여준다.

키워드: Persistent homology, 위상적데이터분석, 음악생성, Tonnetz, Jensen–Shannon divergence, 다중레이블분류, Vietoris–Rips 복합체, 중첩행렬

Contents

1 서론 **4**
1.1 연구질문 4
1.2 왜 *hibari* 인가 4
1.3 기여 4

2 수학적배경 **5**
2.1 Vietoris–Rips 복합체 5
2.2 Persistent Homology 5
2.3 음악적거리함수 5
2.4 가중치분해와 Rate 파라미터 6
2.5 중첩행렬 6
2.6 Jensen–Shannon Divergence 6
2.7 탐욕적전진선택 7

3 파이프라인과생성알고리즘 **7**
3.1 1 단계: 전처리 7
3.2 2 단계: Persistent Homology 7
3.3 3 단계: 중첩행렬 7
3.4 Algorithm 1 — 위상적샘플링 7
3.5 Algorithm 2 — 신경망시퀀스모델 8

4 실험 **8**
4.1 거리함수비교 8
4.2 옥타브가중치튜닝 8
4.3 Cycle 부분집합절제 8
4.4 연속값중첩행렬 9
4.5 심층학습모델비교 9
4.6 개선 F: 연속값중첩행렬 + FC 9
4.7 곡고유구조분석 10

5 시각자료 **10**

6 관련연구와의비교 **12**
6.1 일반 AI 음악생성과의비교 12
6.2 기존 TDA–음악연구와의비교 12

7 확장실험 **12**
7.1 모듈단위생성 12
7.2 일반화: *solari*, Bach, Ravel 13
7.3 방향 A: 위상보존 Note 재분배 13
7.4 방향 B: 시간재배치 14
7.5 화성제약 14

7.6 A+B 결합: 최종통합 14
7.6.1 6.6.1 Tonnetz 기반성공사례 14
7.6.2 6.6.2 DFT 전환실패사례 14
7.6.3 6.6.3 메타통찰 14
7.7 Cycle 별임계값최적화 14
7.8 Soft Activation: 전체아키텍처 15
7.9 DFT-Hybrid α 격자탐색 16
7.10 Barcode Wasserstein 모듈선택 16

8 결론 **16**

1. 서론

위상적데이터분석 (Topological Data Analysis, TDA) 은데이터로부터노이즈와스케일에강건한기하학적구조를추출하는수학적도구이다 [1, 2]. 본연구는 TDA 를특정음악작품 — 사카모토류이치의 *hibari* — 에적용하여, 1 차 persistent homology 군 H_1 의불변량이새로운음악생성의구조적씨앗 (seed) 으로기능할수있는지를탐구한다.

1.1 연구질문

1. 음악의위상구조를 Vietoris–Rips H_1 persistence 로어떻게수학적으로정의할수있는가?
2. 이구조를 보존한채새로운음악을생성할수있는가? 보존정도를어떻게정량적으로측정하는가?
3. 거리함수의선택 (frequency, Tonnetz, voice-leading, DFT) 이생성품질에유의미한영향을주는가?

1.2 왜 *hibari* 인가

hibari 는사카모토류이치의실험적앨범 *out of noise* (2009) 수록곡이다. 선택이유:

- **적절한규모**: $T = 1{,}088$ 개 8 분음표시점, $N = 23$ 고유 note, $C = 17$ 화음.
- **단순함과복잡함의균형**: 7 개 pitch class (C major) 의조성적단순함과, 서로소주기구조의두악기 (§4.7) 가만드는복잡함.
- **미학적특수성**: 시간적인과보다음의 공간적배치를중시하는미학으로, 모델선택결과 (§4.5) 와직접공명.

1.3 기여

1. 4 단계파이프라인 (전처리 → PH → 중첩행렬 → 생성) 과두종류의생성기, 네가지거리함수제시.
2. $N = 20$ 통계적비교를통한 Tonnetz 의온음계곡최적성확립.
3. Cycle 별임계값을가진연속값중첩행렬로 JS 를추가 47.5% 개선 (§7.7).
4. Tonnetz 매칭 note 재분배, 시간재배치, 화성제약을통한위상보존변주 (§7).
5. *solari*, Bach, Ravel 에대한교차검증으로, 곡의성격이최적거리함수와모델을결정함을확인 (§7.2).

2. 수학적배경

2.1 Vietoris–Rips 복합체

정의 2.1. 유한거리공간 (X, d) 와 $\varepsilon > 0$ 에대해, Vietoris–Rips 복합체 $\mathrm{VR}_\varepsilon(X)$ 는다음과같이정의되는단체복합체이다:

$$\mathrm{VR}_\varepsilon(X) = \{\sigma \subseteq X \mid \forall x_i, x_j \in \sigma,\ d(x_i, x_j) \leq \varepsilon\}.$$

ε 이증가함에따라포함관계 $\mathrm{VR}_0 \subseteq \mathrm{VR}_{\varepsilon_1} \subseteq \cdots$ 가 *filtration* 을이룬다. 본연구에서 X 는 *hibari* 의 23 개고유 note 이다.

2.2 Persistent Homology

n 차호몰로지군 $H_n(K) = \ker \partial_n / \mathrm{im}\, \partial_{n+1}$ 은 n 차원 "구멍" 을포착한다. 본연구는위상적 cycle 에해당하는 H_1 에집중한다. *Persistent homology* 는 filtration 을따라각 cycle 의탄생 (birth) b 와소멸 (death) d 를추적하며, $\mathrm{pers} = d - b$ 가안정성을측정한다.

주로선행연구 [7, 8] 의 pHcol 알고리즘 (cycle 대표원포함) 을사용하고, 속도가중요한단계에서는 Ripser [6] 로보완한다.

2.3 음악적거리함수

Note $n_i = (p_i, d_i)$ 간의네가지거리함수를비교한다.

Frequency 거리 (기준선) $d_{\mathrm{freq}}(n_i, n_j) = 1/w(n_i, n_j)$. w 는화음시퀀스에서의인접빈도이다.

Tonnetz 거리 Pitch class 를 $\pm 3, \pm 4, \pm 7$ 반음 (단 3 도, 장 3 도, 완전 5 도) 간선을가진육각격자에배치한다. 최단경로거리를 12×12 테이블 (범위 0–4) 로사전계산한다 [4].

Voice-leading 거리 $d_V(p_1, p_2) = |p_1 - p_2|$, 부호없는반음차이 [5].

DFT 거리 Pitch class 를 $\mathbb{R}^{12}$ 지시벡터로표현하고, 처음 6 개 DFT 크기간의 L_2 거리를사용한다 [5].

혼합거리와 note 수준확장 모든음악이론적거리는 frequency 와 $d_{\mathrm{hybrid}} = \alpha\, d_{\mathrm{freq}} + (1-\alpha)\, d_{\mathrm{music}}$ ($\alpha \in [0, 1]$) 로결합된다. Note 수준에서옥타브항과 duration 항이추가된다:

$$d(n_1, n_2) = d_{\mathrm{base}} + w_o |o_1 - o_2| + w_d \frac{|d_1 - d_2|}{\max(d_1, d_2)}, \tag{1}$$

여기서 $w_o = 0.3$ (격자탐색으로최적화, §4.2), $w_d = 0.3$ 이다.

주석 — metric 공리와이론적정당성 실험적검증에따르면, Tonnetz 와 voice-leading 은 metric 공리를모두만족하나, frequency 는 identity 공리 (23 건) 및삼각부등식 (1,327 건) 을위반하며 (non-metric), dft 는 identity 공리 (66 건) 를위반한다 (pseudometric — magnitude-only 설계의의도된귀결). Cohen-Steiner et al. [3] 의고전적 stability 정리 (metric 입력에대해

$d_B \le \|d_1 - d_2\|_\infty$ 보장) 는따라서이두거리에직접적용할수없다. 대신 Heo et al. [9] 를적용한다: 거리행렬 D 를완전그래프 K_n 의 edge weight 로부여하면 path-representable + cost-dominated 조건이자명하게성립하며, Theorem 3.4 에의해 $d_i \le d_j$ 관계하에서 $\mathrm{bcd}_1(d_i) \hookrightarrow \mathrm{bcd}_1(d_j)$ 의 order-preserving injection 이보장된다. 따라서네거리함수모두에서 1-cycle 분석은이론적으로 정당화된다 ($k \ge 2$ 에는미적용 — [9] 의 Theorem 5.1).

2.4 가중치분해와 Rate 파라미터

Note 네트워크가중치는 *hibari* 의두악기구조를반영하여세성분으로분해된다:

- **Intra 가중치** W_{intra}: 악기내순차전이.
- **Inter 가중치** W_{inter}: 악기간전이, lag $\ell \in \{1, 2, 3, 4\}$ 에대해감쇄가중:

$$W_{\text{inter}} = \sum_{\ell=1}^{4} \lambda_\ell W_{\text{inter}}^{(\ell)}, \quad (\lambda_1, \ldots, \lambda_4) = (0.4, 0.3, 0.2, 0.1). \tag{2}$$

  이감쇄가중은 JS 를 69.6% 감소시켰다 ($0.0398 \to 0.0121$).

- **Simul 가중치** W_{simul}: 동시발음공기.

Timeflow 가중치 $W_{\text{tf}}(r) = W_{\text{intra}} + r \cdot W_{\text{inter}}$ 를 $r \in [0, 1.5]$ 에걸쳐스윕한다.

2.5 중첩행렬

정의 2.2 (활성화행렬)**.** $A[t, c] = \mathbb{1}[\exists\, n \in V(c)$ 가시점t에서연주됨$]$.

정의 2.3 (이진중첩행렬)**.** $O[t, c] = \mathbb{1}[t \in R(c)]$. $R(c)$ 는길이 $\ge \mathrm{scale}_c$ 인지속활성화구간의합집합이다.

정의 2.4 (연속값중첩행렬)**.**

$$O_{\text{cont}}[t, c] = \frac{\sum_{n \in V(c)} w(n) \cdot \mathbb{1}[n \text{ at } t]}{\sum_{n \in V(c)} w(n)}, \tag{3}$$

여기서 $w(n) = 1/N_{\text{cyc}}(n)$ 은희귀도가중치이다.

중첩행렬 O 는두생성기가공통으로사용하는 *seed* 이다.

2.6 Jensen–Shannon Divergence

이산분포 P, Q 에대해:

$$D_{\text{JS}}(P\|Q) = \tfrac{1}{2} D_{\text{KL}}(P\|M) + \tfrac{1}{2} D_{\text{KL}}(Q\|M), \quad M = \tfrac{1}{2}(P + Q). \tag{4}$$

상한은 $\log 2 \approx 0.693$ 이다. Pitch JS(note 빈도분포) 와 transition JS(bigram 분포) 를측정한다.

2.7 탐욕적전진선택

Cycle 부분집합 $S \subseteq \mathcal{C}$ 를 $f(S) = 0.5\,J(S) + 0.3\,C(S) + 0.2\,B(S)$ 로선택한다. J 는 note 풀 Jaccard 유사도, C 는중첩패턴 Pearson 상관, B 는 Betti 곡선유사도이다. 탐욕적선택으로 15/46 cycle 만으로 90% 보존을달성한다.

3. 파이프라인과생성알고리즘

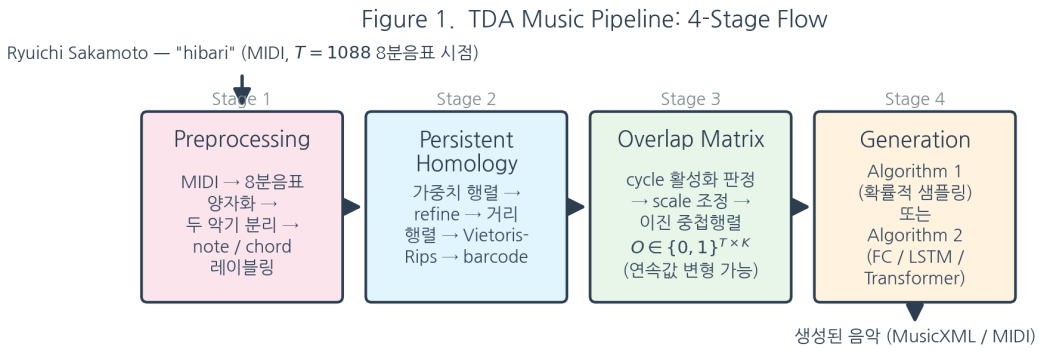

Figure 1: 4 단계파이프라인: (1) MIDI 전처리, (2) persistent homology, (3) 중첩행렬구축, (4) Algorithm 1 또는 2 에의한생성.

3.1 1 단계: 전처리

MIDI 파일을 8 분음표단위로양자화하고 ($T = 1{,}088$), 두악기를분리하며, 각고유 (pitch, duration) 쌍에 1-indexed 레이블을부여한다 (*hibari*: $N = 23$ note, $C = 17$ 화음).

3.2 2 단계: Persistent Homology

가중 note 네트워크를구성하고 (§2.4), 거리행렬을유도하여 $r \in [0, 1.5]$ 에걸친 H_1 filtration 을 계산한다.

3.3 3 단계: 중첩행렬

모든시점에서 cycle 활성화를계산하고임계값을적용한다 (§2.5).

3.4 Algorithm 1 — 위상적샘플링

각시점 t 에대해:

- 활성 cycle 이존재하면 ($\sum_c O[t,c] > 0$): 교집합 $I(t) = \bigcap_{c:O[t,c]=1} V(c)$ 에서샘플링. $I(t) = \emptyset$ 이면합집합 $U(t)$ 로대체.
- 활성 cycle 이없으면: 인접활성 cycle vertex 의여집합 $P \setminus A(t)$ 에서샘플링 (위상적 "번짐" 방지).

- 충돌회피: 시점당최대 $R = 50$ 회재샘플링.

3.5 Algorithm 2 — 신경망시퀀스모델

매핑 $f_\theta : O[t,:] \mapsto y[t,:]$ 을학습하는세가지아키텍처:

- **FC**: 2 층완전연결 ($H = 128$), 시점독립.
- **LSTM**: 2 층, 순방향시퀀스문맥.
- **Transformer**: 2 층, 4-head, 학습가능위치임베딩.

모든모델은 `BCEWithLogitsLoss` 와데이터증강 (부분집합샘플링, 순환이동, 비트플립노이즈) 을사용한다. 추론시적응형임계값 $\theta = \mathrm{quantile}(P, 1 - \rho_{\mathrm{on}})$ 으로원곡 ON 비율 $\rho_{\mathrm{on}} \approx 0.15$ 를맞춘다.

4. 실험

모든실험은 $N = 20$ 회독립반복으로수행하였다. 주요지표는 pitch JS divergence 이다.

4.1 거리함수비교

Table 1: 네가지거리함수에대한 Algorithm 1 JS divergence ($N = 20$).

거리함수	K	JS (평균 ± 표준편차)	Coverage
frequency	1	0.0344 ± 0.0023	0.957
Tonnetz	47	0.0493 ± 0.0038	1.000
voice-leading	19	0.0566 ± 0.0027	0.989
DFT	**17**	$\mathbf{0.0213 \pm 0.0021}$	1.000

DFT 가 hibari 에서최우수이며, frequency 대비 38.2%, Tonnetz 대비 56.8%, voice-leading 대비 62.4% 낮은 JS 를보인다 (표 1).

4.2 옥타브가중치튜닝

$w_o \in \{0.1, 0.3, 0.5, 0.7, 1.0\}$ 에대한 DFT 조건격자탐색 ($N = 10$) 결과, $w_o = 0.3$ 이최적이다 (best JS 0.0163). *hibari* 의좁은 2 옥타브음역 (MIDI 52–81) 과일치한다.

4.3 Cycle 부분집합절제

Table 2: Cycle 부분집합절제 (Tonnetz, $N = 20$).

K	JS (평균 ± 표준편차)	Coverage
10	0.0991 ± 0.0038	0.980
17	0.0740 ± 0.0038	0.996
46	$\mathbf{0.0397 \pm 0.0025}$	1.000

JS 는 K 에대해단조감소하지만수확체감이나타난다 (표 2).

4.4 연속값중첩행렬

Table 3: 연속값중첩행렬실험 (Tonnetz, $N = 20$).

설정	Density	JS (평균 ± 표준편차)
이진 (캐시)	0.751	0.0387 ± 0.0027
연속값직접사용	0.264	0.0382 ± 0.0021
연속 → 이진 τ=0.3	0.373	0.0386 ± 0.0022
연속 → 이진 τ=0.5	**0.168**	$\mathbf{0.0343 \pm 0.0027}$
연속 → 이진 τ=0.7	0.077	0.0364 ± 0.0032

연속값중첩행렬에 $\tau = 0.5$ 이진화를적용하면이진기준선대비 11.4% 추가개선된다 (Welch $t = 5.16$, $p < 0.001$, $d = 1.63$; 표 3).

4.5 심층학습모델비교

Table 4: 최적 DL 설정 (각 1 회실행).

모델	Val Loss	JS	생성 Note 수
FC (hd=256, do=0.3)	0.282	**0.0015**	3,754
LSTM (2 층)	0.385	0.0448	3,753
Transformer (2L, 4H)	0.676	0.0104	3,753

가장단순한 FC 모델이최저 JS 를달성한다 (표 4). 이는 *hibari* 의미학을반영한다: *out of noise* 는시간적인과보다음의공간적배치를중시하므로, 시간문맥을무시하는 FC 가작곡설계와더잘부합한다.

4.6 개선 F: 연속값중첩행렬 + FC

Table 5: FC 에대한연속 vs. 이진입력 ($N = 5$).

입력	JS (평균 ± 표준편차)	Val Loss	Coverage
이진	0.0014 ± 0.0010	0.070	0.948
연속	$\mathbf{0.0006 \pm 0.0005}$	**0.031**	**0.991**

연속입력은 JS 를 57%, val loss 를 2.3 배감소시킨다 (표 5). 본연구에서관측된최저전곡 JS 이다 (이론적최댓값 $\log 2$ 의 0.09%).

4.7 곡고유구조분석

Deep scale 특성 *hibari* 의 7 개 pitch class $\{C, D, E, F, G, A, B\}$ 는음정벡터 $[2, 5, 4, 3, 6, 1]$ 을 가지며, 모든성분이상이하다. 이는온음계고유의특성이다 [16].

준균등 pitch 분포 정규화 pitch 엔트로피가 0.974 (거의최대) 이다. 모든 pitch 가거의동일확률로나타나므로, 시간순서를무시하는 FC 가이미참분포를잘근사함을설명한다.

Tonnetz 판별력 7 개 PC 에서 Tonnetz 직경은 4 로, 세밀한거리판별이가능하다. 12 개 PC(*solari* 등) 에서는직경이 2 로축소되어 Tonnetz 의이점이사라진다.

위상이동 (Phase shifting) 악기 1 은 32-step 모듈을 33 회반복 (쉼없음); 악기 2 는 33-step 모듈을 32 회반복 (모듈당쉼 1 회). 서로소주기 ($\gcd(32, 33) = 1$) 에의해두악기는결코동기화되지않는다. Steve Reich 의 *phase shifting* 기법과수학적으로동일한구조이다.

5. 시각자료

6 개의정적도표와 1 개의대화형 HTML 보충자료를제공한다.

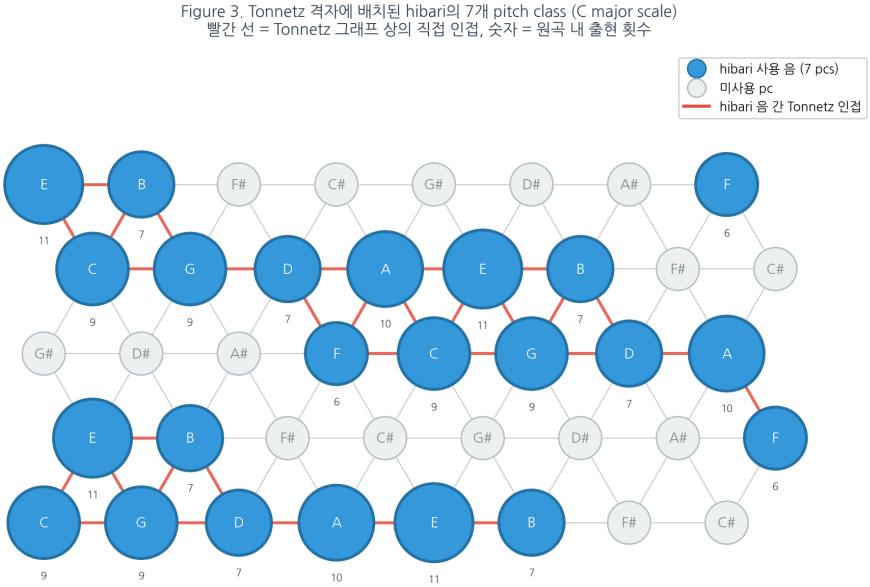

Figure 2: Tonnetz 격자위의 *hibari* 7 개 pitch class (파란색). 빨간간선은직접 Tonnetz 인접을나타낸다.

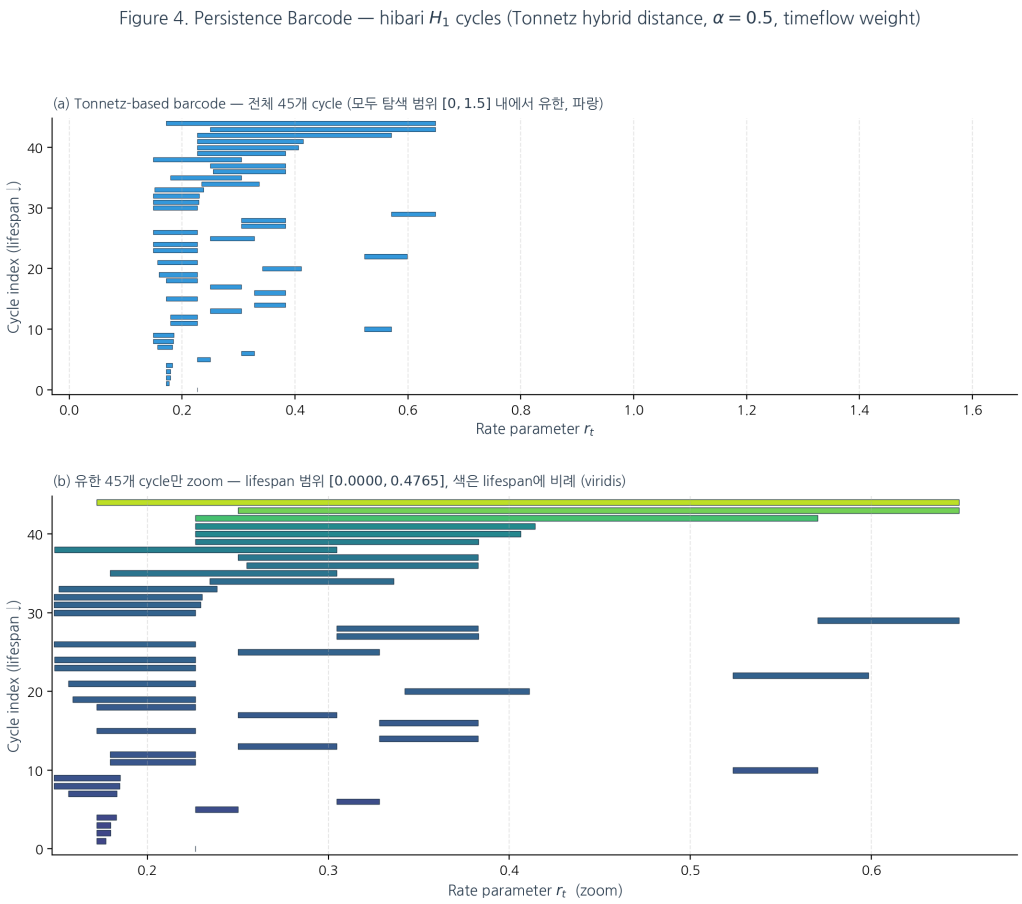

Figure 3: H_1 persistence barcode (Tonnetz). 위: 전체 barcode; 아래: 유한 cycle 확대. 수명범위가 10,000 배이상차이난다.

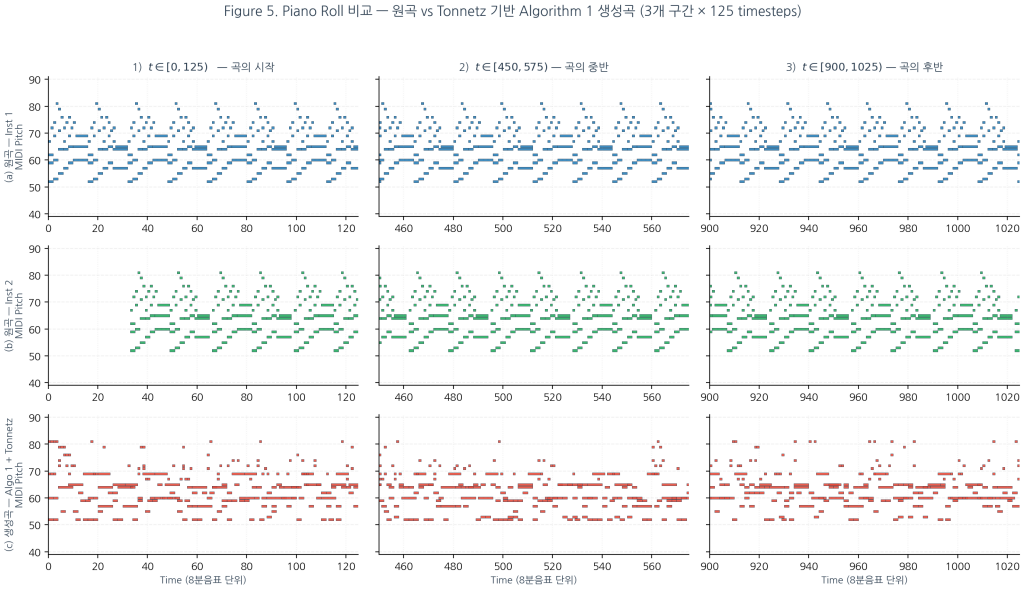

Figure 4: 피아노롤비교: (a)–(b) 원곡악기 1–2; (c) Algorithm 1 + Tonnetz.

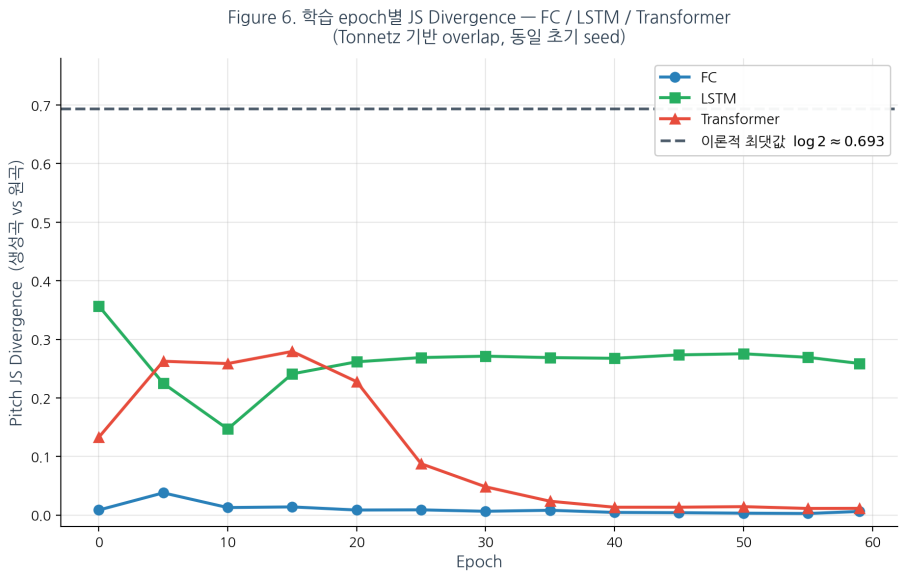

Figure 5: 학습 epoch 에따른 JS divergence. FC 가가장빠르게수렴; LSTM 은 JS ≈ 0.26 에서정체.

6. 관련연구와의비교

6.1 일반 AI 음악생성과의비교

코퍼스기반학습모델 (Magenta, Music Transformer) 과달리, 본파이프라인은 단일곡에대한심층분석을수행하여해석가능하고추적가능한생성을실현한다. FC > Transformer 라는결과는 "더많은시간적모델링이항상우월하다" 는보편적가정에도전한다.

6.2 기존 TDA–음악연구와의비교

선행 TDA–음악연구 [7, 8] 와비교하여:

(A) 네가지거리함수를 N=20 통계로체계적비교.

(B) 연속값중첩행렬도입.

(C) 완전한통계적엄밀성 (Welch t, Cohen's d) 제공.

(D) 서양현대음악으로확장.

(E) 모델선택과미학적맥락의연결.

(F) TDA 를분석에서 변주로확장 (§7).

7. 확장실험

7.1 모듈단위생성

hibari 의 32-step 모듈구조를직접활용하여, 단일모듈을생성한뒤전체곡으로재배치하는접근을검증하였다. 여기서모듈은 32-step(음악적 4 마디) 길이의 A-B-A'-C 반복선율단위이며 inst 1 에서 33 회반복된다. 또한 §7.2 재실험에서 1088 행전체를 34×32 블록으로재해석

했다 (“마디” 는계산용 32-step 블록). 해당재실험의프로토타입비교에서 P3_local 의 best trial JS 는 0.0360 이었다. DFT $\alpha = 0.25$ 조건에서 module PH 는 $K = 14$ 이며, 개선조합 (C/D/P3_local/P3_local+C) 을비교하였다:

Table 6: 모듈단위생성전략 ($N = 10$).

전략	JS (평균 ± 표준편차)	최저	Cov.
P0 기준선	0.1082 ± 0.0241	0.0701	0.826
C: best-of-10	0.0800 ± 0.0171	0.0570	0.913
D: cov≥20/23	0.0808 ± 0.0171	0.0570	0.887
P3_local	0.0721 ± 0.0275	0.0288	0.813
P3_local + C	$\mathbf{0.0440 \pm 0.0158}$	**0.0250**	0.896

33 개시작모듈 (inst 1 기준 start module $0 \ldots 32$) 전수탐색결과, start=0 은평균 JS 기준 5 위이며특별히우수하지않았다. 여기서 $k = 10$ 은 seed 내부 best-of-k 후보수, $N = 10$ 은시작모듈당독립반복횟수이다. 전역최저 trial 은 start=1, seed=9309 에서 JS = 0.01479 로, 전곡 Phase 1 per-cycle 최저 (0.01489) 와동등 ($\alpha = 0.25$ 신기록 0.01156 대비 +28.0% 열세).

7.2 일반화: *solari*, Bach, Ravel

Table 7: 교차곡비교요약.

곡	PC 수	최적거리	최적모델	해석
hibari	7	DFT	FC	스펙트럼구조포착
solari	12	freq./Ton. 동률	Transformer	선율적진행
aqua	12	Tonnetz	—	Tonnetz +26.3%
Bach	12	Tonnetz	—	Tonnetz −54.8%
Ravel	12	frequency	—	note 다양성지배

핵심결론은 “hibari 만 DFT 최적” 이다. solari/aqua/Bach/Ravel 은 Tonnetz 또는 frequency 가 더유리하며, 거리함수의절대우열보다곡구조와목적의정합성이중요하다.

7.3 방향 A: 위상보존 Note 재분배

본변주실험의기본축은 Tonnetz 기반으로둔다. scale 제약과화성적이웃구조 (3 도/5 도) 가 Tonnetz 에서가장일관되게작동하기때문이다. Cycle vertex 집합을 Tonnetz 매칭거리가최소화되는새 note 로교체한다. 중첩행렬은그대로보존된다.

Table 8: Note 재분배 (Algorithm 1, Tonnetz).

설정	Note 오차	Cycle 오차	DTW	ΔDTW
기준선	—	—	2.21	—
narrow	4.00	1.17	2.09	−5.8%
wide	4.46	1.18	2.89	+30.3%
vwide	4.48	1.06	**3.57**	**+61.4%**

가장넓은음역 (MIDI 40–88) 에서 DTW 가 61.4% 증가하면서도 cycle 오차는 ~ 1.1 로안정적이다 (표 8) — 위상구조를보존하면서멜로디가실질적으로다른음악이생성된다.

7.4 방향 B: 시간재배치

세가지전략 (구간셔플, 블록순열, Markov 재샘플링) 을시험하였다. FC 는시간재배치에거의반응하지않고, LSTM 도실측에서변화폭이작다 ($\leq$ 0.5% 수준). PE 제거및재학습을적용한 Transformer 만 DTW +21.7% 까지증가시키지만, 동시에 pitch 분포가붕괴된다 ($0.007 \to 0.173$). 따라서방향 B 단독으로는 "분포보존 + 선율변화" 를동시에달성하기어렵고, 방향 A 와의결합이필요하다.

7.5 화성제약

Note 재분배에음계제약 (major, minor, pentatonic) 과협화목표를추가하였다. **scale_major** 가 가장효과적이다: note 오차 $4.35 \to 3.52$ (-19%), 음계일치 1.00, 평균불협화도 $0.412 \to 0.361$.

7.6 A+B 결합: 최종통합

7.6.1 6.6.1 Tonnetz 기반성공사례

major_block32 (scale_major + block32 + continuous + Transformer) 는 ref pJS = 0.0034, DTW +31%, scale match = 1.00 을동시에만족한다.

7.6.2 6.6.2 DFT 전환실패사례

동일조합을 DFT 로전환하면 ref pJS 가크게악화된다 (Transformer 0.0798, FC 0.0412). 즉 Tonnetz 에서성공한변주스택이 DFT 로자동전이되지는않는다.

7.6.3 6.6.3 메타통찰

거리함수는목적별로분리해설계해야한다. 구조정밀도목적 (원곡재현, cycle 분리) 에는 DFT 가강하고, 화성정합성목적 (scale 제약변주) 에는 Tonnetz 가강하다.

7.7 Cycle 별임계값최적화

DFT continuous OM 에서각 cycle 에대해 $\tau_c \in \{0.1, 0.2, \ldots, 0.7\}$ 를탐색하였다:

Table 9: Cycle 별 τ_c 최적화 ($N = 20$).

설정	JS (평균 ± 표준편차)	개선율
균일 $\tau = 0.35$	0.03605 ± 0.00237	—
단일 $\tau = 0.5$	0.01591 ± 0.00192	+55.9%
Cycle 별 τ_c (Phase 1, $\alpha = 0.5$)	0.01489 ± 0.00143	+58.7%
Cycle 별 τ_c ⋆ (Phase 2, $\alpha = 0.25$)	$\mathbf{0.01156 \pm 0.00147}$	**−22.35%**

Cycle 별최적화는균일임계값대비 Welch $p = 2.48 \times 10^{-26}$ 로유의하며, Algorithm 1 기준연구전체최저성능—Phase 1: 0.01489, Phase 2 신기록: **0.01156** ($p = 4.94 imes 10^{-11}$).

7.8 Soft Activation: 전체아키텍처

Table 10: 이진 vs. 연속입력 (DFT, $N = 10$).

모델	입력	JS	Val Loss	ΔJS
FC	이진	0.00217	0.3395	—
FC	**연속**	**0.000348**	**0.0232**	**+84.0%**
Trans.	이진	0.00251	0.836	—
Trans.	연속	0.000818	0.152	+67.4%
LSTM	이진	0.233	0.408	—
LSTM	연속	0.170	0.395	+27.3%

FC + 연속입력이최우수이며 (JS = 0.000348), Transformer 연속입력보다도유의하게우수하다 (Welch $p = 1.66 \times 10^{-4}$).

비고: Algo 2 의 α 설정 (Task 51). Algorithm 1 에서 $\alpha = 0.25$ 가최적임을확인한후 (§7.7, §7.9), 동일 DFT·gap=0·연속 OM 조건에서 $\alpha = 0.25$ ($K = 14$) FC-cont 를 $N = 10$ 으로재실험하였다 (`fc_cont_dft_alpha025_results.json`). 결과: JS $= 0.00057 \pm 0.00046$ vs. $\alpha = 0.5$ JS 0.000348; Welch $p = 0.168$ (비유의). K 감소 (19→14) 로 FC 학습신호가감소하여 Algorithm 1 의이점이역전된다. **Algorithm 2 최저는 $\alpha = 0.5$, JS $= 0.000348$ 을유지.**

7.9 DFT-Hybrid α 격자탐색

Table 11: DFT-hybrid α 격자탐색 ($N = 20$).

α	K	JS (평균 ± 표준편차)	비고
0.0 (pure DFT)	1	0.0728 ± 0.00432	축퇴 ($K = 1$)
0.1	13	0.01602 ± 0.00204	
0.25	**14**	0.01593 ± 0.00181	**최적**
0.3	16	0.02025 ± 0.00134	
0.5	19	0.01691 ± 0.00143	기존기본값
0.7	24	0.03140 ± 0.00270	
1.0 (pure freq.)	1	0.03386 ± 0.00186	축퇴 ($K = 1$)

DFT-hybrid 에서는양끝점이모두축퇴 ($K = 1$) 하며, $\alpha = 0.25$ 에서최저 JS 와유효한위상구조를동시에확보한다.

7.10 Barcode Wasserstein 모듈선택

DFT $\alpha = 0.25$ 조건에서모듈국소 barcode 와전곡 barcode 의 Wasserstein 거리와생성 JS 의 Pearson 상관은 $r = -0.054$ 로사실상무상관이다. 즉 DFT 조건에서는 Wasserstein 기반모듈선택을권장할수없다.

이값은 Tonnetz 조건에서관찰된 $r = 0.503$ 과부호까지반대이며, barcode 기반선택역시거리함수의존적임을보여준다. 또한 complex(simul 혼합) 모드도 Tonnetz 에서는유효할수있으나 DFT 에서는악화되므로, 최종 DFT 설정에서는 timeflow-only 를유지한다.

8. 결론

본연구는 persistent homology 로음악의위상구조를추출하고그구조를보존하면서새로운음악을생성하는통합파이프라인을제시하였다. 주요발견:

1. **거리함수선택의효과.** hibari 에서는 DFT 가 frequency 대비 38.2%, Tonnetz 대비 56.8%, voice-leading 대비 62.4% 낮은 JS 를보였다. 그러나타곡에서는 Tonnetz 또는 frequency 가최적이어서절대최적거리함수는존재하지않는다.

2. **곡의성격이최적모델을결정한다.** hibari 에서는 FC 가, solari 에서는 Transformer 가최적이다. DFT + continuous 조건에서 FC 는 Transformer 대비 Welch $p = 1.66 \times 10^{-4}$ 로유의우위다.

3. **연속값 OM 정교화의효과.** per-cycle τ_c Phase 1 ($\alpha = 0.5$): 0.01489; Phase 2 ($\alpha = 0.25$) 신기록 $\mathbf{0.01156 \pm 0.00147}$ ($p = 4.94 \times 10^{-11}$). FC-cont 는 0.00035 ± 0.00015 로 Algorithm 2 최저를기록했다.

4. **모듈단위생성의 full-song 품질도달.** P3_local + C best trial 은 0.0250, 33 모듈전수탐색전역최저는 0.01479 로전곡 Phase 1 최저 0.01489 와동등 ($\alpha = 0.25$ 신기록 0.01156 대비 +28.0% 열세).

5. **거리함수 × 목적정합성 (메타통찰).** 구조정밀도목적 (원곡재현, cycle 분리, 모듈탐색) 에는 DFT 가강하고, 화성정합성목적 (scale 제약변주) 에는 Tonnetz 가강하다.

6. **distance-specific 현상.** DFT 조건에서 Wasserstein 모듈선택상관은 $r = -0.054$ 로붕괴하며, complex(simul 혼합) 도악화된다. 따라서해당기법들은거리함수조건부로사용해야한다.

본연구는 TDA 가분석도구일뿐아니라 음악창작을위한제약생성기로기능할수있음을보여주며, 수학적위상과작곡미학사이의다리를놓는다.

감사의글

본연구는고등과학원 (KIAS) 초학제독립연구단의정재훈교수의지도하에수행되었다. 한국전통음악선행연구 [8] 로부터계승된 pHcol 구현과파이프라인설계에감사를표한다.

References

[1] G. Carlsson, "Topology and data," *Bulletin of the AMS*, vol. 46, no. 2, pp. 255–308, 2009.

[2] H. Edelsbrunner and J. Harer, *Computational Topology: An Introduction*. AMS, 2010.

[3] D. Cohen-Steiner, H. Edelsbrunner, and J. Harer, "Stability of persistence diagrams," *Discrete & Computational Geometry*, vol. 37, no. 1, pp. 103–120, 2007.

[4] D. Tymoczko, "The generalized Tonnetz," *J. Music Theory*, vol. 56, no. 1, 2012.

[5] D. Tymoczko, "Set-class similarity, voice leading, and the Fourier transform," *J. Music Theory*, vol. 52, no. 2, 2008.

[6] U. Bauer, "Ripser: Efficient computation of Vietoris–Rips persistence barcodes," *J. Applied and Computational Topology*, vol. 5, pp. 391–423, 2021.

[7] M. L. Tran, C. Park, and J.-H. Jung, "Topological data analysis of Korean music in Jeongganbo," *arXiv:2103.06620*, 2021.

[8] D.-J. Lee, M. L. Tran, and J.-H. Jung, "Geometric structure and AI composition of Korean traditional music," 2024.

[9] E. Heo, B. Choi, and J.-H. Jung, "Persistent homology with path-representable distances on graph data," *arXiv:2501.03553*, 2025.

[10] G. L. Nemhauser, L. A. Wolsey, and M. L. Fisher, "An analysis of approximations for maximizing submodular set functions," *Math. Programming*, vol. 14, no. 1, pp. 265–294, 1978.

[11] B. L. Welch, "The generalization of 'Student's' problem when several different population variances are involved," *Biometrika*, vol. 34, pp. 28–35, 1947.

[12] J. Cohen, *Statistical Power Analysis for the Behavioral Sciences*, 2nd ed. Lawrence Erlbaum, 1988.

[13] S. Hochreiter and J. Schmidhuber, "Long short-term memory," *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.

[14] A. Vaswani *et al.*, "Attention is all you need," in *Proc. NeurIPS*, 2017.

[15] R. Sakamoto, *out of noise* [Album]. commmons, 2009.

[16] C. Gamer and R. Wilson, "Microtones and projective planes," in *Music and Mathematics*. Oxford University Press, 2003.