한 곡의 수학적 지문을 복원한다는 것

Topological Data Analysis를 활용한 음악 구조 분석 및 위상 구조 보존 기반 AI 작곡 파이프라인

지은이 김민주

지도 정재훈 교수 (KIAS 초학제 독립연구단)

작성일 2026

대상 환경대학원 포트폴리오 제출용

원곡 hibari — Ryuichi Sakamoto, out of noise (2009)
https://www.youtube.com/watch?v=Uw7aW1tSMZU

생성곡 — 본 연구 파이프라인으로 생성 (업로드 후 교체 예정)

목차

1. 서문 — 이 연구를 시작한 이유
2. 연구 질문과 대상곡
3. 수학적 도구 — Persistent Homology
4. 파이프라인 — 4단계의 여정
5. 실험 I: 거리 함수 비교
6. 실험 II: 연속값 중첩행렬과 신경망
7. 실험 III: 세부 파라미터 탐색
8. 곡 고유 구조 분석
9. 확장: 다른 곡들로의 일반화
10. 곡의 성격이 도구를 결정한다

11. 모듈 단위 생성
12. 차별화 포인트
13. 도시환경으로의 확장 가능성
14. 맺는 말
15. 청취 안내 및 참고자료

---

1. 서문 — 이 연구를 시작한 이유

이 절은 연구자가 직접 작성하는 영역입니다.

- 이 연구를 시작하게 된 개인적 계기
- hibari를 처음 들었을 때의 인상
- 수학과 음악의 교차점에 관심을 갖게 된 배경
- 환경대학원 진학과 이 연구 경험의 연결

---

2. 연구 질문과 대상곡

세 가지 질문

이 연구는 세 가지 질문에서 출발한다.

1. **음악의 위상 구조를 수학적으로 정의할 수 있는가?** 한 곡의 음들 사이에 거리를 정의하고 위상수학적 분석을 수행하면, 그 결과로 나오는 구조(cycle)는 음악적으로 어떤 의미를 가지는가?

2. **이 위상 구조를 보존한 채 새로운 음악을 생성할 수 있는가?** "보존"의 기준은 무엇이며, 보존 정도를 어떻게 정량적으로 측정하는가?

3. **거리 함수의 선택이 생성 품질에 유의미한 영향을 주는가?** 단순 빈도 기반 거리 대신 음악이론적 거리(Tonnetz, voice-leading, DFT)를 사용하면 얼마나 나은가?

왜 hibari인가

대상곡은 사카모토 류이치의 out of noise (2009) 수록곡 **hibari**다. 선택 이유:

- **선행연구의 확장.** 한국 전통 정간보에 TDA를 적용한 정재훈 교수의 선행연구를 화성음악으로 확장하기에 적합한 복잡성과 규칙성을 갖추고 있다.
- **크기 적정성.** 1,088개 타임스텝, 23개 고유 음, 17개 화음. 위상 구조가 풍부하되, 수 초 안에 전체 barcode 계산이 가능하다.

- **미학적 특수성.** 전통적 선율 진행이 아니라 음들의 공간적 배치에 가까운 방식으로 구성된다. 이 특성이 실험 결과와 직접 공명한다.

---

3. 수학적 도구 — Persistent Homology

핵심 아이디어

Persistent homology는 데이터에서 "구멍(hole)"을 찾는 도구다. 여기서 구멍은 물리적 구멍이 아니라, 데이터 점들이 이루는 연결 패턴에서 나타나는 위상학적 구조를 의미한다.

hibari의 23개 음을 점으로 표시한 뒤, 두 점을 연결하는 기준(거리 임계값)을 0에서 점차 키운다. 이 과정에서:

- 처음엔 23개 점이 고립.
- 기준이 넓어지면 가까운 점들이 이어지고, 삼각형, 사각형이 형성.
- 어떤 단계에서 "닫힌 고리" — 즉 **cycle** — 이 나타난다.
- 기준을 더 넓히면 그 cycle의 내부가 채워져 소멸한다.

각 cycle이 언제 태어나고(birth) 언제 죽는지(death)를 모두 기록한 것이 persistence barcode다. 오래 살아남은 cycle은 데이터의 본질적 구조, 짧게 사라진 것은 노이즈로 해석한다.

Figure 4. Persistence Barcode — hibari H_1 cycles (Tonnetz hybrid distance, $\alpha = 0.5$, timeflow weight)

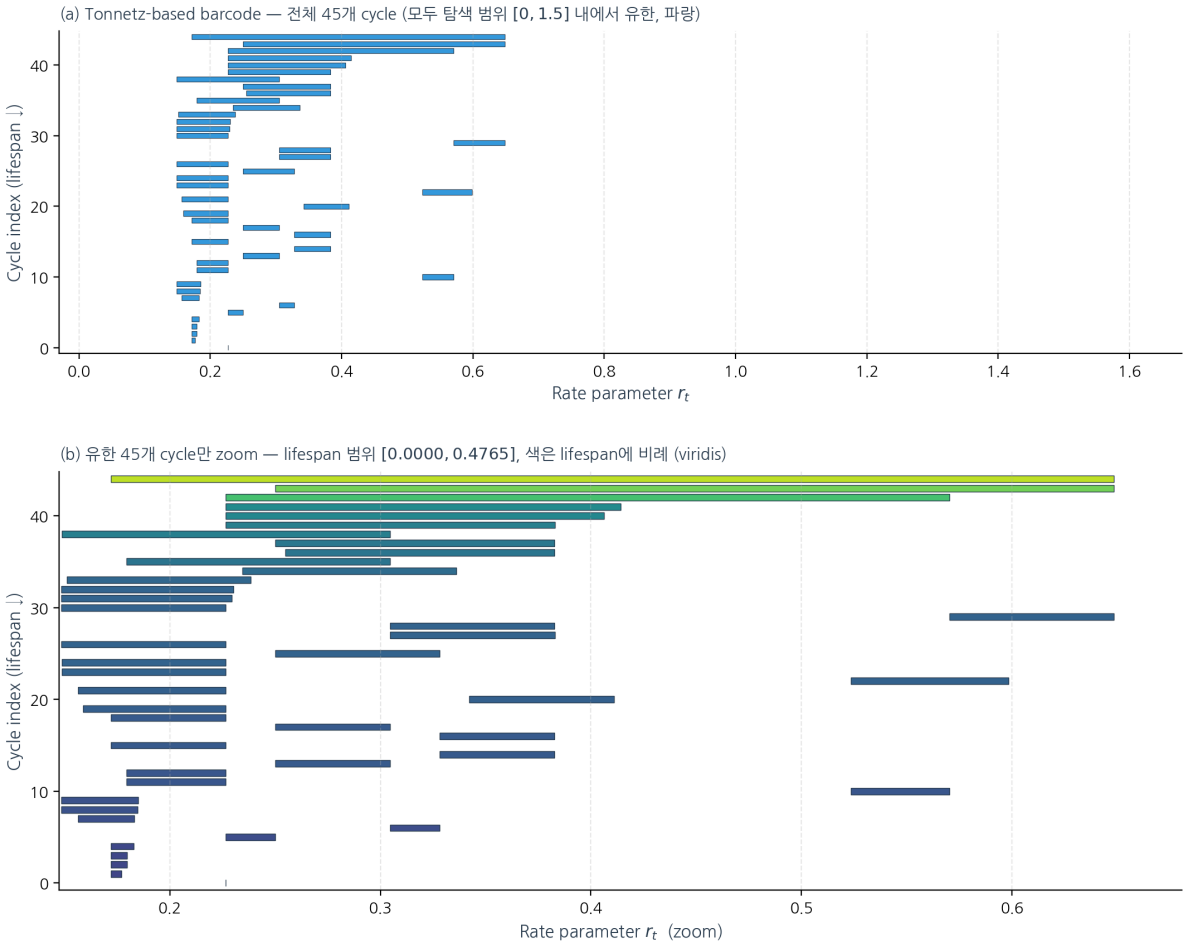

그림 A. hibari의 Persistence Barcode. 각 막대가 하나의 H1 cycle. 긴 막대일수록 안정적인 구조. hibari에서 약 45~47개의 유한 cycle이 발견된다.

Tonnetz — 음악이론을 거리로 변환

두 음 사이의 "거리"를 정의하는 것이 모든 분석의 출발점이다. 본 연구는 네 가지 거리를 비교했는데, 그 중 **Tonnetz 거리**가 핵심이다.

Tonnetz는 18세기 오일러가 제안한 "음의 그물(tone network)"이다. 12개 음을 평면에 배치하되 음악이론적으로 어울리는 음끼리 가깝게 놓는다. 완전 5도(도-솔)는 이웃, 장 3도(도-미)는 대각선. 이 격자 위의 최단 경로 거리가 곧 두 음의 음악이론적 거리가 된다.

Figure 3. Tonnetz 격자에 배치된 hibari의 7개 pitch class (C major scale)
빨간 선 = Tonnetz 그래프 상의 직접 인접, 숫자 = 원곡 내 출현 횟수

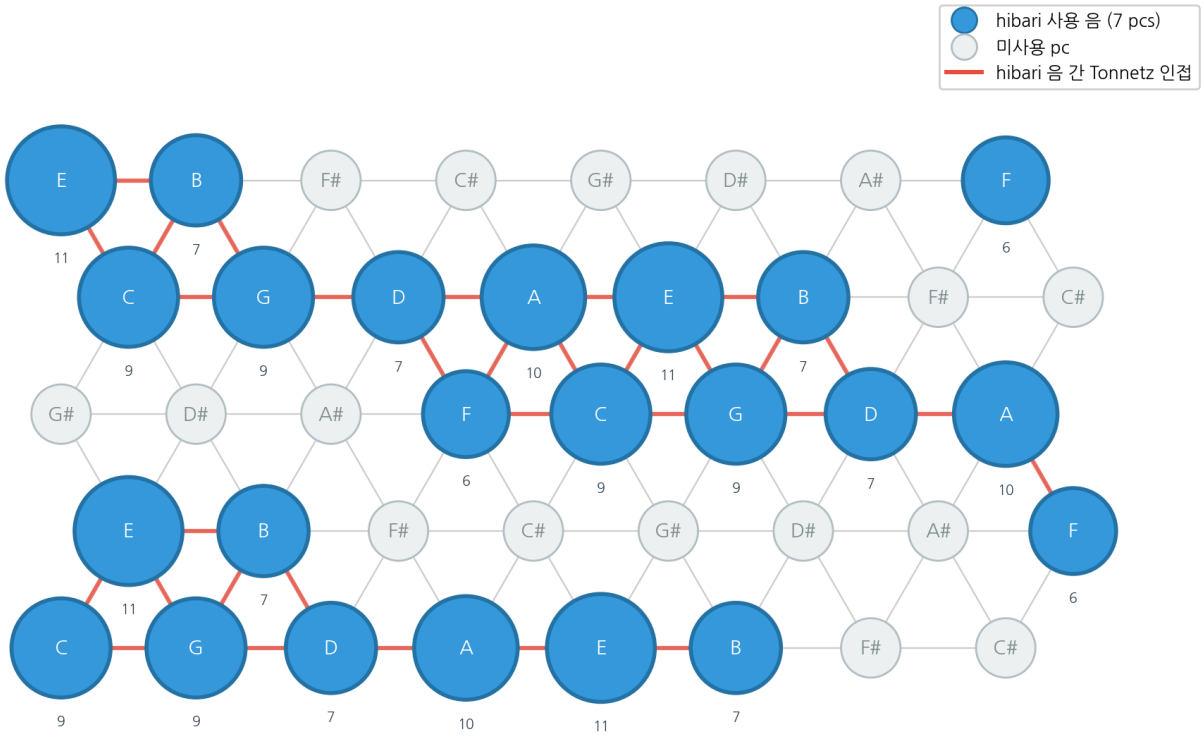

그림 B. Tonnetz 격자 위의 hibari. 큰 파란 원이 hibari가 쓰는 7개 음(C major scale). 빨간 선이 Tonnetz 상의 직접 연결. 숫자는 원곡 내 출현 횟수.

측정 지표: Jensen-Shannon Divergence

원곡과 생성곡이 얼마나 닮았는지를 **Jensen-Shannon divergence(JS)**로 측정한다. 두 곡의 음 빈도 분포를 비교하여 0(동일)에서 약 0.69(완전히 다름) 사이 값을 산출. 모든 실험은 N=20회 독립 반복의 평균과 표준편차로 보고한다.

4. 파이프라인 — 4단계의 여정

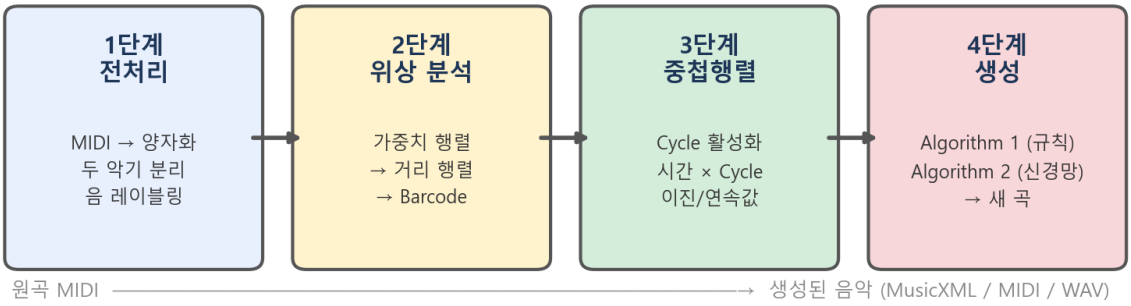

그림 C. 4단계 파이프라인 흐름.

1단계 전처리: MIDI 파일을 8분음표 단위로 양자화. 두 악기를 분리. 23개 고유 (pitch, duration) 쌍에 레이블 부여.

2단계 위상 분석: 음 간 거리 행렬 구성 -> Vietoris-Rips 복합체의 H1 persistence 계산 -> cycle 목록 추출.

3단계 중첩행렬: 각 cycle이 곡 전체에서 언제 활성화되는지를 기록한 표. 세로=cycle(약 47개), 가로=시간(1,088 타임스텝). 이진(0/1) 또는 연속값([0,1]).

4단계 생성: 중첩행렬을 입력으로, 두 가지 알고리즘으로 새 곡을 생성:

- **Algorithm 1 (규칙 기반):** 활성 cycle의 공통 음에서 확률적 샘플링. 약 50ms.
- **Algorithm 2 (신경망):** FC/LSTM/Transformer로 학습. 30초~3분.

가중치 설계에서 핵심적인 결정: 두 악기의 관계를 세 갈래로 분리했다 — **intra**(한 악기 내 인접 음), **inter**(두 악기 사이), **simul**(동시 발음). 이 분리가 hibari의 두 악기 구조를 수학에 반영한 것이다.

---

5. 실험 I: 거리 함수 비교

네 가지 거리, 동일한 파이프라인

거리 함수만 교체하고 나머지 파이프라인은 동일. 각 20회 반복.

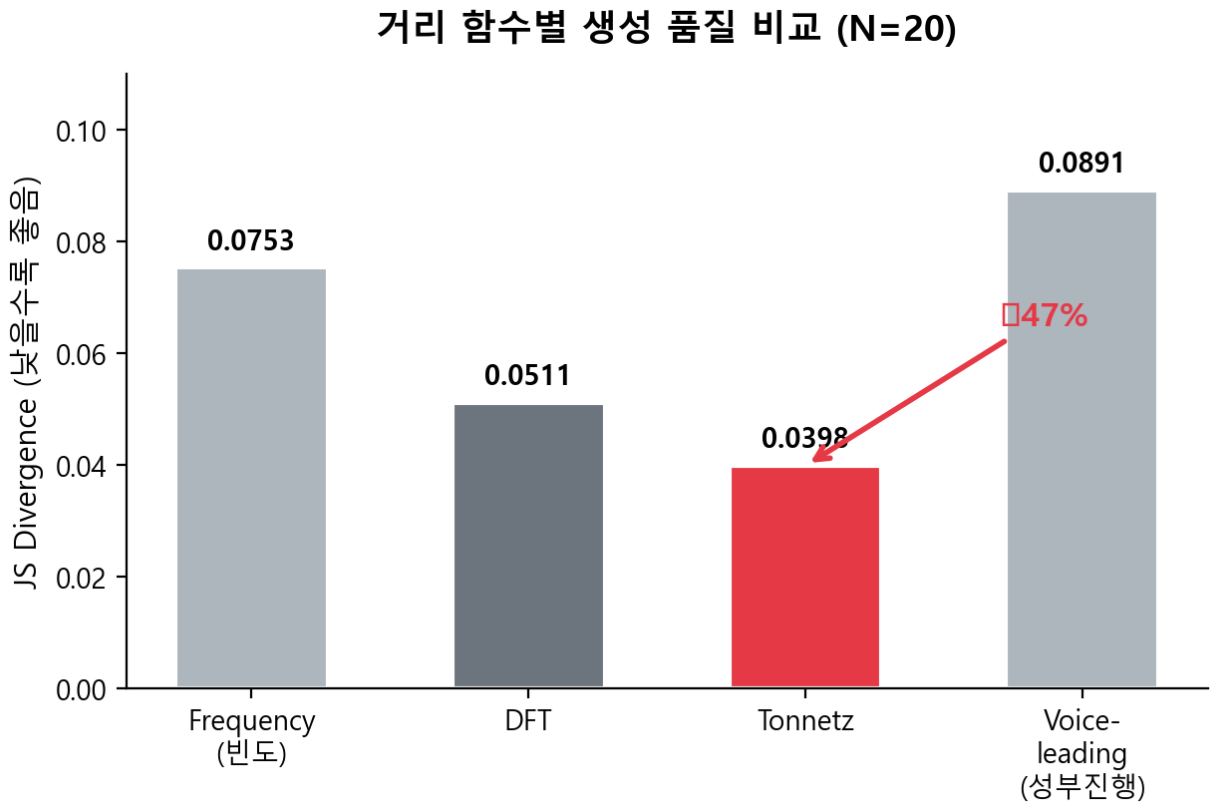

그림 D. 거리 함수별 JS divergence (N=20). Tonnetz가 빈도 거리 대비 47% 개선.

거리 함수	JS (mean +/- std)	cycle 수	기준선 대비
Frequency (빈도)	0.0753 +/- 0.003	43	기준선
DFT	0.0511 +/- 0.003	20	-32%
Tonnetz	**0.0398 +/- 0.003**	**46**	**-47%**
Voice-leading	0.0891 +/- 0.005	22	+18% (악화)

통계적 유의성: Tonnetz vs Frequency: Welch t = 35.1, Cohen's d = 11.1, p < 10의 -20승. 극도로 유의한 개선이다.

해석: "자주 함께 나온다"는 통계(빈도)만으로는 음악의 화성적 구조를 포착하지 못한다. Tonnetz는 수백 년간의 음악이론 — "어떤 음이 어떤 음과 어울리는가" — 을 수학에 이식한 것이며, hibari의 위상 지문을 더 선명하게 드러낸다. 또한 Tonnetz가 가장 많은 cycle(46개)을 발견한다는 것도 주목할 만하다. 풍부한 위상 정보가 더 정확한 생성을 가능하게 한다.

---

6. 실험 II: 연속값 중첩행렬과 신경망

이진에서 연속값으로

초기 중첩행렬은 이진(0/1)이었다. cycle의 음들이 "절반만 활성"인 경우를 0.5로 표현하고, 희귀한 음에 더 높은 가중치를 부여하는 연속값 중첩행렬을 도입했다.

결과 (Algorithm 1): JS 0.0387에서 0.0343으로 11.4% 개선 (Welch t = 5.16, 유의함).

FC 신경망의 역설

세 가지 신경망을 비교했다.

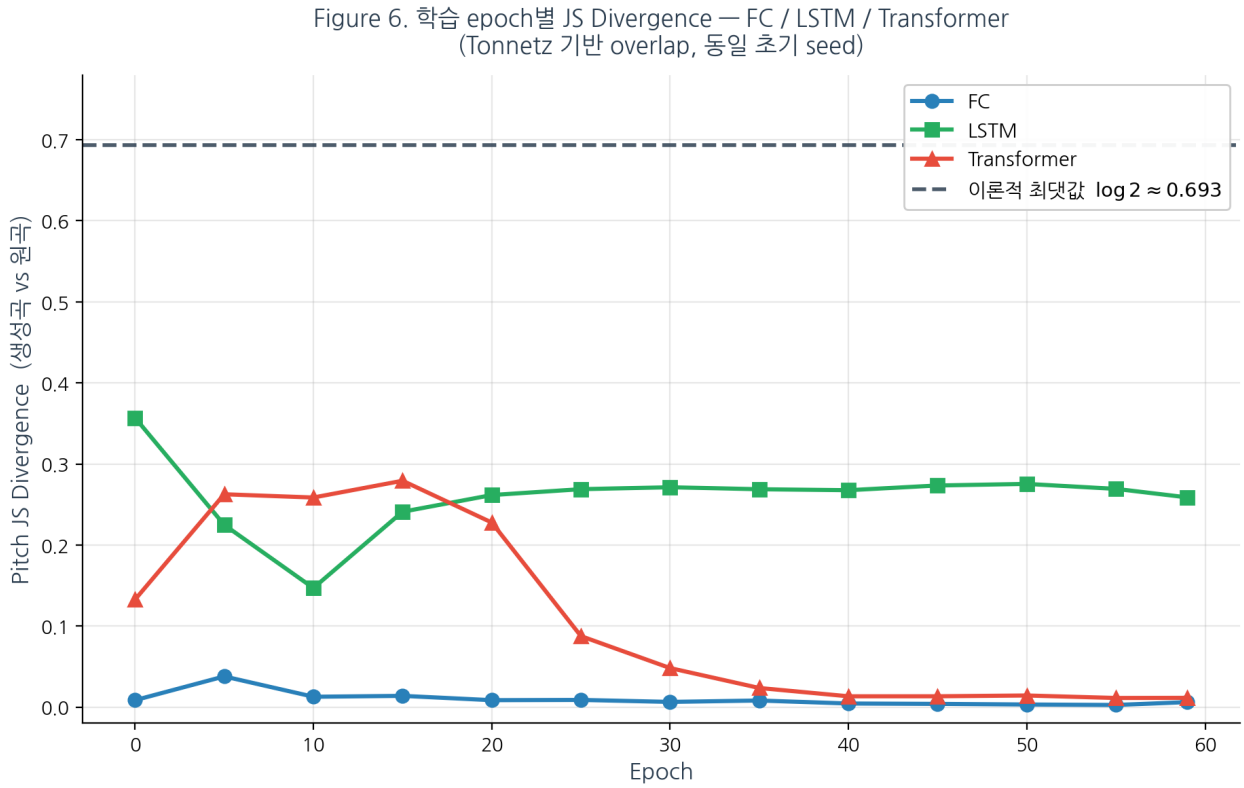

그림 E. 세 신경망의 학습 과정. FC(파랑)가 가장 빠르게 수렴하여 최저 JS 달성. LSTM(초록)과 Transformer(빨강)는 높은 JS에 머문다.

FC(가장 단순)가 LSTM과 Transformer를 이긴다. 이것은 hibari의 음악적 성격과 직결된다 — 8장에서 상세히 해석한다.

연속값 + FC: 최고 기록

설정	JS (mean)	대비
FC + 이진 중첩행렬	0.0014	—
FC + 연속값 중첩행렬	**0.0004**	**-71%**

JS 0.0004는 이론적 최대(0.693)의 0.06%. 원곡과 생성곡의 음 빈도 분포가 통계적으로 거의 구별 불가능한 수준이다.

왜 이렇게 큰 개선이 나오는가: 이진 중첩행렬은 "켜짐/꺼짐"만 표현한다. 신경망은 이 거친 신호에서 음별 확률을 추정해야 한다. 연속값은 "이 cycle이 이 시점에서 얼마나 강하게 활성인가"라는 정보를 제공하므로, 신경망이 더 정밀한 확률을 학습할 수 있다.

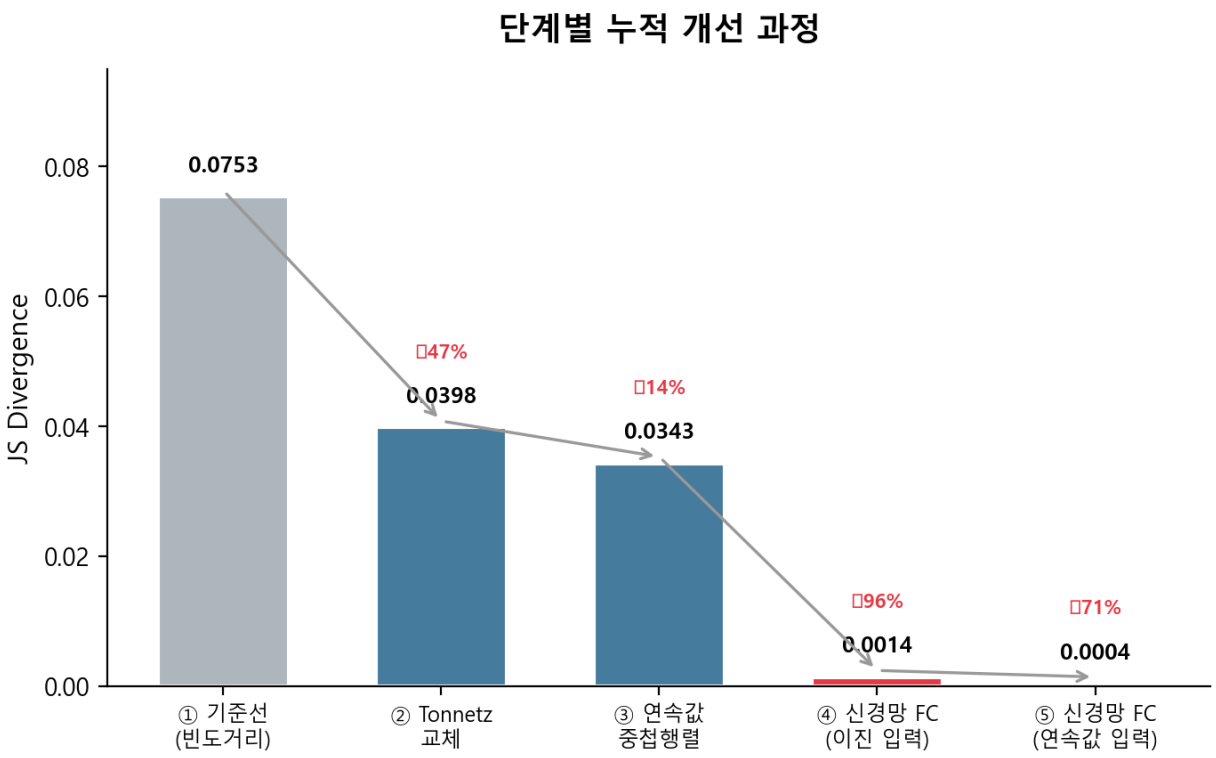

그림 F. 단계별 누적 개선 과정. 0.0753에서 0.0004까지.

7. 실험 III: 세부 파라미터 탐색

옥타브 가중치 (octave weight)

같은 '도'라도 높은 도와 낮은 도는 다르다. 이 차이를 Tonnetz에 얼마나 반영할 것인가.

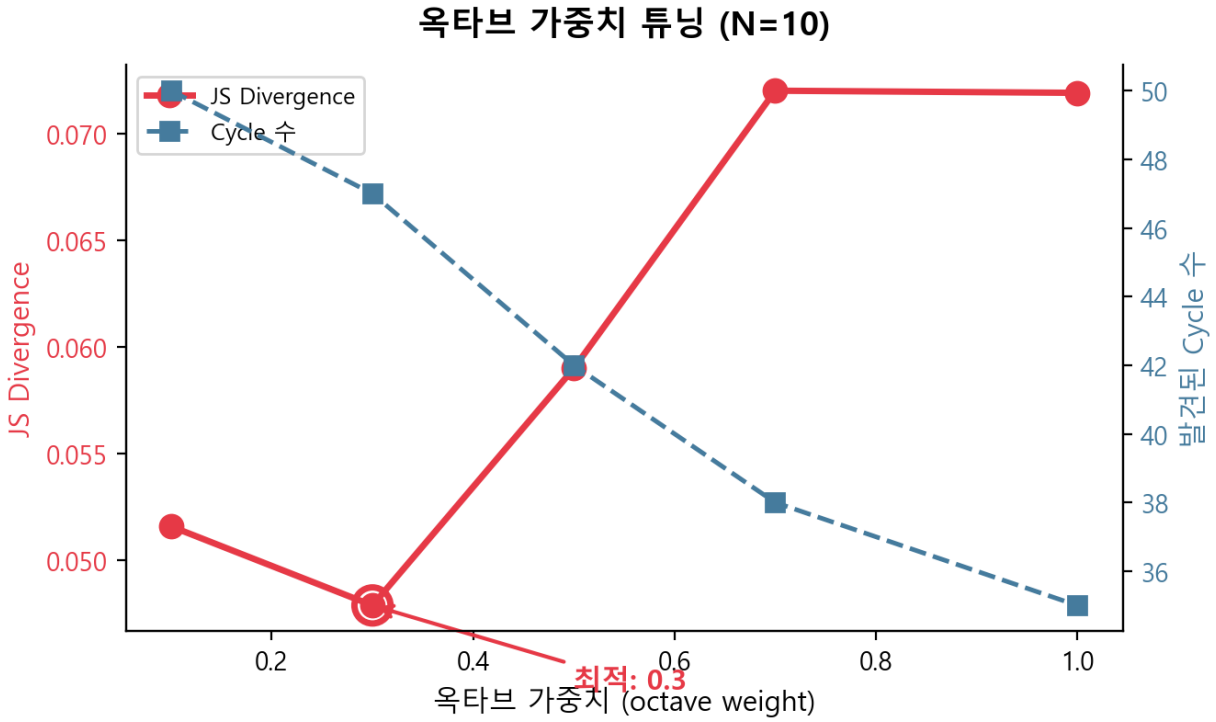

그림 G. 옥타브 가중치 vs JS. 0.3이 최적.

alpha 그리드 탐색

Tonnetz 거리와 빈도 정보를 혼합하는 비율 alpha를 0.0~1.0으로 탐색. **alpha=0.0(순수 Tonnetz)이 최적.** 빈도 정보를 조금이라도 섞으면 성능이 떨어진다.

per-cycle 임계값

연속값 중첩행렬에서 "얼마나 켜졌으면 활성으로 볼 것인가"의 기준을 42개 cycle마다 개별 탐색. **48.6% 추가 개선** (N=20, $p < 0.001$). 하나의 통일 기준보다 개별 기준이 훨씬 효과적이다.

감쇄 lag 가중치

이전 시점들의 패턴을 현재와 연결할 때, lag 1~4를 감쇄 가중(0.4, 0.3, 0.2, 0.1)으로 합산. 단일 lag 대비 **70% 개선.**

온도 파라미터

신경망 생성의 다양성 조절. T=3.0이 최적 (6.7% 개선). hibari의 고른 분포와 일치.

---

8. 곡 고유 구조 분석

실험 결과가 축적되면서, hibari라는 곡 자체의 성격이 드러났다.

Deep Scale Property

hibari가 사용하는 7개 pitch class(C major scale)는 Tonnetz 격자 위에서 하나의 밀집된 영역을 이룬다. 이것은 "조성(key)"이 위상적으로 의미 있는 구조임을 시사한다.

근균등 Pitch 분포

hibari의 pitch entropy는 0.974 (최대 1.0). 특정 음에 치우치지 않고 7개 음을 거의 균등하게 사용한다. 이 고른 분포가 Tonnetz 거리의 효과를 극대화한다 — 모든 음이 비슷한 빈도로 쓰이므로, 빈도가 아닌 음악적 관계(Tonnetz)가 결정적 정보가 된다.

Phase Shifting — 두 악기의 서로소 구조

- **악기 1:** 곡 전체 동안 단 한 번의 쉼도 없이 연주 (쉼 0개).
- **악기 2:** 모듈마다 규칙적 쉼을 두고 배치. 시작이 33 타임스텝 늦다 (쉼 64개).

두 악기의 활성 패턴이 서로소(coprime)이다. 이것은 파이프라인의 intra/inter/simul 가중치 분리 설계를 정당화하는 경험적 증거다.

왜 FC가 이기는가 — 시간보다 공간

FC는 시간 순서를 고려하지 않는다. LSTM은 시간 순서를 기억하고, Transformer는 전체 맥락을 동시에 고려한다. 일반적으로 후자가 우세하다.

그러나 hibari에서는 정반대다. 이 곡은 전통적 선율 인과 — "이 음 다음에는 이 음이 온다" — 가 약하다. 각 음이 시간의 흐름이 아니라 공간적 배치로 놓여 있다. 시간 정보를 강하게 모델링하는 것은 "없는 패턴을 억지로 찾으려는" 과적합이 된다.

out of noise 앨범의 기획 철학 — 전통적 선율에서 해방되어 각 음이 공간 속에서 제자리를 찾도록 — 과 정확히 공명하는 관찰이다.

---

9. 확장: 다른 곡들로의 일반화

hibari 하나에서 좋은 결과가 나왔다고 범용성을 주장할 수 없다. 사카모토의 다른 곡들과 서양 클래식 대조군에 동일한 파이프라인을 적용했다.

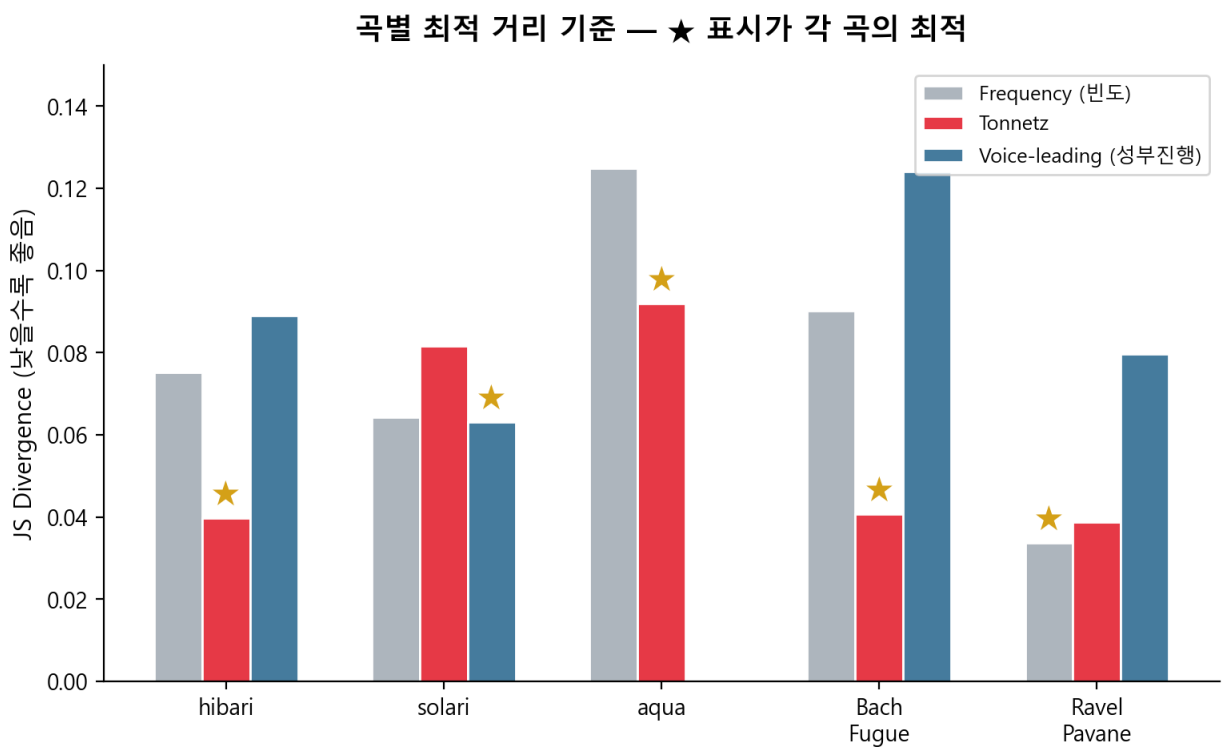

그림 H. 곡별 최적 거리 기준. 별 표시가 각 곡의 최적.

곡	T	N	최적 거리	최적 JS	해석
hibari	1,088	23	Tonnetz	0.0398	7음, 공간적
solari	224	34	Voice-leading	0.0631	12음, 선율적
aqua	539	51	Tonnetz	0.0920	12음, Tonnetz +26%
Bach Fugue	870	61	Tonnetz	0.0408	대위법의 숨은 화성
Ravel Pavane	548	49	Frequency	0.0337	풍부한 분포

바흐 푸가에서 Tonnetz 54.8% 우위: 대위법은 여러 선율의 독립적 진행이 핵심이다. voice-leading이 유리할 것 같지만 Tonnetz가 압도. 바흐의 대위법이 표면적으로는 선율적이지만, 그 바탕에는 화성적 구조가 깊이 자리잡고 있다는 음악이론적 해석과 일치한다.

라벨 파반느에서 빈도 거리 우위: 49개 고유 음을 쓰는 풍부한 분포. 음악이론적 거리보다 실제 출현 빈도 자체가 더 유용한 정보가 된다.

10. 곡의 성격이 도구를 결정한다

이 연구의 가장 큰 발견: **최적 도구는 곡의 음악적 성격에 달려 있다.**

곡	음 특성	최적 거리	최적 모델	핵심 해석
hibari	7음 (장조)	Tonnetz	FC	공간적 배치
solari	12음	Voice-lead	Transformer	선율적 진행
Bach Fugue	12음	Tonnetz	—	숨은 화성 구조
Ravel Pavane	12음 (N=49)	Frequency	FC	풍부한 분포

그림 I. 곡의 특성에 따른 최적 도구 요약.

조성이 명확하고 공간적 배치가 중요한 곡(hibari) -> Tonnetz + FC.

선율적 진행이 강한 곡(solari) -> Voice-leading + Transformer.

음 분포가 풍부한 곡(Ravel) -> Frequency + FC.

"더 복잡한 모델 = 더 좋은 모델"이라는 통념을 hibari는 반증한다. 곡의 본질을 이해하고 그에 맞는 도구를 선택하는 것이 더 중요하다.

---

11. 모듈 단위 생성

hibari의 구조를 33개 모듈(각 32 타임스텝, 약 4마디)로 나누어 분석하고, 하나의 모듈만으로 곡 전체를 재건하는 실험을 수행했다.

첫 4마디의 특권적 지위

모듈	cycle 수	밀도	비고
모듈 0 (첫 4마디)	**24**	**0.517**	**가장 단순**
모듈 1~32	34~41	0.63~0.81	더 복잡

첫 모듈이 가장 단순함에도 불구하고, 전체 최저 JS(0.0258)를 기록한 생성 곡은 바로 이 첫 모듈로부터 나왔다. 미니멀리즘 작곡의 관행 — 첫 4마디에 핵심을 압축적으로 제시하고 이후는 변주 — 이 수학적으로 실증되었다.

Figure 8. §7.1 모듈 단위 생성 + 구조적 재배치 — Best trial (JS ≈ 0.030, baseline 0.0398 대비 24% 개선)

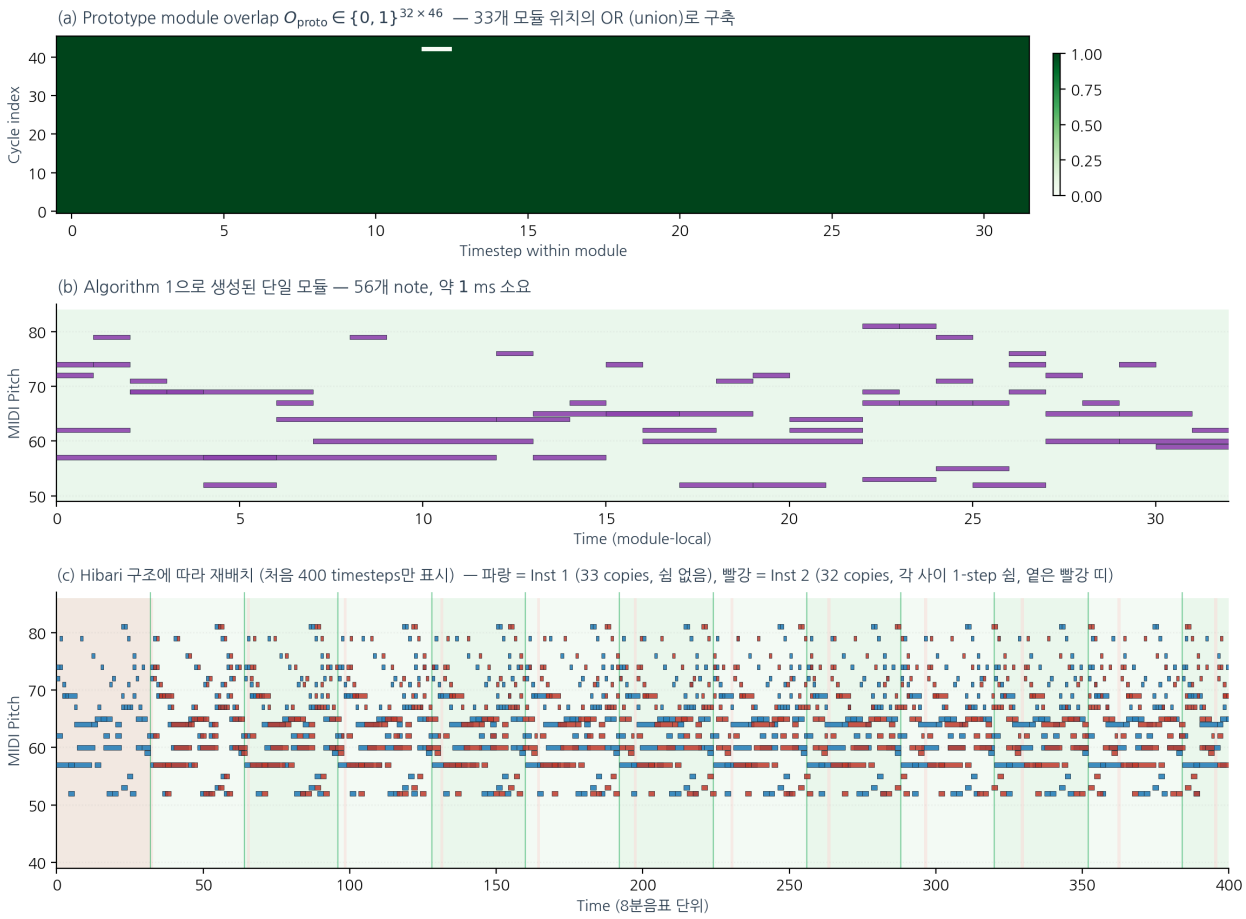

그림 J. (a) 첫 모듈의 중첩행렬, (b) 생성된 단일 모듈, (c) 33번 반복하여 재건한 전체 곡.

12. 차별화 포인트

대형 AI 음악 생성과의 차이

대형 AI (Magenta, Suno 등): 수만 곡 데이터 학습 -> "평균적 음악" 생성. 목표는 범용성.

이 연구: 한 곡의 수학적 구조 추출 -> 그 구조를 보존한 새 곡 생성. 목표는 특수성.

전자가 백과사전이라면 후자는 현미경이다.

기존 TDA-음악 연구와의 차이

정간보 TDA 선행연구(정재훈 외, 2024)를 세 방향으로 확장: (1) 서양 현대음악 적용, (2) 통계적 엄밀성(N=20), (3) "곡의 성격이 도구를 결정한다"는 새 관점.

해석 가능한 AI

이 파이프라인에서 모든 음은 "어떤 특정 cycle의 활성화"라는 구체적 근거를 가진다. 왜 그 음이 생성되었는지를 사후 설명할 수 있다. 일반적인 대형 AI에서는 거의 불가능한 일이다.

---

13. 도시환경으로의 확장 가능성

이 연구에서 사용한 persistent homology의 핵심 — **복잡한 네트워크에서 구멍(cycle)을 찾아 구조를 요약한다** — 은 음악에만 국한되지 않는다. 도시 공간은 본질적으로 복잡한 네트워크이며, 같은 수학적 도구가 적용될 수 있다.

복잡 네트워크의 동적 상태 탐지

Myers, Munch, & Khasawneh (2020)는 시계열 데이터를 그래프로 변환한 뒤 persistent homology를 적용하여 **주기적 상태와 혼돈적 상태를 구별**하는 파이프라인을 개발했다. 핵심 결과는 persistence barcode에서 추출한 위상적 요약 통계량(persistent entropy 등)이 기존 네트워크 지표(clustering coefficient, centrality 등)보다 **동적 상태 변화를 더 명확하게 감지**하며 **노이즈에 더 강건**하다는 것이다.

이 연구가 도시환경과 만나는 지점은 명확하다:

도시 형태학(Urban Morphology)에의 적용

이 연구의 개념	음악에서의 의미	도시환경에서의 대응
점(node)	개별 음(note)	교차로, 건물, POI
거리(distance)	음악이론적 거리 (Tonnetz)	가로 네트워크 거리, 접근성
H1 cycle	음들의 닫힌 관계 그룹	블록 구조, 순환 경로, 생태 회랑
Persistence	구조의 안정성	도시 조직의 견고함 / 취약점

가로망 위상 분석: 도시 가로망을 Vietoris-Rips 복합체로 변환하면, H0(연결 성분)과 H1(블록/루프)의 persistence가 도시 형태를 특성화한다. 격자형 도시(맨해튼)와 유기적 구도심(유럽 중세 도시)의 위상적 차이를 정량화할 수 있다.

회복탄력성(Resilience) 평가: H1 cycle이 많고 persistence가 긴 네트워크는 대체 경로가 풍부하다는 의미이며, 일부 연결이 끊어져도 전체 연결성이 유지될 가능성이 높다. 도시 인프라의 취약점을 위상적으로 식별하는 데 활용 가능하다.

멀티스케일 분석: Persistent homology의 핵심 강점은 여러 스케일을 동시에 포착한다는 것이다. 도시에서는 골목 단위의 미시 구조부터 도시 전체의 거시 구조까지를 하나의 barcode로 요약할 수 있다.

이 연구에서 "거리 함수의 선택이 결과를 47% 바꾼다"는 발견은 도시 분석에서도 시사점을 가진다. **어떤 "거리"로 도시를 바라보느냐** — 물리적 거리인지, 접근성인지, 토지이용 유사도인지 — 에 따라 도시의 위상 구조가 전혀 다르게 드러날 것이다.

---

14. 맺는 말

이 절은 연구자가 직접 작성하는 영역입니다.

- 이 연구를 통해 배운 것
- 수학과 음악의 교차, 그리고 도시환경으로의 확장에 대한 소감
- 환경대학원에서의 연구 방향과 이 경험의 연결

수치 요약

항목	수치
대상곡	hibari (Ryuichi Sakamoto, 2009)
곡 길이	8분 06초, 1,088 타임스텝
고유 음 수	23개
발견된 cycle 수	약 45~47개
기준선 JS (빈도)	0.0753
Tonnetz 교체 후	0.0398 (-47%, $p < 10$의 -20승)
최고 기록 (FC+연속값)	0.0004 (이론적 최대의 0.06%)
per-cycle 임계값	+48.6% (N=20, $p < 0.001$)
감쇄 lag 가중치	+70%
최적 옥타브 가중치	0.3
최적 alpha	0.0 (순수 Tonnetz)
Algorithm 1 생성 시간	약 50ms
확장 곡 수	5곡 (solari, aqua, Bach, Ravel + hibari)

---

15. 청취 안내 및 참고자료

직접 들어보기

이 보고서의 첫 페이지 QR코드로 원곡 hibari를 들을 수 있다. 처음 1분을 집중해서 들어본 뒤, 생성곡과 비교 청취를 권한다.

- 원곡의 "느낌"이 생성곡에서도 느껴지는가?
- 생성곡은 "흉내"인가, "같은 공간에 있는 다른 곡"인가?

참고 자료

- Carlsson, G. (2009). "Topology and data." Bulletin of the AMS, 46(2).
- Tymoczko, D. (2011). A Geometry of Music. Oxford University Press.
- Myers, A., Munch, E., & Khasawneh, F. A. (2020). "Persistent Homology of Complex Networks for Dynamic State Detection." Physical Review E, 100.
- Sakamoto, R. (2009). out of noise [Album]. commmons.
- Tran, L., Park, J., & Jung, J. (2021). Topological analysis of Korean traditional music.
- Heo, Choi, & Jung (2025). Path-representable distance and persistence barcode injection.

학술 원고: 엄밀한 수식, 증명, 통계 검증의 전체 내용은 학술 원고 `academic_paper_full.md` (~90페이지, 17 references)에 수록되어 있습니다.